Regresión lineal múltiple y diagnóstico econométrico

Notas para segundo parcial

Definiciones, convenciones, evidencia con datos reales, gráficos en Python y preguntas tipo CFA

Estas notas desarrollan, desde definiciones formales hasta lectura aplicada, los temas 4.1–4.9 y 5.1–5.13 de la propuesta de segundo parcial: supuestos y parámetros del RLM, prueba F, variables cualitativas, R^2 y R^2 ajustada, precios hedónicos, modelos no anidados, regresión cuantílica, aplicaciones financieras, diagnóstico, heteroscedasticidad, autocorrelación, modelos dinámicos, rezagos y Jarque–Bera.

Convención general: se distingue siempre entre *estimación*, *inferencia*, *diagnóstico* y *decisión*. En las aplicaciones financieras, la lectura económica y la unidad de medida preceden a la significancia estadística; además, salvo aviso en contrario, los rendimientos en los ejemplos empíricos se tratan como rendimientos logarítmicos semanales y las tasas se expresan en forma decimal.

Índice

0. Lenguaje y notación mínima **2**

Cómo leer una salida de regresión **3**

Convenciones econométricas, financieras y de reporte **3**

Mapa general **4**

1. 4.1 Supuestos del modelo de regresión lineal múltiple **6**

1.1. Supuestos esenciales . . . 6

1.2. Ejemplo: rendimiento mensual de un fondo . . . 7

1.3. Lectura rápida de supuestos . . . 7

2. 4.2 Parámetros del RLM: estimación e interpretación **7**

2.1. Interpretación ceteris paribus . . . 8

2.2. Ejemplo numérico . . . 8

2.3. Error estándar, estadístico t e intervalo . . . 9

3. 4.3 Prueba F: significancia conjunta y restricciones **9**

3.1. Forma general . . . 9

3.2. Ejemplo . . . 10

3.3. Relación con la prueba t . . . 10

3.4. Las distribuciones detrás de la inferencia: t, χ^2 y F . . . 10

3.5. Regiones de rechazo: ver la prueba antes de calcularla . . . 12

4. 4.4 Variables cualitativas: dummies e interacciones **14**

4.1. Cambio de intercepto . . . 15

4.2. Cambio de pendiente mediante interacción . . . 15

4.3. Trampa de variables ficticias . . . 15

4.4. Ejemplo financiero . . . 15

5. 4.5 R^2 y R^2 ajustada **15**

6. 4.6 Precios hedónicos **16**

6.1. Interpretación marginal . . . 16

6.2. Problemas frecuentes . . . 17

7. 4.7 Modelos no anidados **17**

7.1. Comparación de modelos no anidados . . . 17

8. 4.8 Regresión cuantílica 17

8.1. Interpretación . . . 18
8.2. Cuándo es útil . . . 18
8.3. Ejemplo . . . 18
8.4. Ejemplo real: regresión cuantílica de gasto con tarjeta . . . 18

9. 4.9 Aplicaciones financieras 19

9.1. Modelo de mercado . . . 20
9.2. Modelos multifactoriales . . . 20
9.3. Curvas y spreads . . . 20

Del DataFrame a la inferencia: tablas que sí deben leer 21

Laboratorio cuantitativo con datos reales y Python 22

10.5.1 Distribuciones y diagnóstico 28

10.1. Qué mirar . . . 28
10.2. Esquema conceptual . . . 28

11.5.2 Supuestos para diagnóstico 28

12.5.3–5.6 Heteroscedasticidad y prueba de Breusch–Pagan 29

12.1. Consecuencias . . . 29
12.2. Breusch–Pagan . . . 29
12.3. Ejemplo . . . 30
12.4. Correcciones . . . 30

13.5.7–5.10 Autocorrelación: Durbin–Watson y Breusch–Godfrey 30

13.1. AR(1) en el error . . . 30
13.2. Durbin–Watson . . . 31
13.3. Breusch–Godfrey . . . 31
13.4. DW vs BG . . . 31
13.5. Errores HAC / Newey–West . . . 31

14.5.11 Modelos dinámicos 31

14.1. Modelo con dependiente rezagada . . . 32
14.2. Multiplicador de largo plazo . . . 32

15.5.12 Rezagos **32**
15.1. Rezagos distribuidos 32
15.2. Selección del número de rezagos 32

16.5.13 Prueba de Jarque–Bera **33**
16.1. Ejemplo 33

17. Convenciones de interpretación, reporte y decisión **34**

18. Ejemplo integrado con lectura profesional **36**
18.1. Interpretación 36

19. Ejemplos resueltos de examen **37**

20. Preguntas tipo CFA **38**

21. Respuestas y razonamiento breve **42**

22. Formulario compacto **43**

23. Glosario ultrarrápido **43**

Lista de comprobación antes del examen **44**

0. Lenguaje y notación mínima

Antes de usar pruebas o diagnósticos conviene fijar el vocabulario. En econometría, muchos errores de examen provienen de confundir una *variable*, un *parámetro*, un *estimador*, una *estimación* y un *residuo*.

Definición — Variable dependiente. La variable Y es el objeto cuyo comportamiento condicional queremos explicar, describir o predecir. También se denomina variable explicada, respuesta o regresando.

Definición — Regresor o variable explicativa. Una variable X_j es un regresor cuando aparece del lado derecho de la ecuación y se utiliza para explicar variaciones de Y. Que una variable sea regresora **no implica** que sea causal.

Definición — Parámetro poblacional. Un parámetro, por ejemplo β_j, es una cantidad fija pero desconocida que caracteriza a la relación poblacional especificada. En el modelo lineal representa una pendiente parcial o, según la forma funcional, una semielasticidad o elasticidad.

Definición — Estimador y estimación. Un *estimador* $\hat{\beta}_j$ es una regla aleatoria construida con la muestra para aproximar β_j. Una vez observados los datos, el número obtenido es la *estimación*. El parámetro no es aleatorio en el enfoque clásico; el estimador sí lo es antes de observar la muestra.

Definición — Error estándar. El *error estándar* de un estimador es una estimación de la desviación estándar de su distribución muestral. Para un coeficiente de regresión,

$$se(\hat{\beta}_j) \approx \sqrt{\widehat{\mathrm{Var}}(\hat{\beta}_j)}.$$

Mide, por tanto, la **incertidumbre o precisión estadística** de $\hat{\beta}_j$: si repitiéramos el muestreo muchas veces bajo el mismo mecanismo generador de datos, $\hat{\beta}_j$ cambiaría de una muestra a otra, y el error estándar cuantifica el tamaño típico de esas fluctuaciones.

Un error estándar **pequeño** indica una estimación relativamente precisa; uno **grande** indica mayor incertidumbre. No mide el tamaño económico del coeficiente ni el tamaño de los residuos.

Lectura económica — Diferencia entre desviación estándar y error estándar. La *desviación estándar* describe la dispersión de una variable observada, por ejemplo la volatilidad de los rendimientos. El *error estándar* describe la dispersión de un *estimador* a través de muestras hipotéticas. En finanzas: la desviación estándar de r_t mide volatilidad; $se(\hat{\beta})$ mide cuánta incertidumbre existe alrededor de la beta estimada.

Definición — Error y residuo. El error poblacional ε_i recoge factores no observados que afectan a Y_i y que no están incluidos explícitamente en X_i. El residuo $\hat{\varepsilon}_i = Y_i - \hat{Y}_i$ es su análogo muestral después de estimar el modelo. No son sinónimos: el error no se observa; el residuo sí se calcula.

Definición — Media condicional. $\mathbb{E}(Y \mid X = x)$ es el promedio poblacional de Y entre unidades con valores de X iguales a x. El RLM especifica una forma funcional para esta media condicional.

Definición — Ceteris paribus. Interpretar β_j "manteniendo lo demás constante" significa comparar la media condicional de Y al variar X_j y mantener fijas las demás regresoras incluidas. Es una comparación condicional; no equivale automáticamente a un experimento causal.

Objeto	Notación típica	Qué significa
Variable dependiente	Y_i	Resultado observado.
Vector de regresores	X_i	Información explicativa observada.
Parámetro	β_j	Cantidad poblacional desconocida.
Estimador	$\hat{\beta}_j$	Regla muestral para estimar β_j.
Valor ajustado	$\hat{Y}_i$	Predicción dentro de la muestra.
Error	ε_i	Componente poblacional no observado.
Residuo	$\hat{\varepsilon}_i$	Diferencia observada $Y_i - \hat{Y}_i$.
Error estándar	$se(\hat{\beta}_j)$	Desviación estimada de la distribución muestral del estimador.
p-valor	p	Probabilidad, bajo H_0, de observar un estadístico tan extremo o más que el obtenido. No es $P(H_0 \mid \text{datos})$.

Cómo leer una salida de regresión

Suponga que un software reporta:

$$\hat{Y} = 2.30 + 0.45X_1 - 1.20X_2,$$

con errores estándar (0.80), (0.10) y (0.50). La lectura debe seguir un orden:

1. **Signo y unidades:** $\hat{\beta}_1 = 0.45$ significa 0.45 unidades de Y por unidad de X_1, si el modelo es nivel–nivel.
2. **Magnitud económica:** preguntar si 0.45 es grande o pequeño en el contexto.
3. **Precisión:** $t \approx 0.45/0.10 = 4.5$ sugiere estimación precisa frente a $H_0 : \beta_1 = 0$.
4. **Ajuste global:** revisar R^2, $\bar{R}^2$ y prueba F.
5. **Diagnóstico:** revisar residuos y supuestos antes de confiar en la inferencia clásica.

Convenciones econométricas, financieras y de reporte

Estas notas están pensadas para alumnado de Finanzas Cuantitativas. Por ello se fijan desde el inicio varias *convenciones de lectura*:

1. **Escala y unidades.** Un coeficiente solo puede interpretarse después de identificar la unidad de medida: pesos, puntos base, porcentaje, proporción o logaritmo.
2. **Rendimientos.** En los ejemplos empíricos con acciones se usan rendimientos logarítmicos semanales; en spreads y tasas, cuando se diga “pb” se trata de puntos base.
3. **Ceteris paribus.** Toda interpretación de pendiente en MCO es condicional en los demás regresores incluidos. En un examen, omitir esta idea resta precisión conceptual.
4. **Significancia estadística vs significancia económica.** Un coeficiente con $p < 0.05$ puede ser económicamente irrelevante; a la inversa, un coeficiente grande puede ser impreciso si la muestra es ruidosa.

5. **Errores estándar.** Siempre debe decirse si son clásicos o robustos. En presencia de heteroscedasticidad, el signo del coeficiente no cambia por usar HC, pero sí puede cambiar la inferencia.

6. **Variables dummy.** Toda dummy necesita categoría base explícita. Toda interacción requiere sumar coeficientes antes de dar la pendiente total del grupo correspondiente.

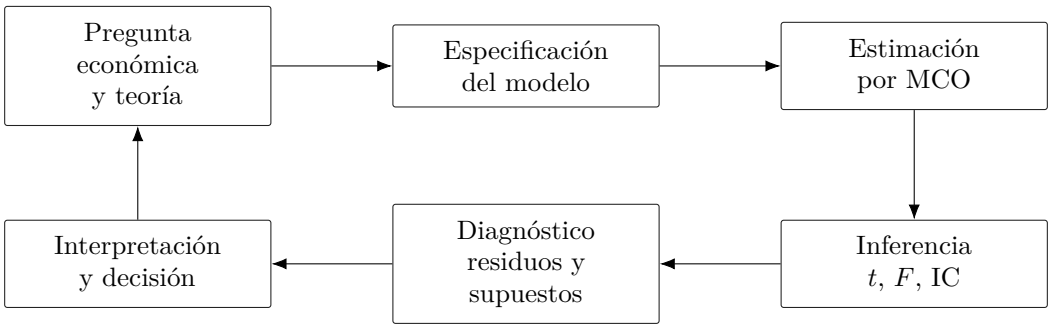
7. **Protocolo empírico.** El orden recomendado es: especificación → estimación → interpretación → prueba F → diagnóstico → corrección/inferencia final.

Cuadro 2: Convenciones de notación y lectura empleadas en el cuadernillo

Convención	**Lectura en estas notas**
Y	Variable dependiente o rendimiento/spread/tasa a explicar.
X_j	Regresor individual; puede ser factor, spread, dummy o rezago.
β_j	Parámetro poblacional.
$\hat{\beta}_j$	Estimación muestral del parámetro.
$se(\hat{\beta}_j)$	Error estándar del estimador.
u_i, ε_i	Error no observado del modelo.
$\hat{\varepsilon}_i$	Residuo muestral, base del diagnóstico.
R^2 y $\bar{R}^2$	Ajuste *in-sample*; no equivalen a calidad causal.
p-valor	Medida de compatibilidad con H_0; no es la probabilidad de que H_0 sea verdadera.

Mapa general

El flujo lógico de un análisis econométrico aplicado puede resumirse así:



Etapa	**Pregunta**	**Idea central**
Especificación	¿Qué explica a Y?	Elegir variables por teoría, temporalidad y mecanismo causal plausible.
Estimación	¿Cuánto vale cada efecto parcial?	MCO elige coeficientes que minimizan la suma de residuos al cuadrado.
Inferencia	¿La evidencia es compatible con una restricción?	Pruebas t y F comparan restricciones con la incertidumbre muestral.
Diagnóstico	¿Es razonable confiar en errores estándar y pruebas?	Examinar heteroscedasticidad, autocorrelación, normalidad, especificación y dinámica.

Interpretación	¿Qué significa económicamente?	Magnitud, signo, unidades, escenario y limitaciones.

1 4.1 Supuestos del modelo de regresión lineal múltiple

Definición — Regresión lineal múltiple (RLM). Un RLM es un modelo para la media condicional de una variable Y en función de varias regresoras. Se escribe

$$\mathbb{E}(Y_i \mid X_i) = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki}.$$

La ecuación observacional $Y_i = X_i'\beta + \varepsilon_i$ separa la parte sistemática $X_i'\beta$ de aquello no observado ε_i.

Definición — Lineal en parámetros. "Lineal" significa linealidad respecto de los coeficientes desconocidos, no necesariamente respecto de las variables. Por ejemplo $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + u$ es un modelo lineal en parámetros.

Definición — Exogeneidad. La condición $\mathbb{E}(\varepsilon \mid X) = 0$ expresa que, una vez controlado por X, el error no contiene un componente sistemático correlacionado con las regresoras. Es central para la interpretación de MCO como estimador de la relación condicional especificada.

El modelo poblacional es

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki} + \varepsilon_i, \qquad i = 1, \ldots, n.$$

En forma matricial:

$$\boldsymbol{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

1.1 Supuestos esenciales

Supuesto	Formulación	Significado econométrico
Linealidad en parámetros	$Y = \beta_0 + \sum_j \beta_j X_j + \varepsilon$	Los coeficientes entran linealmente. Las X pueden aparecer transformadas: $\log X$, X^2, interacciones, etc.
Muestra adecuada	Observaciones generadas por un mecanismo compatible con la inferencia	El muestreo debe permitir interpretar los estimadores y sus distribuciones. En series de tiempo no se exige i.i.d.; se modela la dependencia.
No colinealidad perfecta	$\operatorname{rank}(X) = k + 1$	Ninguna regresora es combinación lineal exacta de las demás. Sin esto, $(X'X)^{-1}$ no existe.
Media condicional cero	$\mathbb{E}(\varepsilon \mid X) = 0$	Las regresoras no deben contener información sistemática sobre el error. Es el supuesto clave para insesgadez condicional de MCO.
Homoscedasticidad	$\operatorname{Var}(\varepsilon_i \mid X) = \sigma^2$	La varianza del error es constante. No se necesita para insesgadez de MCO, pero sí para la fórmula clásica de varianza y eficiencia BLUE.

No autocorrelación	$\mathrm{Cov}(\varepsilon_i, \varepsilon_j \mid X) = 0$ para $i \neq j$	Los errores no deben compartir estructura temporal o transversal no modelada bajo el esquema clásico.
Normalidad	$\varepsilon \mid X \sim N(0, \sigma^2 I)$	Facilita inferencia exacta en muestras finitas. En muestras grandes puede reemplazarse por aproximaciones asintóticas bajo condiciones regulares.

Gauss–Markov.. Bajo linealidad, rango completo, media condicional cero y varianza esférica $\mathrm{Var}(\boldsymbol{\varepsilon} \mid X) = \sigma^2 I$, MCO es BLUE: el mejor estimador lineal insesgado, donde "mejor" significa mínima varianza dentro de la clase lineal e insesgada.

Una distinción que evita errores.. Heteroscedasticidad o autocorrelación no implican automáticamente que $\hat{\beta}$ sea sesgado. El sesgo aparece si falla la exogeneidad, por ejemplo por variable omitida correlacionada con una regresora, simultaneidad o error de medición no clásico.

1.2 Ejemplo: rendimiento mensual de un fondo

Suponga

$$r_t^{\text{fondo}} = \beta_0 + \beta_1 r_t^{\text{mercado}} + \beta_2 \Delta i_t + \varepsilon_t.$$

Si ε_t contiene una noticia macroeconómica no observada que también mueve Δi_t, entonces es plausible que $\mathbb{E}(\varepsilon_t \mid \Delta i_t) \neq 0$. El problema no es sólo de errores estándar: la interpretación de $\hat{\beta}_2$ como efecto parcial queda comprometida.

1.3 Lectura rápida de supuestos

Problema	Qué suele afectar	Respuesta típica
Heteroscedasticidad	Error estándar clásico	Errores robustos HC, WLS si la forma es conocida/plausible
Autocorrelación	Error estándar y eficiencia	HAC/Newey–West, GLS, dinámica explícita
Colinealidad alta	Precisión de coeficientes	Más información, reespecificar con teoría; no "curar" eliminando por rutina
Endogeneidad	Sesgo/consistencia	Variables instrumentales, diseño causal, controles válidos
Mala forma funcional	Sesgo de especificación	Transformaciones, términos no lineales, interacciones

2 4.2 Parámetros del RLM: estimación e interpretación

Definición — Mínimos Cuadrados Ordinarios (MCO). MCO elige los coeficientes que minimizan la suma de cuadrados de los residuos:

$$SSR(b) = \sum_{i=1}^{n} (Y_i - X_i' b)^2.$$

Geométricamente, $\hat{y} = X\hat{\beta}$ es la proyección ortogonal de y sobre el espacio generado por las columnas de X.

Definición — Pendiente parcial. En un modelo nivel–nivel, $\beta_j = \partial \mathbb{E}(Y \mid X)/\partial X_j$. Mide la tasa de cambio de la media condicional respecto de X_j, manteniendo fijos los demás regresores.

Definición — Insesgadez, consistencia y eficiencia. Insesgadez significa $\mathbb{E}(\hat{\beta}) = \beta$ en muestras del tamaño considerado. Consistencia significa $\hat{\beta} \to_p \beta$ cuando $n \to \infty$. Eficiencia compara varianzas entre estimadores dentro de una clase. Son propiedades distintas.

MCO resuelve

$$\min_{b_0,\ldots,b_k} \sum_{i=1}^{n} (Y_i - b_0 - b_1 X_{1i} - \cdots - b_k X_{ki})^2 .$$

En matriz,

$$\hat{\boldsymbol{\beta}} = (X'X)^{-1} X'\boldsymbol{y}.$$

2.1 Interpretación ceteris paribus

El coeficiente β_j es el cambio esperado en Y asociado con una unidad adicional de X_j, manteniendo constantes las demás regresoras, cuando la forma funcional es lineal-lineal.

Forma	**Modelo**	**Interpretación aproximada**
Nivel–nivel	$Y = \beta_0 + \beta_1 X$	$+1$ unidad en X se asocia con β_1 unidades en Y.
Log–nivel	$\ln Y = \beta_0 + \beta_1 X$	$+1$ unidad en X se asocia con $100\beta_1\,\%$ en Y (exacto: $100(e^{\beta_1} - 1)\,\%$).
Nivel–log	$Y = \beta_0 + \beta_1 \ln X$	$+1\,\%$ en X se asocia con $\beta_1/100$ unidades en Y.
Log–log	$\ln Y = \beta_0 + \beta_1 \ln X$	β_1 es elasticidad: $+1\,\%$ en X se asocia con $\beta_1\,\%$ en Y.

2.2 Ejemplo numérico

Considere

$$\widehat{\ln(P)} = 10.20 + 0.065\,\text{habitaciones} + 0.310\,\ln(\text{m}^2) - 0.004\,\text{distancia}.$$

Interpretaciones:

- Una habitación adicional se asocia con aproximadamente $6.5\,\%$ más en el precio, manteniendo lo demás constante; de forma exacta, $100(e^{0.065} - 1) \approx 6.72\,\%$.
- Una expansión de $1\,\%$ en superficie se asocia con un aumento de $0.31\,\%$ en el precio.
- Un kilómetro adicional de distancia se asocia con aproximadamente $0.4\,\%$ menos en el precio si distancia se mide en km.

2.3 Error estándar, estadístico t e intervalo

Bajo los supuestos clásicos de MCO y homoscedasticidad,

$$\widehat{\mathrm{Var}}(\hat{\beta}) = \hat{\sigma}^2 (X'X)^{-1}, \qquad \hat{\sigma}^2 = \frac{\sum_{i=1}^{n} \hat{\varepsilon}_i^2}{n-k-1}.$$

El error estándar de $\hat{\beta}_j$ es la raíz cuadrada del elemento diagonal correspondiente de esta matriz. Esto deja ver dos fuentes de precisión: menor ruido residual $\hat{\sigma}^2$ y mayor información independiente en X tienden a reducir los errores estándar; alta colinealidad tiende a aumentarlos.

Ejemplo. Si $\hat{\beta} = 0.84$ y $se(\hat{\beta}) = 0.30$, la estimación puntual es 0.84, pero su incertidumbre típica es 0.30. Para $H_0 : \beta = 0$,

$$t = \frac{0.84}{0.30} = 2.80.$$

El error estándar entra así directamente en la construcción del estadístico t y del intervalo de confianza.

Para probar

$$H_0 : \beta_j = \beta_{j,0},$$

se usa

$$t = \frac{\hat{\beta}_j - \beta_{j,0}}{se(\hat{\beta}_j)}.$$

Un intervalo aproximado del 95 % es

$$\hat{\beta}_j \pm t_{0.975,\, n-k-1}\, se(\hat{\beta}_j).$$

Idea CFA.. Significancia estadística no equivale a relevancia económica. Un coeficiente puede ser muy preciso pero pequeño; o grande pero estimado con mucha incertidumbre.

3 4.3 Prueba F: significancia conjunta y restricciones

Definición — Prueba F. Es una prueba de hipótesis para una o varias restricciones lineales sobre los parámetros. Su uso característico es evaluar si un *bloque* de regresores aporta información condicional conjunta una vez que otros regresores permanecen en el modelo.

Definición — Modelo restringido y no restringido. El modelo no restringido estima libremente todos los parámetros relevantes. El restringido impone H_0, por ejemplo $\beta_2 = \beta_3 = 0$. Si imponer las restricciones deteriora demasiado el ajuste relativo a la variación residual, el estadístico F será grande.

La prueba F evalúa varias restricciones lineales simultáneamente. Es la herramienta correcta cuando la hipótesis no puede reducirse a un solo coeficiente.

3.1 Forma general

$$H_0 : R\boldsymbol{\beta} = \boldsymbol{r},$$

donde q es el número de restricciones. Una forma basada en sumas de cuadrados es

$$F = \frac{(SSR_R - SSR_{UR})/q}{SSR_{UR}/(n-k-1)},$$

donde R es el modelo restringido y UR el no restringido.

3.2 Ejemplo

Modelo:

$$R_i = \beta_0 + \beta_1 \text{Size}_i + \beta_2 \text{Value}_i + \beta_3 \text{Momentum}_i + \varepsilon_i.$$

Hipótesis:

$$H_0 : \beta_2 = \beta_3 = 0.$$

Si $SSR_R = 1250$, $SSR_{UR} = 1100$, $q = 2$, $n = 120$ y $k = 3$:

$$F = \frac{(1250 - 1100)/2}{1100/(120 - 4)} \approx 7.91.$$

La lectura es conjunta: se pregunta si Value y Momentum, como bloque, aportan información condicional sobre el rendimiento.

3.3 Relación con la prueba t

Si hay una sola restricción, $q = 1$, entonces bajo el esquema clásico

$$F = t^2.$$

Prueba	**Uso natural**	**Ejemplo**
t	Una restricción	$H_0 : \beta_3 = 0$
F	Dos o más restricciones	$H_0 : \beta_2 = \beta_3 = 0$
F global	Todas las pendientes	$H_0 : \beta_1 = \cdots = \beta_k = 0$

3.4 Las distribuciones detrás de la inferencia: t, χ^2 y F

En econometría aplicada no basta con memorizar una regla como "rechazar si $p < 0.05$". Conviene visualizar de dónde salen los valores críticos. Las tres distribuciones que aparecen una y otra vez en este parcial son:

- la t **de Student**, para restricciones individuales y pequeños errores estándar estimados;
- la χ^2, en pruebas LM como Breusch–Pagan, Breusch–Godfrey y Jarque–Bera en su formulación asintótica;
- la F, para restricciones conjuntas en modelos lineales.

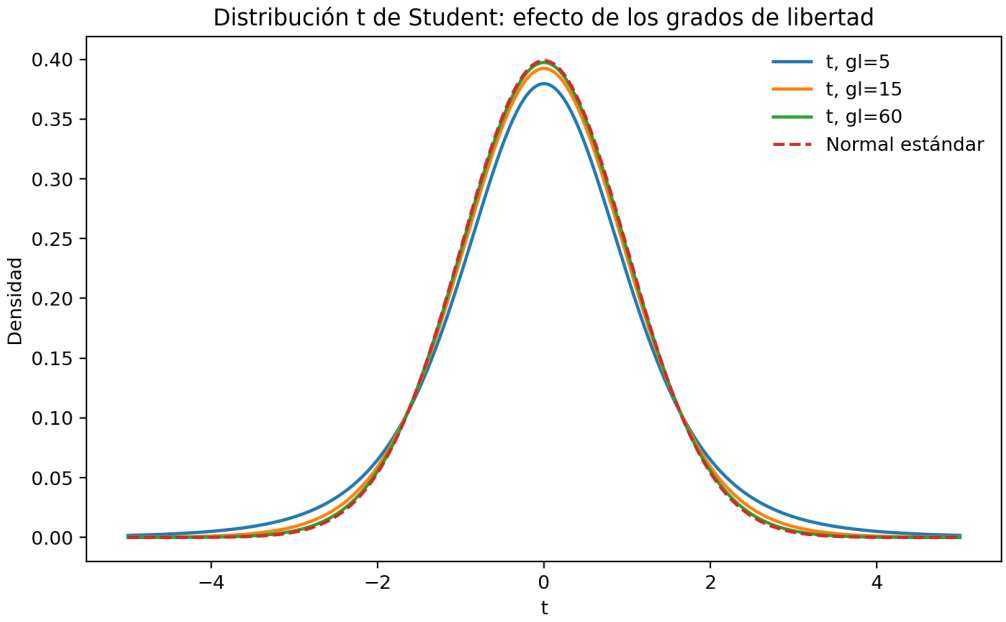


Figura 1: Distribución t de Student para distintos grados de libertad. Conforme aumentan los grados de libertad, la distribución se aproxima a la normal estándar.

Lectura financiera. Si un coeficiente estimado tiene $t = 2.8$, no se interpreta ese número aisladamente: se compara con la distribución t correspondiente a los grados de libertad del modelo. En muestras grandes, un valor absoluto por arriba de aproximadamente 2 suele ser una guía rápida, pero el valor crítico exacto depende de los grados de libertad y de si la prueba es bilateral o unilateral.

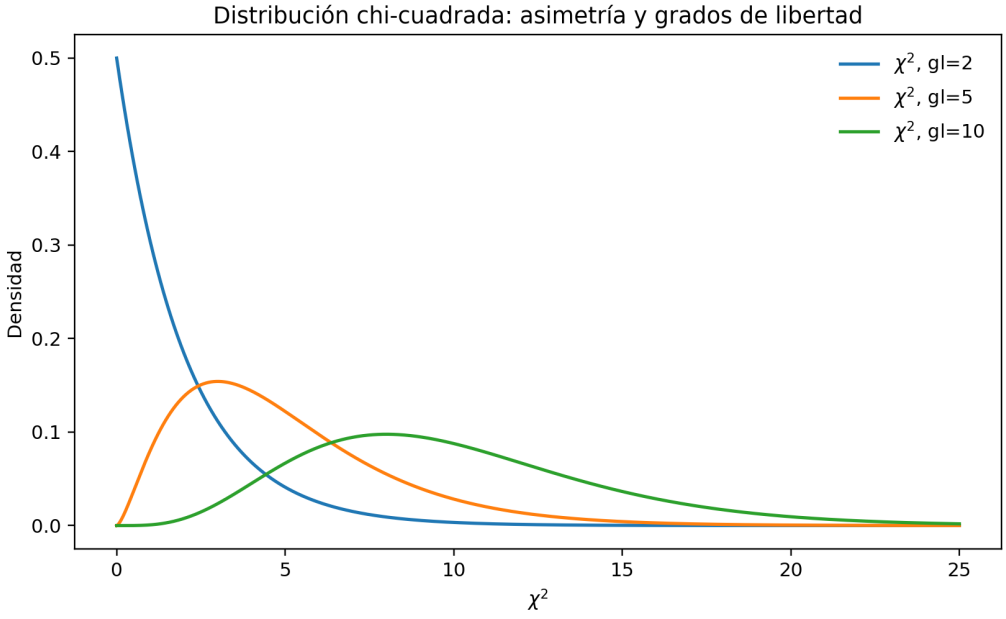


Figura 2: Distribución χ^2. Es no negativa y suele ser asimétrica a la derecha.

Lectura financiera. Las pruebas LM acumulan evidencia en una cantidad no negativa. Por eso valores

grandes del estadístico son los que llevan al rechazo de H_0. En BP, por ejemplo, un nR^2 suficientemente grande indica que los cuadrados de los residuos contienen estructura sistemática explicable por las regresoras.

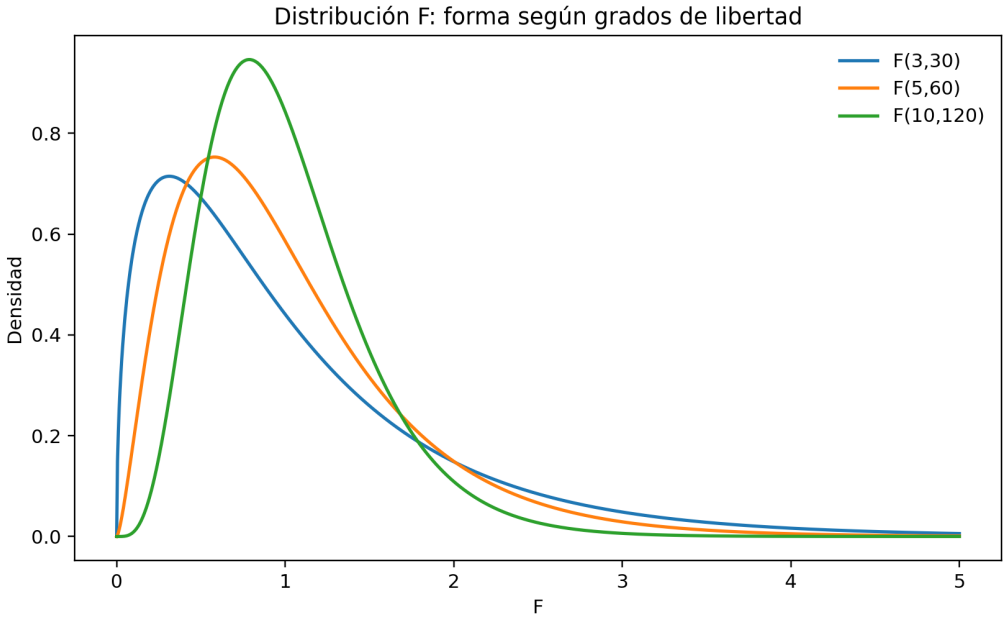


Figura 3: Distribución F para distintos grados de libertad. La masa se concentra cerca de uno a medida que aumentan los grados de libertad.

3.5 Regiones de rechazo: ver la prueba antes de calcularla

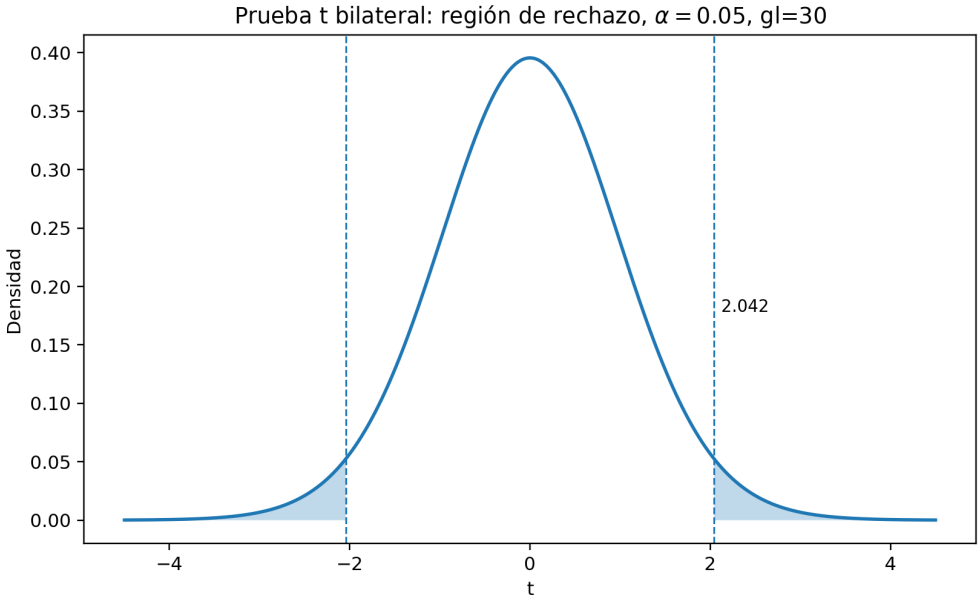


Figura 4: Prueba t bilateral al 5 %: el área total sombreada suma $\alpha = 0.05$.

Para 30 grados de libertad y una prueba bilateral con $\alpha = 0.05$, el valor crítico es aproximadamente ± 2.042. Por tanto:

$$|t_{obs}| > 2.042 \quad \Longrightarrow \quad \text{rechazar } H_0.$$

Ejemplo: si $\hat{\beta} = 0.84$ y $se(\hat{\beta}) = 0.30$, entonces

$$t = \frac{0.84}{0.30} = 2.80,$$

y la hipótesis $H_0 : \beta = 0$ se rechaza al 5 %.

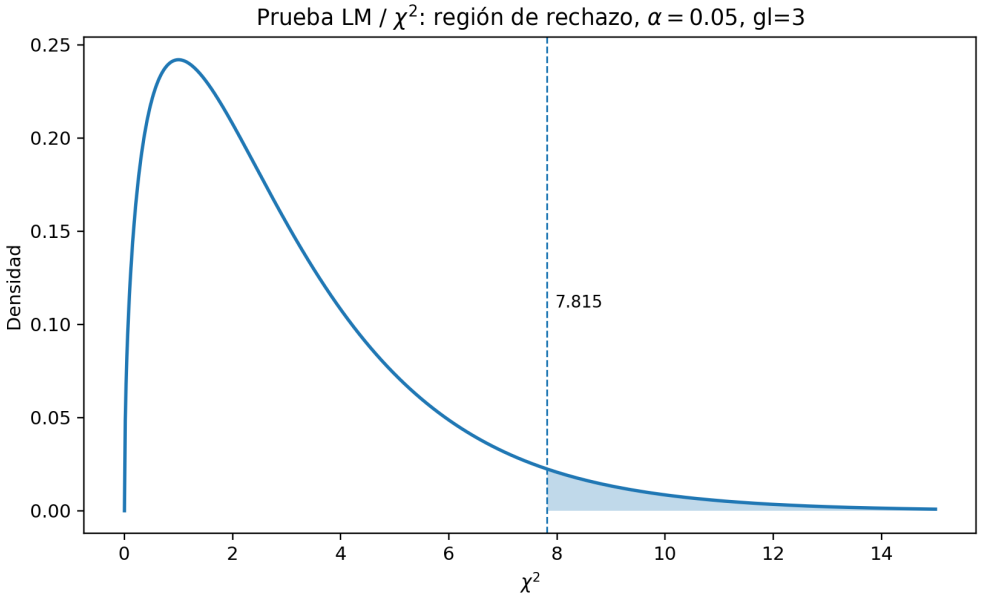


Figura 5: Región de rechazo para una prueba χ^2 con 3 grados de libertad.

En una prueba LM con tres restricciones, el valor crítico al 5 % es aproximadamente 7.815. Si una prueba BP arroja $LM = 10.2$, se rechaza homoscedasticidad al 5 % porque $10.2 > 7.815$.

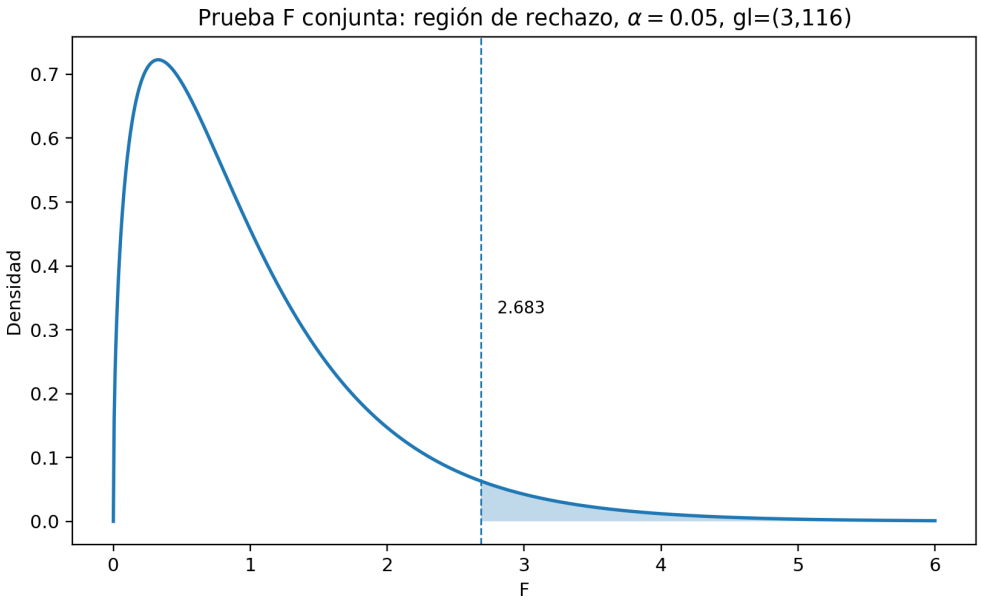


Figura 6: Región de rechazo para una prueba $F(3, 116)$ al 5 %.

Si se contrastan tres restricciones conjuntas y el estadístico observado es $F = 4.10$, mientras el valor crítico es aproximadamente 2.68, se rechaza H_0. La interpretación no es que "cada coeficiente es significativo", sino que *el bloque de restricciones es incompatible con los datos al nivel elegido.*

Cuadro 6: Valores críticos generados directamente en Python con `scipy.stats`

Distribución	gl	alpha	valor crítico
t bilateral	30	0.050000	2.042000
t bilateral	60	0.050000	2.000000
chi-cuadrada	3	0.050000	7.815000
chi-cuadrada	5	0.050000	11.070000
F	(3,116)	0.050000	2.683000
F	(5,120)	0.050000	2.290000

Convención para el examen.. Siempre escribir, en este orden: hipótesis, estadístico, distribución de referencia, grados de libertad, regla de decisión y conclusión contextualizada.

4 4.4 Variables cualitativas: dummies e interacciones

Definición — Variable cualitativa. Una variable cualitativa clasifica observaciones en categorías (sector, región, régimen, trimestre, tipo de bono). Para incorporarla a un RLM se representa mediante variables indicadoras o *dummies*.

Definición — Dummy. Una dummy D toma valor 1 cuando la observación pertenece a una categoría y 0 en caso contrario. Su coeficiente se interpreta siempre respecto de una categoría base.

Definición — Interacción. Una interacción $X \times D$ permite que el efecto marginal de X dependa del grupo D. No debe interpretarse aisladamente: la pendiente del grupo $D = 1$ es la suma de coeficientes correspondiente.

Una variable indicadora D toma valores 0 y 1. El grupo con $D = 0$ es la categoría base.

4.1 Cambio de intercepto

$$Y = \beta_0 + \beta_1 X + \delta D + \varepsilon.$$

Para $D = 0$:

$$\mathbb{E}(Y \mid X, D = 0) = \beta_0 + \beta_1 X.$$

Para $D = 1$:

$$\mathbb{E}(Y \mid X, D = 1) = (\beta_0 + \delta) + \beta_1 X.$$

Entonces δ mide una diferencia de nivel condicional.

4.2 Cambio de pendiente mediante interacción

$$Y = \beta_0 + \beta_1 X + \delta D + \gamma(XD) + \varepsilon.$$

Para $D = 1$, la pendiente es $\beta_1 + \gamma$.

4.3 Trampa de variables ficticias

Con m categorías y constante, se usan $m - 1$ dummies. Incluir las m genera colinealidad perfecta.

4.4 Ejemplo financiero

$$\text{spread} = \beta_0 + \beta_1 \text{duration} + \delta\, \text{InvestmentGrade} + \gamma(\text{duration} \times \text{InvestmentGrade}) + \varepsilon.$$

Aquí δ cambia el intercepto y γ modifica la sensibilidad del spread a la duración para bonos investment grade frente al grupo base.

5 4.5 R^2 y R^2 ajustada

Definición — Coeficiente de determinación R^2. Con constante, R^2 es la proporción de la variación muestral total de Y explicada por los valores ajustados del modelo:

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{SSR}{TSS}.$$

No mide causalidad, calidad de identificación ni validez de los supuestos.

Definición — R^2 ajustada. La $\bar{R}^2$ corrige el ajuste por grados de libertad y penaliza la incorporación de regresores que no reducen suficientemente el SSR. Puede disminuir al añadir una variable.

$$R^2 = 1 - \frac{SSR}{TSS}, \qquad TSS = \sum_i (Y_i - \bar{Y})^2.$$

R^2 mide la fracción de variación muestral de Y explicada por el ajuste lineal. Siempre aumenta o permanece igual cuando se agregan regresoras.

La versión ajustada penaliza por complejidad:

$$\bar{R}^2 = 1 - \frac{SSR/(n-k-1)}{TSS/(n-1)}.$$

	R^2	$\bar{R}^2$
Al agregar una variable	Nunca disminuye	Puede subir o bajar
Penaliza complejidad	No	Sí
Sirve para comparar modelos con distinta cantidad de regresoras	Limitado	Más útil, si la variable dependiente es la misma
Prueba causalidad	No	No
Indica buena especificación por sí solo	No	No

Advertencia.. Un R^2 alto puede coexistir con endogeneidad, tendencia espuria, heteroscedasticidad o una interpretación causal inválida. En series temporales con tendencia puede ser particularmente engañoso.

6 4.6 Precios hedónicos

Definición — Modelo de precios hedónicos. Es una regresión que descompone el precio observado de un bien diferenciado en el valor asociado a sus características. En vivienda, por ejemplo, el precio refleja simultáneamente superficie, ubicación, antigüedad, servicios y amenidades.

Definición — Precio implícito o marginal de un atributo. En una especificación diferenciable, el precio implícito de la característica z_j es $\partial \mathbb{E}(P \mid z)/\partial z_j$. En un modelo lineal coincide con β_j; en modelos logarítmicos o con interacciones depende de la forma funcional y, a veces, del punto de evaluación.

El enfoque hedónico modela el precio de un bien como función de sus atributos observables:

$$P_i = f(z_{1i}, \ldots, z_{ki}) + \varepsilon_i.$$

En vivienda, z puede incluir superficie, antigüedad, ubicación, número de habitaciones, estacionamiento, accesibilidad, seguridad, etc.

6.1 Interpretación marginal

En un modelo lineal,

$$P_i = \beta_0 + \beta_1 \mathrm{m}_i^2 + \beta_2 \mathrm{edad}_i + \beta_3 \mathrm{metro}_i + \varepsilon_i,$$

β_1 es el precio marginal estimado de un m^2 adicional, condicional a los otros atributos.

En un log-lineal,

$$\ln P_i = \beta_0 + \beta_1 \mathrm{m}_i^2 + \cdots ,$$

β_1 se interpreta aproximadamente como cambio porcentual en precio por unidad de atributo.

6.2 Problemas frecuentes

- **Variables omitidas:** calidad no observada del inmueble o del vecindario.
- **Endogeneidad espacial:** atributos de ubicación pueden correlacionarse con factores no observados.
- **No linealidad:** el valor marginal del m^2 puede depender del tamaño total.
- **Interacciones:** un estacionamiento puede valer distinto según zona o segmento.

7 4.7 Modelos no anidados

Definición — Modelos anidados. M_0 está anidado en M_1 si M_0 puede obtenerse imponiendo restricciones sobre parámetros de M_1.

Definición — Modelos no anidados. Dos modelos son no anidados cuando ninguno puede obtenerse como caso restringido del otro. En ese caso, la prueba F clásica de restricciones no es, en general, la comparación apropiada.

Dos modelos están anidados si uno puede obtenerse imponiendo restricciones sobre el otro. Por ejemplo,

$$M_1 : Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + u$$

y

$$M_0 : Y = \beta_0 + \beta_1 X_1 + u$$

son anidados porque M_0 surge de M_1 al imponer $\beta_2 = 0$.

No son anidados, por ejemplo,

$$M_A : Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + u, \qquad M_B : Y = \gamma_0 + \gamma_1 Z_1 + \gamma_2 Z_2 + v,$$

si ninguno es una restricción paramétrica del otro.

7.1 Comparación de modelos no anidados

No basta con una prueba F clásica. Pueden usarse criterios como AIC/BIC, desempeño fuera de muestra, teoría económica y pruebas específicas como Davidson–MacKinnon en ciertos contextos.

Criterio sano.. La selección no debe descansar en una sola métrica. Un modelo con menor BIC puede ser preferible para parsimonia predictiva, pero no necesariamente responde mejor una pregunta causal.

8 4.8 Regresión cuantílica

Definición — Cuantil condicional. $Q_\tau(Y \mid X)$ es el valor que deja aproximadamente una fracción τ de la distribución condicional de Y por debajo. La mediana condicional corresponde a $\tau = 0.5$.

Definición — Regresión cuantílica. Modela directamente $Q_\tau(Y \mid X) = X'\beta_\tau$ en lugar de $\mathbb{E}(Y \mid X)$. Así permite que la asociación entre X y Y sea distinta en la parte baja, central o alta de la distribución condicional.

MCO modela la media condicional. La regresión cuantílica modela un cuantil condicional, por ejemplo la mediana:

$$Q_\tau(Y \mid X) = X'\beta_\tau, \qquad 0 < \tau < 1.$$

El estimador minimiza la pérdida asimétrica

$$\min_b \sum_{i=1}^{n} \rho_\tau(Y_i - X_i'b),$$

donde

$$\rho_\tau(u) = u(\tau - \mathbf{1}\{u < 0\}).$$

8.1 Interpretación

Si $\tau = 0.90$, $\beta_{j,0.90}$ describe cómo X_j se asocia con el percentil 90 condicional de Y, no con su media.

8.2 Cuándo es útil

- Distribuciones asimétricas o con colas relevantes.
- Efectos heterogéneos a lo largo de la distribución.
- Riesgo, salarios, pérdidas, spreads, volatilidad o tiempos de espera.

8.3 Ejemplo

Si el efecto de apalancamiento sobre el spread es 0.8 en la mediana, pero 2.1 en el cuantil 0.90, el apalancamiento se relaciona mucho más intensamente con empresas ubicadas en la cola alta de spreads.

8.4 Ejemplo real: regresión cuantílica de gasto con tarjeta

Con el conjunto real `ccard` de `statsmodels`, se modela el gasto promedio con tarjeta `AVGEXP` como función de edad, ingreso y tenencia de vivienda. En lugar de estimar solamente la media condicional, se estiman varios cuantiles.

Cuadro 7: Descriptivos del DataFrame `ccard`

Variable	count	mean	std	min	Mediana	max
AVGEXP	72.000000	262.530000	318.050000	9.580000	158.320000	1898.030000
AGE	72.000000	31.280000	7.150000	20.000000	30.000000	55.000000
INCOME	72.000000	3.440000	1.700000	1.500000	3.000000	10.000000
OWNRENT	72.000000	0.380000	0.490000	0.000000	0.000000	1.000000

Cuadro 8: Coeficientes de regresión cuantílica para distintos cuantiles

Variable	q=0.10	q=0.25	q=0.50	q=0.75	q=0.90
AGE	-3.793000	-2.787000	-4.275000	2.162000	10.099000
INCOME	34.504000	62.883000	56.404000	82.392000	140.859000
Intercept	51.533000	-23.647000	98.934000	-70.576000	-325.782000
OWNRENT	43.492000	43.708000	95.181000	78.130000	194.685000

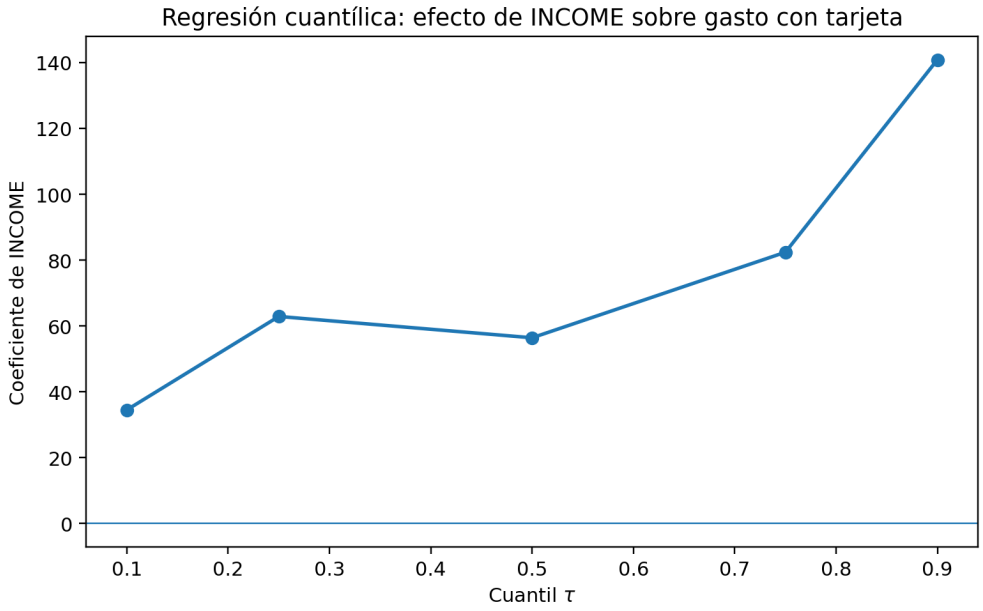


Figura 7: Coeficiente de ingreso a lo largo de distintos cuantiles del gasto con tarjeta.

La Figura 7 muestra por qué la regresión cuantílica puede ser más informativa que una sola pendiente media: el vínculo entre ingreso y gasto puede variar entre clientes con gasto bajo, mediano y alto. En finanzas cuantitativas esta idea aparece también cuando la sensibilidad de una variable cambia entre estados tranquilos y extremos de la distribución.

9 4.9 Aplicaciones financieras

Definición — Beta de mercado. En el modelo de mercado, β_i mide la sensibilidad condicional del rendimiento excedente del activo frente a movimientos del rendimiento excedente del mercado. No es una volatilidad absoluta: es una exposición sistemática dentro del modelo.

Definición — Alfa. α_i es el intercepto del modelo de rendimiento. Describe el promedio condicional no explicado por los factores incluidos. Su interpretación económica depende de la especificación y del horizonte de datos.

9.1 Modelo de mercado

$$R_{i,t} - R_{f,t} = \alpha_i + \beta_i(R_{m,t} - R_{f,t}) + \varepsilon_{i,t}.$$

Interpretación:

- β_i: sensibilidad al factor de mercado.
- α_i: rendimiento promedio no explicado por el mercado dentro del modelo.

9.2 Modelos multifactoriales

$$R_{i,t} - R_{f,t} = \alpha_i + \beta_M MKT_t + \beta_S SMB_t + \beta_H HML_t + \varepsilon_{i,t}.$$

La lectura es condicional: cada beta mide sensibilidad al factor correspondiente manteniendo los demás constantes.

9.3 Curvas y spreads

$$\Delta\text{Spread}_t = \beta_0 + \beta_1 \Delta i_t + \beta_2 \Delta\text{VIX}_t + \beta_3 \Delta\text{liquidez}_t + \varepsilon_t.$$

Aquí la especificación exige especial atención a autocorrelación, heteroscedasticidad condicional, dinámica y posibles rupturas estructurales.

Del DataFrame a la inferencia: tablas que sí deben leer

En Python, una regresión no comienza con una fórmula: comienza con un `DataFrame`. El alumnado debe ser capaz de mirar una tabla y reconocer observaciones, variables, frecuencia y transformaciones.

El siguiente fragmento corresponde a rendimientos logarítmicos semanales construidos a partir de precios normalizados de acciones tecnológicas. `MKT_EW` es un índice equiponderado de las seis acciones disponibles en el conjunto.

Cuadro 9: Primeras ocho filas del DataFrame de rendimientos utilizado en los ejemplos

date	AAPL	MKT_EW	MSFT	AMZN	GOOG
2018-01-08	0.011900	0.019500	0.015900	0.060000	0.018000
2018-01-15	0.007700	0.004100	0.004500	-0.008200	0.013500
2018-01-22	-0.039700	0.064000	0.044100	0.079700	0.033100
2018-01-29	-0.066300	-0.025300	-0.024500	0.019700	-0.055900
2018-02-05	-0.025800	-0.057800	-0.040000	-0.065300	-0.069000
2018-02-12	0.097500	0.064800	0.042400	0.078300	0.053500
2018-02-19	0.017600	0.027100	0.022100	0.034800	0.028800
2018-02-26	0.004000	-0.005900	-0.010800	0.000200	-0.043400

```
import numpy as np
import plotly.express as px

stocks = px.data.stocks()
returns = np.log(stocks[['GOOG','AAPL','AMZN','FB','NFLX','MSFT']]).diff()
returns['MKT_EW'] = returns.mean(axis=1)
returns.head()
```

A partir de ese mismo DataFrame puede estimarse un RLM de AAPL sobre otras acciones tecnológicas:

$$r_{AAPL,t} = \beta_0 + \beta_1 r_{MSFT,t} + \beta_2 r_{AMZN,t} + \beta_3 r_{GOOG,t} + u_t.$$

Cuadro 10: Tabla de coeficientes creada desde un objeto de regresión en Python

Variable	Coef.	EE	t	p
const	0.001200	0.003200	0.387200	0.699400
MSFT	0.559300	0.191200	2.925900	0.004300
AMZN	0.111900	0.118900	0.941200	0.348900
GOOG	0.094700	0.138400	0.684200	0.495400

Cuadro 11: Medidas globales del modelo obtenidas desde el objeto `OLSResults`

Medida	Valor
n	104
R^2	0.3049
R^2 ajustada	0.284
F global	14.62
p-valor F	5.758e-08
SSR	0.09972

Esta tabla permite introducir la prueba F global de manera natural. La pregunta no es si MSFT, AMZN y GOOG son individualmente significativos, sino si el conjunto de pendientes satisface

$$H_0 : \beta_1 = \beta_2 = \beta_3 = 0.$$

El estadístico F reportado por el modelo resume precisamente esa prueba conjunta.

DataFrames que conviene pedir en tareas

En una práctica aplicada conviene que cada estudiante entregue, como mínimo:

1. `df.head()` para mostrar estructura y frecuencia de los datos;
2. `df.describe()` para escala, dispersión y valores extremos;
3. un DataFrame de coeficientes con estimación, error estándar, t, p e intervalo;
4. un DataFrame de diagnósticos con BP, BG y JB;
5. una tabla final con la conclusión económica de cada coeficiente relevante.

Estas tablas son mucho más útiles que una tabla decorativa de comparación porque surgen directamente del flujo reproducible de análisis.

Laboratorio cuantitativo con datos reales y Python

La econometría se vuelve verdaderamente útil para estudiantes de Finanzas Cuantitativas cuando se conecta con series observadas. En esta sección se incorporan ejemplos con datos reales tomados de conjuntos ampliamente utilizados en Python. El objetivo no es reemplazar la teoría, sino mostrar cómo leer una regresión en contexto.

Cuadro 12: Fuentes de datos utilizadas en los gráficos y tablas

Conjunto	Fuente	Uso
Acciones tecnológicas	Dataset real de mercado incluido en Plotly Express	Aplicación financiera, beta, diagnóstico
Interés e inflación	`statsmodels.datasets.interest_inflation`	Relación tasas-inflación
Macrodata	`statsmodels.datasets.macrodata`	Dinámica, rezagos, persistencia y tasas reales

Ejemplo A. Comportamiento relativo de acciones tecnológicas

La Figura 8 muestra precios normalizados de AAPL, AMZN, GOOG y MSFT. El mensaje pedagógico es inmediato: incluso dentro de un mismo segmento, las trayectorias y la volatilidad relativa difieren. Esa heterogeneidad justifica tanto modelos de factores como diagnósticos de colas y asimetría.

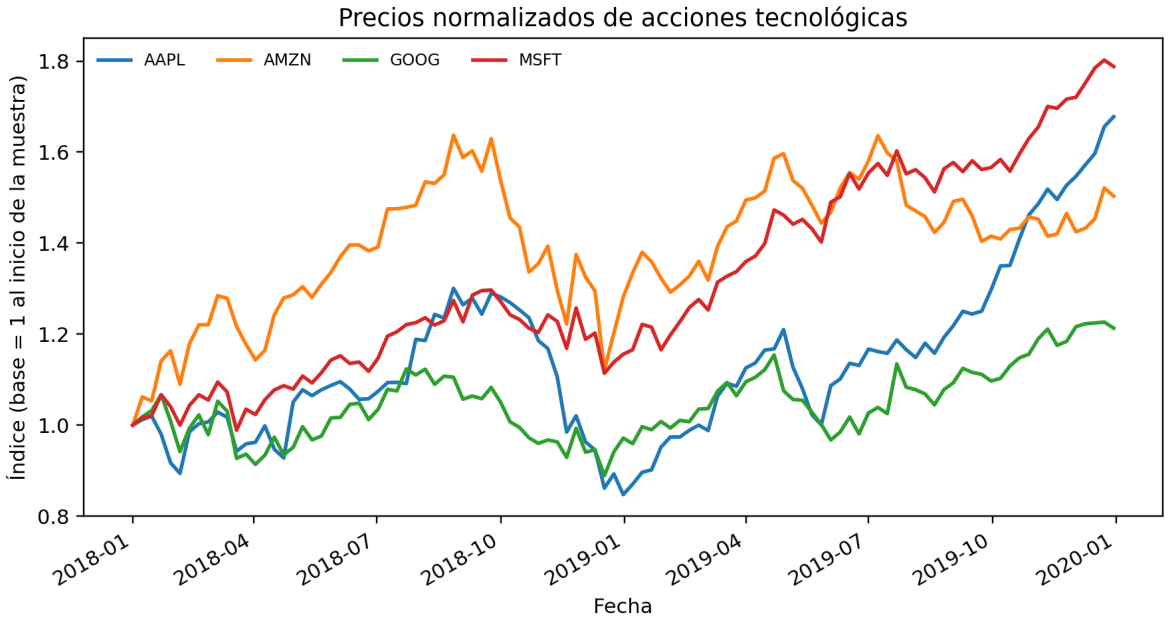


Figura 8: Precios normalizados de acciones tecnológicas.

Cuadro 13: Resumen estadístico de rendimientos logarítmicos semanales

Serie	Media	DesvStd	Min	Max	Asimetría	CurtosisExceso
AAPL	0.005000	0.037300	-0.116300	0.124400	-0.200800	1.704200
MSFT	0.005600	0.026700	-0.081700	0.073100	-0.504300	1.067200
AMZN	0.003900	0.038000	-0.144700	0.118000	-0.357400	1.883600
MKT_EW	0.003600	0.030700	-0.099700	0.076500	-0.652000	1.072600

Obsérvese que AAPL y AMZN presentan mayor dispersión semanal que MSFT, y que las curtosis en exceso positivas sugieren colas más pesadas que la referencia gaussiana. Para un curso de finanzas cuantitativas, este punto es central: la normalidad es una hipótesis de trabajo, no una descripción automática de los retornos.

Ejemplo B. Estimación de beta de mercado

Para aproximar una aplicación tipo CAPM, se modela el rendimiento semanal de AAPL como función del rendimiento de un mercado tecnológico equiponderado. La nube con recta ajustada se presenta en la Figura 9. El coeficiente de pendiente captura la sensibilidad sistemática de AAPL respecto al mercado de referencia.

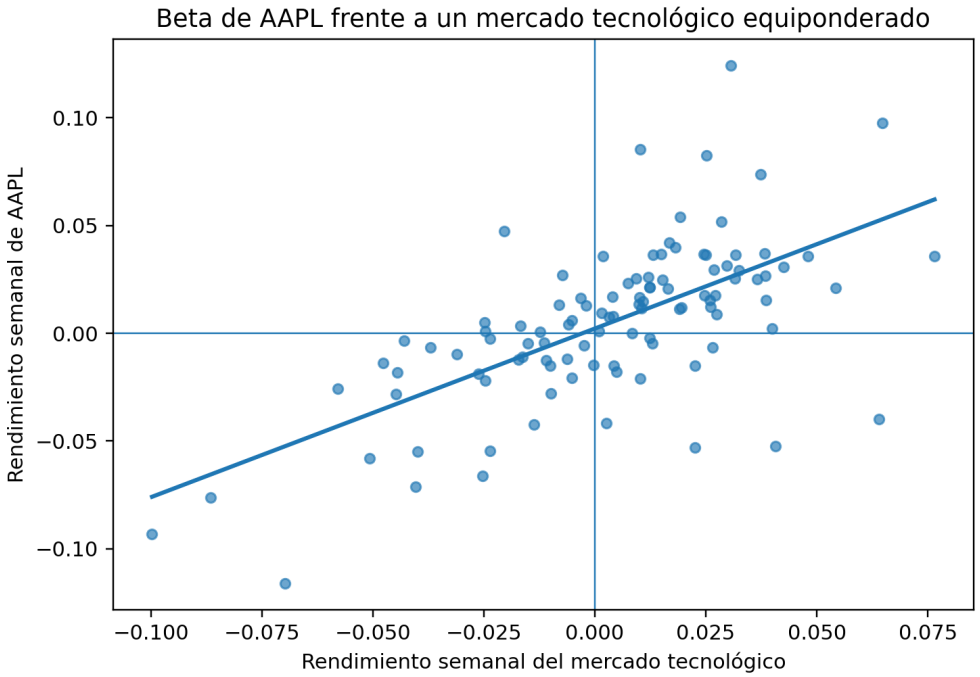


Figura 9: Rendimiento de AAPL frente a un mercado tecnológico equiponderado.

Cuadro 14: Salida resumida del modelo beta de AAPL

Parámetro	Estimación	Error estándar	t	p-valor	IC 95 % inf	IC 95 % sup
Intercepto (alpha)	0.002200	0.002800	0.770300	0.442900	-0.003400	0.007800
Beta mercado	0.783100	0.092300	8.485200	0.000000	0.600000	0.966100

La estimación entrega una beta cercana a 0.78, lo que sugiere que AAPL co-mueve con el mercado tecnológico, aunque con sensibilidad ligeramente inferior a uno en esta muestra. El intercepto es pequeño y estadísticamente impreciso, por lo que no conviene sobrerreaccionar ante la idea de “alfa” sin especificación más rica, muestra más larga o factores adicionales.

La Figura 10 y la lectura diagnóstica resumen qué pasa después de estimar: primero se revisa la forma de los residuos, y luego se contrastan heteroscedasticidad, autocorrelación y normalidad.

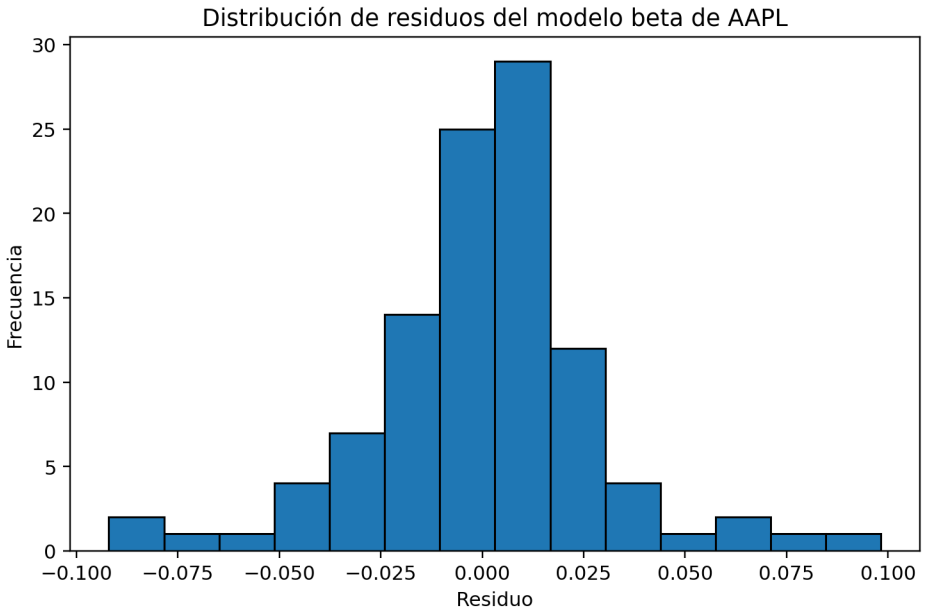


Figura 10: Histograma de residuos del modelo beta de AAPL.

- **Breusch–Pagan:** el p-valor es aproximadamente 0.098, de modo que al nivel del 5 % no hay evidencia fuerte para rechazar homoscedasticidad en esta especificación sencilla.
- **Breusch–Godfrey con 4 rezagos:** el p-valor es alto (alrededor de 0.823), por lo que no aparece evidencia fuerte de autocorrelación serial hasta orden 4.
- **Jarque–Bera:** el p-valor es esencialmente cero, de modo que los residuos no son compatibles con normalidad. Este hallazgo es muy razonable en retornos financieros, donde colas pesadas y episodios extremos son frecuentes.

Ejemplo C. Tasas nominales e inflación

Otro ejercicio útil para finanzas cuantitativas consiste en estudiar el vínculo entre tasas nominales e inflación. La Figura 11 muestra una relación positiva, aunque no muy apretada, entre inflación trimestral y tasa nominal en el conjunto `interest_inflation`. Esto ilustra por qué un signo económico plausible no garantiza alta precisión estadística.

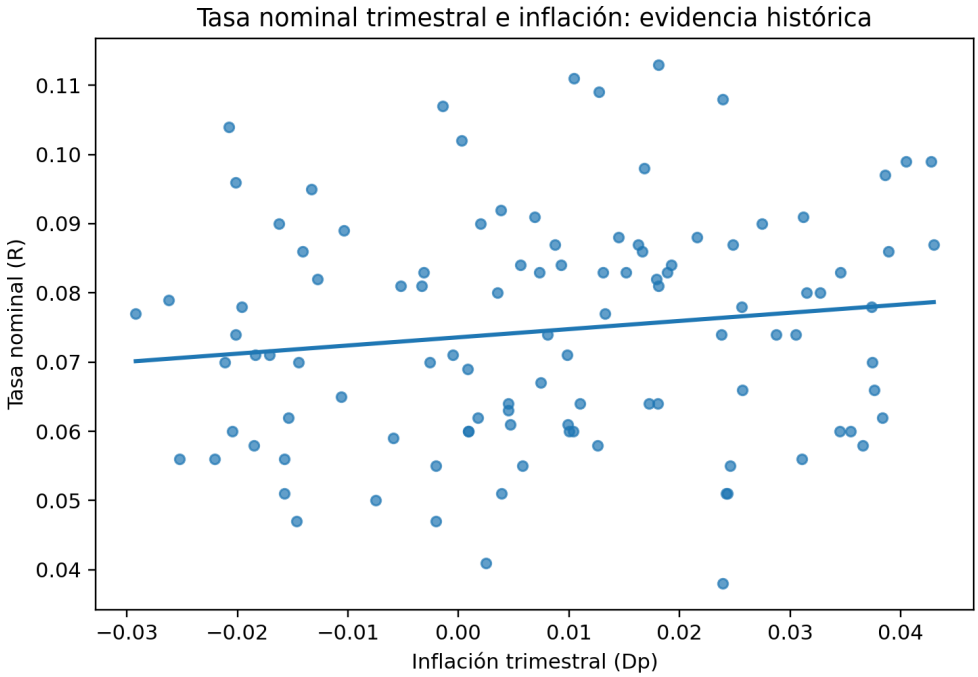


Figura 11: Relación entre inflación trimestral y tasa nominal.

Cuadro 15: Salida resumida del modelo tasa nominal sobre inflación

Parámetro	Estimación	Error estándar	t	p-valor
Intercepto	0.073600	0.001700	42.278500	0.000000
Coef. inflación trimestral	0.118200	0.084600	1.397700	0.165100

El coeficiente de inflación es positivo, pero su p-valor ronda 0.165 en esta muestra; por tanto, la evidencia no basta para rechazar $H_0 : \beta_{\text{inflación}} = 0$ al nivel de 5 %. La lectura correcta en un examen es: *el signo es consistente con la intuición económica, pero la precisión inferencial es limitada en esta especificación*. No debe escribirse simplemente “la inflación afecta la tasa” sin matices.

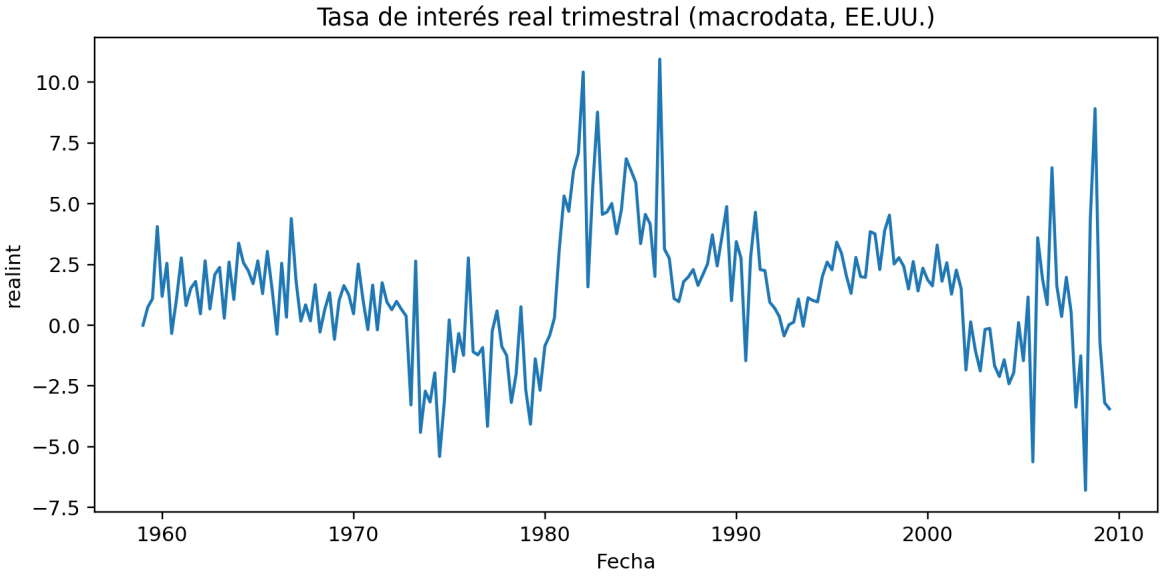


Figura 12: Tasa de interés real trimestral en `macrodata`.

La persistencia visible en la tasa real motiva naturalmente los temas 5.11 y 5.12: modelos dinámicos, rezagos y corrección por autocorrelación. Cuando una serie exhibe memoria, un modelo estático suele dejar estructura en los residuos.

Recetas en Python para el aula

Los gráficos anteriores se prepararon en Python. Si se quiere un flujo declarativo para el aula o para un notebook, Altair resulta especialmente didáctico. El archivo `altair_recetas.py` acompaña este material y el siguiente extracto resume el estilo de trabajo:

```
import numpy as np
import plotly.express as px
import altair as alt

stocks = px.data.stocks()
long = stocks.melt('date', var_name='activo', value_name='indice')

alt.Chart(long).mark_line().encode(
    x='date:T',
    y=alt.Y('indice:Q', title='Indice base=1'),
    color='activo:N',
    tooltip=['date:T','activo:N','indice:Q']
).properties(width=650, height=300)
```

En un curso aplicado, una buena práctica consiste en pedir al estudiantado que replique el análisis con un activo distinto, que estime su beta, que ejecute BP/BG/JB y que escriba una conclusión de cinco líneas donde distinga claramente: signo, magnitud, precisión y diagnóstico.

También se incluye un script adicional con curvas t, χ^2 y F preparadas como DataFrames y visualizadas con Altair. La idea pedagógica es que incluso una distribución teórica puede trabajarse con el mismo patrón: `DataFrame` → transformación → gráfico → interpretación.

10 5.1 Distribuciones y diagnóstico

Definición — Diagnóstico econométrico. Es el conjunto de análisis posteriores a la estimación destinados a detectar patrones incompatibles con los supuestos utilizados para interpretar coeficientes, errores estándar, pruebas o pronósticos. Diagnosticar no es "hacer que las pruebas no rechacen", sino comprender la estructura que quedó en los residuos.

Definición — Distribución de los residuos. Es la forma empírica de los $\hat{\varepsilon}_i$. Su asimetría, curtosis, colas y dependencia pueden advertir sobre outliers, mala forma funcional, heteroscedasticidad, autocorrelación o innovaciones no gaussianas.

El residuo es

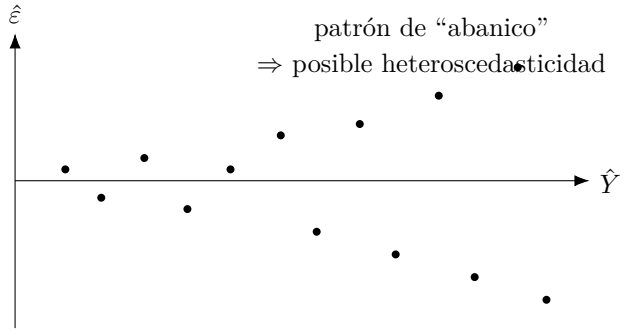
$$\hat{\varepsilon}_i = Y_i - \hat{Y}_i.$$

El diagnóstico no consiste en buscar que "todo salga perfecto", sino en detectar patrones que hagan inadecuadas las fórmulas inferenciales o la especificación.

10.1 Qué mirar

Herramienta	Qué busca	Patrón preocupante
Residuos vs ajustados	Forma funcional y varianza	Curvatura, abanico, clusters
Histograma / Q–Q	Forma marginal de residuos	Colas pesadas, asimetría, outliers
Residuos vs tiempo	Dependencia temporal	Rachas, ciclos, persistencia
ACF de residuos	Correlación serial	Autocorrelaciones fuera de bandas
Leverage/Cook	Observaciones influyentes	Puntos con gran impacto en coeficientes

10.2 Esquema conceptual



11 5.2 Supuestos para diagnóstico

Definición — Especificación correcta de la media. Una especificación de media es adecuada cuando la forma funcional y el conjunto de regresores capturan la estructura sistemática relevante para $\mathbb{E}(Y \mid X)$ bajo el objetivo del análisis.

Definición — Varianza esférica. La condición clásica $\mathrm{Var}(u \mid X) = \sigma^2 I$ combina homoscedasticidad y ausencia de correlación entre errores. Es más fuerte que la exogeneidad y se utiliza para la fórmula clásica de varianza de MCO.

Conviene separar tres niveles:

1. **Supuestos sobre la media condicional:** exogeneidad y forma funcional.
2. **Supuestos sobre la varianza/covarianza:** homoscedasticidad y ausencia de autocorrelación.
3. **Supuestos distributivos:** normalidad para inferencia exacta en ciertas muestras pequeñas.

Principio.. Corregir el error estándar no corrige una media condicional mal especificada. Por ejemplo, errores robustos no resuelven una variable omitida endógena.

12 5.3–5.6 Heteroscedasticidad y prueba de Breusch–Pagan

Definición — Heteroscedasticidad. Existe heteroscedasticidad cuando la varianza condicional del error cambia con las observaciones:

$$\mathrm{Var}(u_i \mid X_i) = \sigma_i^2.$$

Es un problema de la segunda parte de la distribución condicional, no necesariamente de la media.

Definición — Prueba de Breusch–Pagan (BP). Es una prueba LM de homoscedasticidad que estudia si los residuos al cuadrado pueden explicarse sistemáticamente mediante variables observadas. En su forma básica usa $LM = nR^2_{aux}$ y una referencia asintótica χ^2.

Hay heteroscedasticidad si

$$\mathrm{Var}(\varepsilon_i \mid X_i) = \sigma_i^2,$$

con σ_i^2 variable entre observaciones.

12.1 Consecuencias

Bajo exogeneidad, MCO sigue siendo insesgado y consistente, pero:

- deja de ser eficiente dentro de la clase de estimadores lineales insesgados;
- los errores estándar clásicos pueden ser incorrectos;
- las pruebas t y F clásicas pueden quedar mal calibradas.

12.2 Breusch–Pagan

Pasos:

1. Estimar el modelo original por MCO y obtener $\hat{\varepsilon}_i$.
2. Estimar una regresión auxiliar de $\hat{\varepsilon}_i^2$ sobre las regresoras relevantes.
3. Calcular $LM = nR^2_{aux}$.
4. Bajo H_0 de homoscedasticidad, $LM \overset{a}{\sim} \chi^2_q$, donde q es el número de pendientes en la auxiliar.

Hipótesis:

$$H_0 : \mathrm{Var}(\varepsilon_i \mid X) = \sigma^2, \qquad H_1 : \mathrm{Var}(\varepsilon_i \mid X) \text{ depende de } X.$$

12.3 Ejemplo

Si $n = 200$ y la regresión auxiliar arroja $R^2 = 0.08$,

$$LM = 200(0.08) = 16.$$

Con $q = 3$, el valor es grande frente a una χ^2_3 típica, aportando evidencia contra homoscedasticidad.

12.4 Correcciones

Método	Ventaja	Precaución
Errores robustos HC	Mantienen coeficientes MCO y corrigen la matriz de varianza	No cambian sesgos por endogeneidad ni forma funcional
WLS	Puede ganar eficiencia si se modela bien la varianza	Una función de pesos mal especificada puede empeorar resultados
Transformaciones	A veces estabilizan la varianza	Deben tener interpretación económica coherente

13 5.7–5.10 Autocorrelación: Durbin–Watson y Breusch–Godfrey

Definición — Autocorrelación serial. Existe cuando errores de distintos periodos están correlacionados, por ejemplo $\mathrm{Cov}(u_t, u_{t-1} \mid X) \neq 0$. Indica que los errores contienen memoria temporal que la especificación no absorbió completamente.

Definición — Durbin–Watson (DW). Estadístico diseñado principalmente para detectar autocorrelación de primer orden en los residuos de ciertas regresiones lineales. Toma valores entre 0 y 4; de manera heurística, valores cercanos a 2 son compatibles con poca correlación AR(1).

Definición — Breusch–Godfrey (BG). Prueba LM más general para autocorrelación de orden p. Regresa los residuos sobre las regresoras originales y p rezagos de los residuos; el contraste conjunto sobre esos rezagos determina la evidencia de correlación serial.

La autocorrelación aparece cuando

$$\mathrm{Cov}(\varepsilon_t, \varepsilon_{t-j} \mid X) \neq 0$$

para algún rezago j.

13.1 AR(1) en el error

$$\varepsilon_t = \rho \varepsilon_{t-1} + u_t, \qquad |\rho| < 1.$$

13.2 Durbin–Watson

$$DW = \frac{\sum_{t=2}^{T}(\hat{\varepsilon}_t - \hat{\varepsilon}_{t-1})^2}{\sum_{t=1}^{T}\hat{\varepsilon}_t^2}.$$

Como regla heurística,

$$DW \approx 2(1-\hat{\rho}).$$

Así, $DW \approx 2$ sugiere poca autocorrelación de primer orden; valores bajos apuntan a autocorrelación positiva y valores altos a negativa. La decisión formal usa regiones críticas y tiene limitaciones, especialmente con variables dependientes rezagadas.

13.3 Breusch–Godfrey

BG es más flexible. Para orden p:

1. Estimar el modelo original y obtener $\hat{\varepsilon}_t$.
2. Regresar $\hat{\varepsilon}_t$ sobre las regresoras originales y $\hat{\varepsilon}_{t-1}, \ldots, \hat{\varepsilon}_{t-p}$.
3. Calcular $LM = TR^2_{aux}$.
4. Bajo H_0 de no autocorrelación hasta orden p, $LM \overset{a}{\sim} \chi^2_p$.

13.4 DW vs BG

	Durbin–Watson	Breusch–Godfrey
Orden	Principalmente AR(1)	Orden p configurable
Variable dependiente rezagada	Problemático	Más apropiado
Implementación	Muy simple	Regresión auxiliar
Lectura	Estadístico con tablas/heurística	LM con χ^2 asintótica

13.5 Errores HAC / Newey–West

Cuando interesa mantener los coeficientes MCO pero ajustar inferencia ante heteroscedasticidad y autocorrelación débil, se pueden usar errores estándar HAC. No sustituyen una especificación dinámica cuando la propia media condicional está mal modelada.

14 5.11 Modelos dinámicos

Definición — Modelo dinámico. Es un modelo en el que el valor actual de Y depende de valores pasados de Y, de X o de ambos. Permite separar efectos contemporáneos, ajustes transitorios y respuestas de largo plazo.

Definición — Estabilidad. En el modelo ARDL(1,0) $Y_t = \alpha + \phi Y_{t-1} + \beta X_t + u_t$, la condición $|\phi| < 1$ hace que el efecto de un shock sobre Y disminuya geométricamente y permite definir un nivel de largo plazo estable bajo condiciones apropiadas.

Un modelo dinámico incorpora explícitamente el tiempo mediante rezagos de Y, de X o ambos.

14.1 Modelo con dependiente rezagada

$$Y_t = \alpha + \phi Y_{t-1} + \beta X_t + u_t.$$

ϕ mide persistencia. Si $|\phi| < 1$, el efecto contemporáneo de un cambio permanente en X puede acumularse.

14.2 Multiplicador de largo plazo

Si X_t aumenta permanentemente una unidad y el modelo es estable,

$$\text{efecto de largo plazo} = \frac{\beta}{1-\phi}.$$

Ejemplo: si $\phi = 0.75$ y $\beta = 0.50$,

$$\frac{0.50}{1-0.75} = 2.$$

El impacto de corto plazo es 0.50, pero el efecto acumulado de largo plazo es 2 unidades.

15 5.12 Rezagos

Definición — Rezago. X_{t-j} es el valor de X observado j periodos antes de t. Incluir rezagos permite representar retardos en la transmisión económica.

Definición — Rezago distribuido. Un modelo de rezagos distribuidos incluye varios valores pasados de una regresora: $Y_t = \alpha + \sum_{j=0}^{q} \beta_j X_{t-j} + u_t$. Cada β_j describe una respuesta en un horizonte específico.

15.1 Rezagos distribuidos

$$Y_t = \alpha + \beta_0 X_t + \beta_1 X_{t-1} + \beta_2 X_{t-2} + u_t.$$

Interpretación:

- β_0: impacto contemporáneo.
- β_1: efecto después de un periodo.
- β_2: efecto después de dos periodos.
- $\beta_0 + \beta_1 + \beta_2$: efecto acumulado dentro del horizonte incluido.

15.2 Selección del número de rezagos

Puede guiarse por:

- teoría y frecuencia de los datos;

- AIC/BIC;
- diagnóstico de residuos;
- estabilidad y parsimonia;
- desempeño fuera de muestra.

Agregar demasiados rezagos consume grados de libertad y puede elevar colinealidad entre regresoras cercanas en el tiempo.

16 5.13 Prueba de Jarque–Bera

Definición — Normalidad. Una variable normal tiene asimetría teórica cero y curtosis no excesiva igual a 3 bajo la convención de curtosis total. En regresión, la normalidad de errores no es necesaria para que MCO exista ni, bajo exogeneidad, para insesgadez.

Definición — Prueba de Jarque–Bera (JB). Es una prueba omnibus de normalidad basada en la asimetría y la curtosis muestrales de los residuos. Bajo H_0 y condiciones regulares, JB tiene referencia asintótica χ^2_2.

Jarque–Bera contrasta si la asimetría y la curtosis muestrales son compatibles con una distribución normal.

$$JB = \frac{n}{6}\left(S^2 + \frac{(K-3)^2}{4}\right),$$

donde S es asimetría y K curtosis.

Bajo normalidad y condiciones asintóticas,

$$JB \overset{a}{\sim} \chi^2_2.$$

16.1 Ejemplo

Si $n = 120$, $S = 0.8$ y $K = 4.2$:

$$JB = \frac{120}{6}\left(0.8^2 + \frac{(4.2-3)^2}{4}\right) = 20(0.64 + 0.36) = 20.$$

Es un valor grande frente a una χ^2_2, por lo que los residuos muestran una desviación relevante respecto a normalidad.

Importante.. Rechazar normalidad no implica que MCO deje de ser consistente. La consecuencia depende del objetivo, del tamaño muestral y de las condiciones asintóticas. En finanzas, colas pesadas son frecuentes; por eso interesa complementar con errores robustos, bootstrap u otros modelos de distribución cuando corresponda.

17 Convenciones de interpretación, reporte y decisión

En lugar de memorizar tablas comparativas extensas, conviene interiorizar una secuencia estable de interpretación. Para resolver ejercicios o redactar un comentario empírico, recomiendo el siguiente protocolo.

Protocolo de lectura de una regresión

1. **Especificación.** Escribir con claridad cuál es Y, cuáles son las X, la frecuencia temporal y la unidad de medida.
2. **Forma funcional.** Indicar si el modelo es nivel–nivel, log–nivel, nivel–log o log–log; sin esto, la interpretación del coeficiente queda incompleta.
3. **Signo y magnitud.** Interpretar primero el signo esperado y después la magnitud económica de cada pendiente relevante.
4. **Precisión.** Mirar error estándar, estadístico t, intervalo de confianza y p-valor.
5. **Significancia conjunta.** Verificar si un bloque de variables es relevante mediante prueba F cuando corresponda.
6. **Diagnóstico.** Revisar residuos, heteroscedasticidad, autocorrelación, normalidad y posible mala forma funcional.
7. **Corrección.** Si falla un supuesto, explicar qué cambiaría: errores robustos, HAC, nuevos rezagos, transformación funcional, variables omitidas o reformulación del problema.
8. **Conclusión.** Redactar una frase final que distinga entre evidencia estadística y lectura económica.

Errores que penalizan mucho en un examen de Finanzas Cuantitativas

- Decir que un p-valor es la probabilidad de que la hipótesis nula sea verdadera.
- Interpretar R^2 como prueba de causalidad o como sinónimo de pronóstico fuera de muestra.
- Olvidar la categoría base de una dummy.
- Interpretar una interacción sin sumar coeficientes.
- Concluir “no hay efecto” únicamente porque $p > 0.05$.
- Confundir no rechazo de H_0 con prueba a favor de H_0.
- Escribir que Jarque–Bera “prueba heteroscedasticidad” o que Breusch–Pagan “prueba normalidad”.
- Corregir todo con errores robustos cuando el problema real es dinámica omitida o endogeneidad.
- Omitir la unidad: porcentaje, puntos base, pesos, logaritmos o unidades físicas.

Convención de cierre para reportes cortos

Una conclusión empírica breve y bien escrita debería parecerse a lo siguiente: *“El coeficiente de X_j es positivo y económicamente relevante; su magnitud sugiere un aumento aproximado de $\cdots$ en Y por cada unidad adicional de X_j, ceteris paribus. La evidencia individual es (fuerte/moderada/débil) según su p-valor e intervalo de confianza. El diagnóstico sugiere (normalidad/no normalidad, presencia/ausencia*

de heteroscedasticidad, presencia/ausencia de autocorrelación), por lo que la inferencia final se reporta con el esquema adecuado."

18 Ejemplo integrado con lectura profesional

Una analista modela el spread corporativo mensual (pb) como

$$\text{Spread}_t = \beta_0 + \beta_1 \text{Leverage}_t + \beta_2 \text{VIX}_t + \beta_3 D_t + \beta_4 (\text{VIX}_t D_t) + u_t,$$

donde $D_t = 1$ en episodios de tensión financiera.

Resultados:

$$\widehat{\text{Spread}} = 42 + 18.0\,\text{Leverage} + 2.4\,\text{VIX} + 25D + 1.1(\text{VIX} \times D).$$

18.1 Interpretación

- Fuera de tensión ($D = 0$), un punto adicional de VIX se asocia con 2.4 pb más de spread.
- En tensión ($D = 1$), la pendiente respecto a VIX es $2.4 + 1.1 = 3.5$ pb.
- El término $25D$ altera el intercepto del régimen de tensión; su lectura aislada corresponde al punto VIX=0 y por ello puede no tener interpretación económica directa. Para una comparación en un nivel razonable de VIX conviene centrar la variable.

Diagnóstico:

- BP: $p = 0.004 \Rightarrow$ evidencia contra homoscedasticidad.
- BG(2): $p = 0.018 \Rightarrow$ evidencia de autocorrelación residual hasta orden 2.
- JB: $p < 0.001 \Rightarrow$ residuos alejados de normalidad.

Una respuesta responsable no es “el modelo no sirve”. La conclusión es que los errores estándar clásicos no deben aceptarse sin ajuste y que la dinámica probablemente necesita reespecificación. Una ruta razonable sería introducir estructura temporal defendible y usar una matriz de covarianza robusta apropiada.

19 Ejemplos resueltos de examen

Ejemplo 1: prueba F con restricciones

Se estima un modelo de retornos con $n = 150$ y $k = 5$ regresores. El modelo no restringido tiene $SSR_{UR} = 420$ y el restringido, que impone tres betas iguales a cero, tiene $SSR_R = 486$. Entonces

$$F = \frac{(486 - 420)/3}{420/(150 - 5 - 1)} = \frac{22}{2.9167} \approx 7.54.$$

La prueba no pregunta si cada beta es individualmente significativa, sino si las tres restricciones son conjuntamente compatibles con los datos. Un valor grande conduce a evidencia contra H_0 al compararlo con el crítico o su p-valor.

Ejemplo 2: dummy e interacción

$$\widehat{Spread} = 180 + 12\,Duration - 45D - 6(Duration \times D),$$

donde $D = 1$ para grado de inversión.

- Grupo base ($D = 0$): intercepto 180, pendiente 12.
- Grado de inversión ($D = 1$): intercepto $180 - 45 = 135$, pendiente $12 - 6 = 6$.
- A duración 5, la diferencia condicional es $-45 - 6(5) = -75$ puntos base.

Este último cálculo muestra por qué, con interacción, el coeficiente de la dummy por sí solo representa la diferencia únicamente cuando $X = 0$.

Ejemplo 3: BP y decisión inferencial

Una regresión auxiliar de $\hat{u}_i^2$ sobre tres variables produce $R^2_{aux} = 0.06$ con $n = 300$:

$$LM = 300(0.06) = 18.$$

La referencia es χ^2_3. Si el p-valor es pequeño, se rechaza homoscedasticidad. Si la ecuación de media sigue siendo plausible y las regresoras son exógenas, una respuesta inmediata es conservar $\hat{\beta}_{MCO}$ y usar errores robustos; no existe justificación para eliminar automáticamente observaciones o variables.

Ejemplo 4: dinámica y largo plazo

$$Y_t = 1.5 + 0.75Y_{t-1} + 0.40X_t + u_t.$$

El efecto contemporáneo de aumentar permanentemente X en una unidad es 0.40. Al siguiente periodo persiste $0.75(0.40)$, luego $0.75^2(0.40)$, etc. Como $|0.75| < 1$,

$$0.40\left(1 + 0.75 + 0.75^2 + \cdots\right) = \frac{0.40}{1 - 0.75} = 1.60.$$

Éste es el multiplicador de largo plazo.

Ejemplo 5: cuantiles

Suponga que el coeficiente de apalancamiento sobre spread es 0.5 en $\tau = .25$, 1.0 en $\tau = .50$ y 2.4 en $\tau = .90$. No significa que el apalancamiento "cause con 90 % de probabilidad" el spread. Significa que su asociación condicional estimada es mucho más intensa en la parte alta de la distribución del spread.

20 Preguntas tipo CFA

Las preguntas privilegian interpretación, selección de herramienta y lectura de resultados.

P1. Un analista estima $\ln(P) = 8.5 + 0.04\,\text{parking} + 0.30\ln(\text{m}^2)$. Manteniendo constante la superficie, una plaza adicional de estacionamiento se asocia aproximadamente con:

A. 0.04 unidades monetarias más.

B. 4 % más en el precio.

C. 30 % más en el precio.

P2. Si se agrega una regresora irrelevante a un modelo con constante, ¿qué ocurre necesariamente?

A. R^2 no disminuye.

B. $\bar{R}^2$ no disminuye.

C. El error estándar de todos los coeficientes disminuye.

P3. Se desea probar $H_0 : \beta_2 = \beta_3 = \beta_4 = 0$. La herramienta más directa es:

A. prueba t sobre β_2.

B. prueba F conjunta.

C. prueba Jarque–Bera.

P4. En $Y = \beta_0 + \beta_1 X + \delta D + \gamma X D + u$, la pendiente de X cuando $D = 1$ es:

A. β_1.

B. γ.

C. $\beta_1 + \gamma$.

P5. Un rechazo de Breusch–Pagan sugiere principalmente que:

A. $\mathbb{E}(u \mid X) \neq 0$.

B. la varianza condicional no es constante.

C. los residuos no son normales.

P6. Bajo exogeneidad, la heteroscedasticidad por sí sola hace que MCO:

A. sea necesariamente sesgado.

B. pueda conservar insesgadez pero pierda eficiencia clásica.

C. sea idéntico a WLS.

P7. Un valor DW cercano a 2 suele ser compatible con:

A. poca autocorrelación de primer orden.

B. fuerte autocorrelación positiva.

C. heteroscedasticidad severa.

P8. Frente a Durbin–Watson, Breusch–Godfrey es especialmente útil porque:

A. sólo detecta heteroscedasticidad.

B. permite probar autocorrelación de orden superior y manejar mejor modelos dinámicos.

C. exige normalidad exacta.

P9. En $Y_t = \alpha + 0.8Y_{t-1} + 0.6X_t + u_t$, el multiplicador de largo plazo de un cambio permanente en X es:

A. 0.6.

B. 0.75.

C. 3.0.

P10. Si una regresión cuantílica para $\tau = 0.90$ arroja $\hat{\beta} = 2.5$, el coeficiente describe:

A. el efecto sobre la media incondicional.

B. una asociación con el percentil 90 condicional.

C. una probabilidad del 90 % de causalidad.

P11. Un modelo con $R^2 = 0.95$:

A. es necesariamente causalmente válido.

B. puede aún presentar endogeneidad o regresión espuria.

C. garantiza residuos normales.

P12. En un modelo hedónico, el coeficiente de distancia al centro puede interpretarse como precio marginal de localización sólo si:

A. se ignoran todos los demás atributos.

B. la especificación y supuestos permiten una interpretación condicional válida.

C. R^2 es mayor a 0.8.

P13. Dos modelos no anidados:

A. siempre pueden compararse con una prueba F clásica de restricciones.

B. requieren criterios o pruebas apropiadas a comparación no anidada.

C. tienen necesariamente la misma variable dependiente y regresoras.

P14. Jarque–Bera se construye a partir de:

A. media y varianza únicamente.

B. asimetría y curtosis.

C. autocorrelaciones parciales.

P15. Si BP rechaza homoscedasticidad pero no hay evidencia de endogeneidad, una respuesta inmediata razonable para inferencia puede ser:

A. usar errores estándar robustos.

B. eliminar automáticamente la variable con mayor p-valor.

C. imponer $\beta_j = 0$ a todas las variables no significativas.

P16. Un coeficiente no significativo estadísticamente:

A. prueba que el efecto verdadero es exactamente cero.

B. indica que los datos no permiten rechazar la restricción al nivel elegido.

C. debe eliminarse siempre del modelo.

P17. En un modelo con dummies para cuatro sectores y constante, el número estándar de dummies sectoriales es:

A. 4.

B. 3.

C. 2.

P18. Si $\hat{\rho} \approx 0.6$ para errores AR(1), la aproximación $DW \approx 2(1 - \hat{\rho})$ da:

A. 0.8.

B. 1.2.

C. 3.2.

P19. En $\ln Y = \beta_0 + 1.4 \ln X + u$, 1.4 representa:

A. una semielasticidad.

B. una elasticidad.

C. un cambio absoluto de 1.4 unidades.

P20. Si el efecto de una regresora es pequeño pero su error estándar aún más pequeño, puede ser:

A. estadísticamente significativo pero económicamente pequeño.

B. económicamente enorme por definición.

C. no identificable necesariamente.

P21. En una regresión auxiliar BG(3), el estadístico LM se compara asintóticamente con:

A. χ^2_3.

B. t_3.

C. $F_{1,3}$ únicamente.

P22. Si $\phi = 1$ en $Y_t = \alpha + \phi Y_{t-1} + \beta X_t + u_t$, la fórmula $\beta/(1 - \phi)$:

A. produce un multiplicador finito estándar.

B. no es válida como multiplicador estable de largo plazo.

C. siempre vale cero.

P23. Una ventaja de regresión cuantílica es:

A. imponer que todos los cuantiles tengan el mismo efecto.

B. estudiar heterogeneidad de efectos a lo largo de la distribución condicional.

C. garantizar causalidad.

P24. En selección de rezagos, BIC tiende a penalizar complejidad más fuertemente que AIC en muestras suficientemente grandes. Por tanto, manteniendo todo lo demás comparable, BIC suele favorecer:

A. especificaciones más parsimoniosas.

B. siempre más rezagos.

C. modelos con mayor R^2 sin importar el número de parámetros.

P25. Un rechazo de JB en una muestra financiera grande debe interpretarse como:

A. evidencia de que asimetría/curtosis difieren de normalidad, no como prueba automática de sesgo de MCO.

B. prueba directa de endogeneidad.

C. evidencia suficiente para eliminar todas las observaciones extremas.

21 Respuestas y razonamiento breve

Pregunta	Resp.	Idea clave
1	B	En un modelo log-nivel, 0.04 equivale aproximadamente a 4 %.
2	A	R^2 no puede bajar al agregar regresoras; $\bar{R}^2$ sí puede.
3	B	Son tres restricciones conjuntas.
4	C	La interacción suma γ a la pendiente del grupo $D = 1$.
5	B	BP contrasta constancia de la varianza condicional.
6	B	Con exogeneidad, MCO puede seguir insesgado/consistente; falla eficiencia clásica e inferencia usual.
7	A	Heurísticamente $DW \approx 2$ corresponde a $\rho \approx 0$.
8	B	BG admite orden superior y es más flexible en modelos dinámicos.
9	C	$0.6/(1 - 0.8) = 3$.
10	B	El objetivo es el cuantil condicional, no la media.
11	B	Alto ajuste no valida causalidad ni estacionariedad.
12	B	La interpretación marginal depende de especificación y supuestos.
13	B	La prueba F estándar compara restricciones anidadas.
14	B	JB usa asimetría y curtosis.
15	A	Los errores robustos corrigen inferencia frente a heteroscedasticidad bajo condiciones apropiadas.
16	B	No rechazar no equivale a probar igualdad exacta a cero.
17	B	Con constante se omite una categoría: $4 - 1 = 3$.
18	A	$2(1 - 0.6) = 0.8$.
19	B	Log-log: el coeficiente es elasticidad.
20	A	Precisión y magnitud económica son conceptos distintos.
21	A	BG(3) usa referencia asintótica χ^2_3.
22	B	Con $\phi = 1$ no hay estabilidad geométrica estándar; el denominador es cero.
23	B	Los coeficientes pueden variar con τ.
24	A	BIC impone una penalización que favorece parsimonia relativa.
25	A	JB diagnostica forma distributiva; no es una prueba de endogeneidad.

22 Formulario compacto

$$
\begin{aligned}
\hat{\beta} &= (X'X)^{-1}X'y, \\
R^2 &= 1 - \frac{SSR}{TSS}, \\
\bar{R}^2 &= 1 - \frac{SSR/(n-k-1)}{TSS/(n-1)}, \\
t &= \frac{\hat{\beta}_j - \beta_{j,0}}{se(\hat{\beta}_j)}, \\
F &= \frac{(SSR_R - SSR_{UR})/q}{SSR_{UR}/(n-k-1)}, \\
LM_{BP} &= nR^2_{aux}, \\
DW &= \frac{\sum_{t=2}^{T}(\hat{u}_t - \hat{u}_{t-1})^2}{\sum_{t=1}^{T}\hat{u}_t^2}, \\
LM_{BG} &= TR^2_{aux}, \\
JB &= \frac{n}{6}\left(S^2 + \frac{(K-3)^2}{4}\right), \\
\text{multiplicador LR} &= \frac{\beta}{1-\phi}.
\end{aligned}
$$

23 Glosario ultrarrápido

Término	**Definición de una línea**
RLM	Modelo lineal en parámetros para la media condicional de Y dada X.
MCO	Método que minimiza la suma de cuadrados de los residuos.
Exogeneidad	El error tiene media condicional cero dado el conjunto de regresores.
Homoscedasticidad	Varianza condicional del error constante.
Heteroscedasticidad	Varianza condicional del error no constante.
Autocorrelación	Dependencia entre errores de distintos periodos.
Dummy	Indicador 0–1 para representar categorías.
Interacción	Producto de variables que permite efectos dependientes del nivel o grupo.
R^2	Fracción de variación muestral de Y explicada por el ajuste, con constante.
$\bar{R}^2$	Medida de ajuste penalizada por número de regresores.
Modelo anidado	Caso particular de otro modelo obtenido mediante restricciones.
Cuantil	Punto de una distribución asociado con una probabilidad acumulada τ.
BP	Prueba LM de homoscedasticidad.

DW	Estadístico orientado a autocorrelación de primer orden bajo condiciones específicas.
BG	Prueba LM general de autocorrelación hasta orden p.
JB	Prueba de normalidad basada en asimetría y curtosis.
Modelo dinámico	Modelo con valores pasados de variables.
Rezago	Valor observado de una variable en periodos anteriores.
Multiplicador LR	Efecto acumulado de largo plazo de un cambio permanente bajo estabilidad.

Lista de comprobación antes del examen

1. ¿Puedo interpretar correctamente nivel–nivel, log–nivel, nivel–log y log–log?
2. ¿Sé cuándo usar t y cuándo F?
3. ¿Puedo explicar una dummy y una interacción sin confundir intercepto y pendiente?
4. ¿Sé por qué R^2 no basta para elegir un modelo?
5. ¿Puedo distinguir modelos anidados y no anidados?
6. ¿Entiendo qué cambia al pasar de media condicional a cuantil condicional?
7. ¿Sé qué diagnostican BP, DW, BG y JB y qué *no* diagnostican?
8. ¿Puedo calcular un multiplicador de largo plazo y verificar estabilidad $|\phi| < 1$?
9. ¿Puedo explicar por qué errores robustos corrigen inferencia pero no endogeneidad?
10. ¿Puedo separar significancia estadística de relevancia económica?

Nota final: en econometría aplicada, una prueba aislada rara vez “decide” por sí sola. La lectura correcta combina teoría, magnitud económica, incertidumbre, diagnóstico, estabilidad y el propósito del modelo.