Proyecto de Econometría

De la regresión lineal a la multicolinealidad

Guía de trabajo e instrumentos de evaluación

UP!

Propósito del proyecto

Usar datos para plantear una pregunta económica, estimar e interpretar un modelo de regresión lineal y evaluar si la multicolinealidad dificulta responderla.

- Pasar de una pregunta clara a un análisis reproducible.
- Distinguir asociación estadística de causalidad.
- Comunicar resultados, limitaciones y decisiones con honestidad.

Producto final: informe breve, base documentada, código reproducible y presentación oral.

Equipos

1. Serur, Jacobo, Abraham
2. Patricio, Adan, Eduardo
3. Jassan, Muller, Gamboa
4. Sara, Camila, Ximena
5. Santiado, Mauricio, Annuar
6. Euken, Alvaro Vazquez, Diego
7. Fer, Rodrigo

Acuerdos de equipo. Repartan tareas, registren contribuciones y aseguren que cada integrante pueda explicar el modelo y sus resultados.

Pregunta, datos y alcance

1. Formulen una pregunta económica concreta y medible.
2. Definan una variable dependiente Y y al menos dos explicativas.
3. Usen datos públicos o de elaboración propia, con fuente verificable.
4. Procuren al menos 30 observaciones; expliquen cualquier limitación de tamaño o selección de la muestra.
5. Delimiten unidad de análisis, periodo, población y variables.

Ejemplos: ¿Cómo se asocian horas de estudio y asistencia con la calificación? ¿Cómo se relacionan tamaño y ubicación con el precio de una vivienda?

Fuentes de datos abiertas

- INEGI: Banco de Información — indicadores sociodemográficos y económicos por zona y serie histórica.
- API de indicadores de INEGI — consulta programática de series mexicanas; requiere token de acceso.
- Banco Mundial: Data — desarrollo, población, educación y economía por país; también ofrece una API con ejemplo de PIB de México.
- CEPALSTAT — estadísticas comparables de América Latina y el Caribe.
- OECD Data Explorer — estadísticas comparadas de países miembros y asociados.
- FRED — series macroeconómicas y financieras; muchas de Estados Unidos.
- Our World in Data: Data Explorers — conjuntos descargables sobre salud, educación, población y ambiente.

Antes de elegir, verifiquen unidad de análisis, periodo, frecuencia, definición de variables, licencia y método de descarga. Registren la fuente y fecha de consulta; los nombres subrayados son hipervínculos.

Ruta de trabajo

1. **Pregunta y datos:** justificación, fuente y diccionario.
2. **Exploración:** limpieza, descriptivos, gráficas y correlaciones.
3. **Regresión:** modelo inicial, estimación MCO e interpretación.
4. **Diagnóstico:** supuestos, residuos y multicolinealidad.
5. **Comunicación:** conclusiones, limitaciones y reproducibilidad.

Regla de interpretación. Una regresión observacional identifica asociaciones condicionadas a las variables incluidas; por sí sola no demuestra causalidad.

Modelo de regresión lineal

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki} + u_i$$

- Y_i: resultado de interés para la observación i.
- X_{ji}: característica explicativa j.
- β_j: cambio esperado en Y asociado con una unidad de X_j, manteniendo constantes las demás variables.
- u_i: factores no observados incluidos en el error.

Antes de estimar: justifiquen el signo esperado, las unidades y por qué cada variable pertenece al modelo.

Mínimos cuadrados ordinarios (MCO)

MCO elige los coeficientes que minimizan la suma de residuos al cuadrado:

$$\min_{\beta_0,\ldots,\beta_k} \sum_{i=1}^{n} \left(Y_i - \widehat{Y}_i\right)^2, \qquad \widehat{u}_i = Y_i - \widehat{Y}_i.$$

- El intercepto es el valor ajustado de Y cuando todos los X valen cero; puede no tener interpretación útil.
- Cada pendiente es una asociación parcial, condicionada a los demás regresores del modelo.
- Reporten coeficientes, unidades, tamaño de muestra e incertidumbre.

Cómo interpretar coeficientes

- **Niveles:** si Y y X están en niveles, β_1 expresa unidades de Y asociadas con una unidad adicional de X.
- **Logaritmo de Y:** en $\log(Y) = \beta_0 + \beta_1 X + u$, una unidad adicional de X se asocia aproximadamente con un cambio de $100\beta_1$ % en Y, para valores pequeños de β_1.

Siempre especifiquen las unidades, el signo, la magnitud y la interpretación "manteniendo constantes las demás variables". No confundan significancia con relevancia económica.

Variables categóricas

- Representen una categoría binaria con una variable indicadora: $D_i = 1$ si pertenece al grupo y 0 si no.
- En $Y_i = \beta_0 + \beta_1 X_i + \delta D_i + u_i$, δ es la diferencia condicional respecto al grupo de referencia.
- Con m categorías, incluyan $m - 1$ indicadores y nombren la categoría omitida.

Eviten la trampa de las variables ficticias: incluir el intercepto y los m indicadores genera dependencia lineal perfecta; omitan una categoría de referencia.

Ajuste e inferencia

- R^2: fracción de variación muestral de Y explicada por el modelo; no prueba causalidad ni calidad por sí solo.
- Error estándar: precisión estimada de un coeficiente.
- Intervalo de confianza: rango de valores compatibles con los datos y el método bajo los supuestos adoptados.
- Valor p: evidencia frente a una hipótesis nula, no probabilidad de que la hipótesis sea verdadera.

En el informe: presenten estimación, error estándar o intervalo, unidades y tamaño de muestra. Elijan un nivel de significancia antes de discutir pruebas.

Supuestos y diagnóstico

- **Linealidad en parámetros:** el modelo está especificado como lineal en los coeficientes.
- **Variación y rango:** hay variación en los regresores y no hay colinealidad perfecta.
- **Exogeneidad:** para interpretar MCO como insesgado, $E[u \mid X] = 0$; es una condición sustantiva, no garantizada por el software.
- **Varianza constante e independencia:** relevantes para los errores estándar convencionales y la eficiencia.
- **Normalidad del error:** útil para inferencia exacta en muestras pequeñas bajo el modelo clásico.

Práctica: inspeccionen residuos y justifiquen errores estándar robustos si la heterocedasticidad es plausible. Un diagnóstico no sustituye el argumento económico.

Multicolinealidad: qué es

Existe cuando dos o más regresores contienen información lineal redundante.

- **Perfecta:** un regresor es combinación exacta de otros. MCO no puede identificar todos los coeficientes.
- **Alta, no perfecta:** los coeficientes pueden estimarse, pero con varianzas grandes e intervalos amplios.
- No implica automáticamente sesgo de MCO si se mantiene la exogeneidad.
- Puede volver inestables magnitudes, signos y pruebas individuales; predicción dentro de la muestra todavía puede ser razonable.

Detectar multicolinealidad

1. Revisen correlaciones entre pares de regresores; solo detectan relaciones bivariadas.
2. Revisen matriz de diseño, categorías duplicadas y variables construidas unas a partir de otras.
3. Calculen el factor de inflación de varianza:

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2},$$

   donde R_j^2 proviene de regresar X_j sobre los otros X.
4. Comparen errores estándar y coeficientes entre especificaciones razonables; interpreten cambios con cautela.

Umbrales: VIF de 5 o 10 se usa a veces como señal de alerta, no como regla universal. Informen el criterio y el contexto.

Qué hacer (y qué no hacer)

- Conserven variables necesarias por teoría o diseño; no eliminen controles automáticamente para bajar un VIF.
- Revisen errores de datos, unidades y codificación de categorías.
- Si hay redundancia sustantiva, justifiquen una medida o especificación alternativa y muestren cómo cambia la pregunta.
- Consideren combinar indicadores estrechamente relacionados solo con justificación; centrar variables puede ayudar con productos e interceptos, pero no resuelve toda colinealidad.
- Reporten limitaciones; no presenten una prueba como solución automática.

Entregables

1. **Informe** de 5–8 páginas: pregunta, teoría breve, datos, especificación, resultados, diagnósticos, conclusiones y limitaciones.
2. **Anexo reproducible**: código y pasos para cargar/limpiar datos, estimar modelos y reproducir tablas o figuras.
3. **Datos documentados**: archivo utilizado, fuente, fecha de consulta, diccionario y transformaciones.
4. **Presentación**: 8 minutos por equipo y 4 minutos de preguntas.

Privacidad: no recopilen ni publiquen datos identificables o sensibles sin autorización. Citen fuentes y respeten sus condiciones de uso.

Calendario sugerido por etapas

Etapa	Evidencia de avance
1. Pregunta	Pregunta, hipótesis, unidad de análisis y variables propuestas.
2. Datos	Fuente, muestra, diccionario, limpieza y descriptivos iniciales.
3. Modelo	Especificación, MCO e interpretación económica de coeficientes.
4. Diagnóstico	Residuos, revisión de supuestos y análisis de VIF/colinealidad.
5. Cierre	Informe, código reproducible, presentación y coevaluación.

El docente asignará fechas según el calendario del curso.

Instrumento 1: rúbrica del informe (70 puntos)

Criterio	Desempeño esperado para el puntaje máximo	Puntos
Pregunta y motivación	Pregunta concreta; hipótesis y relevancia económica claras.	10
Datos y documentación	Fuente verificable, muestra descrita, variables y limpieza documentadas.	10
Especificación	Modelo justificado; variables, unidades y grupo de referencia claros.	10
Estimación e interpretación	Resultados correctos; magnitud, incertidumbre y significado económico bien explicados.	15
Diagnóstico y multicolinealidad	Supuestos discutidos; VIF/correlaciones interpretados sin reglas mecánicas.	15
Conclusiones y límites	Responde la pregunta sin afirmar causalidad injustificada; limita el alcance.	5
Claridad y reproducibilidad	Redacción, tablas, citas y anexos permiten revisar el análisis.	5
	Total	**70**

Instrumento 2: exposición (20 puntos)

Criterio	Puntos
Pregunta, motivación y datos presentados con claridad	4
Modelo y coeficientes interpretados correctamente	5
Diagnósticos, multicolinealidad y límites explicados	5
Estructura, legibilidad de apoyos y manejo del tiempo	3
Respuestas razonadas a preguntas	3
Total	**20**

Escala común. Asigne el puntaje completo si cumple el descriptor, cerca de la mitad si lo cumple parcialmente y cero si no hay evidencia; registre una observación concreta para cada criterio con descuento.

Instrumento 3: proceso y coevaluación (10 puntos)

Proceso (5 puntos)

- Avance de pregunta y datos (2).
- Entrega de modelo y diagnósticos preliminares (2).
- Organización y cumplimiento de acuerdos (1).

Coevaluación (5 puntos) Cada integrante califica confidencialmente de 1 a 5:

- Cumplió tareas acordadas.
- Contribuyó al análisis y revisión.
- Se comunicó y apoyó al equipo.

Promedien las respuestas recibidas y conviertan a escala de 0–5:
puntos $= 5 \times$ (promedio/5).

La coevaluación informa el puntaje individual; el docente revisa discrepancias y evidencia antes de ajustar.

Lista de verificación antes de entregar

- ☐ La pregunta y la unidad de análisis son explícitas.
- ☐ Las fuentes, variables, unidades y limpieza están documentadas.
- ☐ La ecuación corresponde a los resultados presentados.
- ☐ Los coeficientes se interpretan en unidades comprensibles.
- ☐ Se discuten incertidumbre, supuestos y límites de inferencia.
- ☐ Se evalúan y contextualizan correlaciones y VIF.
- ☐ Código, datos permitidos y tablas permiten reproducir el análisis.
- ☐ Todas las personas pueden explicar el trabajo y sus decisiones.

Criterio de éxito

Un buen proyecto no es el que acumula más variables ni el que obtiene el mayor R^2. Es el que responde una pregunta acotada con datos transparentes, interpreta con precisión, evalúa sus límites y puede ser reproducido.

¿Qué decisión de modelado podría cambiar su conclusión?