Regresión lineal: inferencia y diagnóstico

Teoría, datos reales y verificación computacional

César Galindo

Introducción

Las pruebas t y F no deben estudiarse como fórmulas aisladas. Ambas nacen de una misma pregunta: cuánto de lo observado puede atribuirse a variación sistemática y cuánto permanece en los residuos. En regresión lineal, esa pregunta aparece primero en la descomposición

$$\mathrm{SST} = \mathrm{SSE} + \mathrm{SSR},$$

se organiza después en la tabla ANOVA y, finalmente, conduce a contrastes individuales o conjuntos sobre los parámetros del modelo.

Estas notas desarrollan el cálculo y la interpretación de las pruebas t y F, pero incorporan también el diagnóstico que debe preceder a una lectura mecánica de los coeficientes. Se estudian la matriz de correlaciones de las regresoras, la tolerancia, el factor de inflación de la varianza, los autovalores y el número de condición. El objetivo es distinguir un coeficiente poco preciso de un coeficiente económicamente irrelevante, y separar la falta de evidencia individual de la falta de significancia conjunta. El cálculo manual se acompaña de código reproducible en Python. Al final se conserva la notación

$$\begin{aligned} \mathrm{SSR} &= \text{suma de cuadrados residual}, \\ \mathrm{SSE} &= \text{suma de cuadrados explicada}, \\ \mathrm{SST} &= \text{suma de cuadrados total}. \end{aligned}$$

Idea central

El análisis de regresión moderno reúne ideas que surgieron en momentos distintos. La geometría de mínimos cuadrados se remonta a Legendre y Gauss; la distribución t aparece en el trabajo de William Sealy Gosset, publicado bajo el seudónimo *Student*; y la comparación de varianzas y la formulación sistemática del análisis de la varianza quedaron estrechamente asociadas al trabajo de Ronald A. Fisher. Estas líneas convergen en la regresión lineal: estimamos por mínimos cuadrados, medimos incertidumbre mediante errores estándar y comparamos variación explicada con variación residual.

La tabla ANOVA no es, por ello, una tabla ornamental. Resume la descomposición geométrica de la variabilidad y hace visible el origen del estadístico F. De forma análoga, los diagnósticos de multicolinealidad no constituyen una colección de umbrales automáticos. Describen la geometría de las columnas de la matriz de diseño X. Cuando dos o más regresoras contienen casi la misma información lineal, la predicción puede permanecer estable mientras los coeficientes individuales se vuelven imprecisos.

Conviene separar también *ANOVA* de *MANOVA*. ANOVA, en el contexto de estas notas, organiza una única variable dependiente y conduce de manera natural a la prueba F global. MANOVA es una extensión para varias variables dependientes simultáneas y utiliza estadísticas matriciales como las trazas de Pillai y Hotelling–Lawley o la lambda de Wilks. MANOVA no es una prueba de multicolinealidad. La multicolinealidad pertenece a la estructura de las regresoras.

Índice

Introducción **1**

De mínimos cuadrados a la inferencia **1**

1. Regresión lineal **4**
1.1. Notación . . . 4
1.2. Estimación e inferencia . . . 4
1.3. Dummies e interacciones . . . 5
1.4. R^2 y ajuste . . . 6
1.5. Precios hedónicos . . . 6
1.6. Modelos anidados . . . 7
1.7. Lectura financiera . . . 8
1.8. Restricciones . . . 9
1.9. ANOVA y prueba F . . . 10
1.10. Multicolinealidad . . . 10
1.11. Matriz de diseño . . . 12
1.12. Cálculo reproducible . . . 12
1.13. MANOVA . . . 13
1.14. Residuos . . . 14
1.15. Distribuciones de referencia . . . 17
1.16. Lectura de una prueba F . . . 18

2. Datos reales **20**
2.1. Longley . . . 20
2.2. Engel . . . 22
2.3. Dummies e interacciones . . . 25
2.4. Autocorrelación . . . 26
2.5. Dinámica . . . 28
2.6. MANOVA . . . 29
2.7. Inferencia y predicción . . . 31
2.8. Diagnóstico . . . 32
2.9. Autocorrelación . . . 32
2.10. Normalidad y Jarque–Bera . . . 33
2.11. Flujo reproducible . . . 33

3. Ejercicios resueltos **33**
3.1. 1. Fondo . . . 34
3.2. 2. Cartera . . . 36
3.3. 3. Factores . . . 39
3.4. 4. Prueba t . . . 42
3.5. 5. Magnitud y significancia . . . 43
3.6. 6. Una cola . . . 44
3.7. 7. Un bloque . . . 44
3.8. 8. No rechazo . . . 45
3.9. 9. Restricción lineal . . . 45
3.10. Cómo concluir . . . 45

4. Ejercicios propuestos **46**
4.1. Respuestas . . . 48

5. Práctica con datos reales **49**

6. Verificación en Python **51**

7. Resumen **52**

8. Cierre **52**

1 Regresión lineal

Cómo estudiar esta sección. Lea cada bloque en el mismo orden: concepto → código → salida → interpretación. Las expresiones en **azul fuerte** son los resultados que conviene retener para una lectura rápida.

1.1 Notación

El modelo poblacional con k regresoras y n observaciones es

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki} + \varepsilon_i, \qquad i = 1, \ldots, n, \qquad \text{o bien} \qquad \mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

El estimador de MCO es $\hat{\boldsymbol{\beta}} = (X'X)^{-1}X'\mathbf{y}$, los valores ajustados son $\hat{Y}_i$ y los residuos $\hat{e}_i = Y_i - \hat{Y}_i$. Se usan tres sumas de cuadrados:

$$\text{SST} = \sum_{i=1}^{n}(Y_i - \bar{Y})^2, \qquad \text{SSE} = \sum_{i=1}^{n}(\hat{Y}_i - \bar{Y})^2, \qquad \text{SSR} = \sum_{i=1}^{n}\hat{e}_i^2, \qquad \text{SST} = \text{SSE} + \text{SSR}.$$

Convención: SSR es la suma de cuadrados de los *residuos* (lo que el modelo no explica) y SSE la suma de cuadrados *explicada*, como en las notas. Algunos libros usan las letras al revés; lo que importa es que en la prueba F entra siempre la suma de cuadrados *residual*. Además $R^2 = 1 - \text{SSR}/\text{SST} = \text{SSE}/\text{SST}$.

Convenciones que se mantendrán en todo el documento. Para evitar cambios de notación entre fórmulas, tablas y software, usaremos siempre:

$$\begin{aligned} \text{SSR}_R &: \text{ suma de cuadrados residual del modelo restringido,} \\ \text{SSR}_{NR} &: \text{ suma de cuadrados residual del modelo no restringido.} \end{aligned}$$

$$t_{\text{obs}} \quad \text{y} \quad F_{\text{obs}} \quad \text{para los estadísticos observados,}$$

y escribiremos el p-value como p-value. Los valores críticos se definen por su *cola derecha*:

$$P(T_\nu > t_{\alpha;\nu}) = \alpha, \qquad P(F_{\nu_1,\nu_2} > F_{\alpha;\nu_1,\nu_2}) = \alpha.$$

Por ello, en una prueba t bilateral de nivel α aparece $t_{\alpha/2;\nu}$, mientras que en una prueba F de nivel α aparece $F_{\alpha;\nu_1,\nu_2}$. Esta convención se conservará también al leer las tablas y al usar R o Python.

1.2 Estimación e inferencia

Antes de contrastar hipótesis conviene separar objetos que suelen confundirse. La variable dependiente Y es el resultado cuya media condicional queremos describir; X_j es un regresor; β_j es un parámetro poblacional fijo y desconocido; $\hat{\beta}_j$ es un estimador y, una vez observada la muestra, una estimación. El error poblacional ε_i no se observa, mientras que el residuo

$$\hat{e}_i = Y_i - \hat{Y}_i$$

se calcula después de estimar el modelo. El error estándar $\text{se}(\hat{\beta}_j)$ mide la precisión de un estimador, no la dispersión de la variable dependiente ni el tamaño de los residuos.

Orden de lectura de una regresión. Una salida econométrica debe leerse, *mutatis mutandis*, en este orden:

1. signo y unidades del coeficiente;
2. magnitud económica;
3. precisión mediante error estándar, estadístico t e intervalo de confianza;
4. ajuste global mediante R^2, $\bar{R}^2$ y prueba F;

5. diagnóstico de residuos y supuestos;
6. sólo entonces, conclusión estadística y económica.

Un p-value pequeño no convierte una relación condicional en una relación causal.

Supuestos esenciales

Convención tipográfica. En las tablas se usan reglas horizontales de `booktabs`; no se emplean líneas verticales. Los valores que determinan una decisión o que se reutilizan en el texto aparecen en rojo.

Para el modelo

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki} + \varepsilon_i$$

conviene distinguir los siguientes supuestos y su función:

1. **Linealidad en parámetros:** las transformaciones de las variables son admisibles; la linealidad se exige respecto de los coeficientes.
2. **Rango completo:** ninguna columna de X es combinación lineal exacta de las demás; así, $X'X$ es invertible.
3. **Media condicional cero:** $E(\varepsilon \mid X) = 0$. Es el supuesto central para interpretar MCO como estimación de la relación condicional especificada.
4. **Homoscedasticidad:** $\mathrm{Var}(\varepsilon_i \mid X) = \sigma^2$. Se necesita para la matriz de varianza clásica.
5. **Ausencia de autocorrelación:** $\mathrm{Cov}(\varepsilon_i, \varepsilon_j \mid X) = 0$ para $i \neq j$ en el esquema clásico.
6. **Normalidad:** facilita inferencia exacta en muestras pequeñas; no es necesaria para que MCO exista.

Bajo linealidad, rango completo, media condicional cero y varianza esférica

$$\mathrm{Var}(\varepsilon \mid X) = \sigma^2 I,$$

MCO es BLUE: dentro de la clase de estimadores lineales e insesgados, tiene varianza mínima. Es esencial no mezclar fallas distintas. Heteroscedasticidad o autocorrelación pueden invalidar la fórmula clásica del error estándar sin volver sesgado a $\hat{\beta}$ bajo exogeneidad; la endogeneidad, en cambio, compromete directamente la estimación de la relación condicional.

Interpretación ceteris paribus y formas funcionales

En un modelo lineal–lineal,

$$\beta_j = \frac{\partial E(Y \mid X)}{\partial X_j},$$

y se interpreta manteniendo constantes las demás regresoras incluidas. Para evitar interpretaciones mecánicas, conviene fijar las formas usuales:

Las cuatro formas que conviene reconocer de inmediato son:

1. **Nivel–nivel:** $Y = \beta_0 + \beta_1 X + u$. Una unidad adicional de X se asocia con β_1 unidades de Y.
2. **Log–nivel:** $\log Y = \beta_0 + \beta_1 X + u$. Una unidad adicional de X se asocia aproximadamente con $100\beta_1\,\%$ en Y; exactamente, con $100(e^{\beta_1} - 1)\,\%$.
3. **Nivel–log:** $Y = \beta_0 + \beta_1 \log X + u$. Un aumento de $1\,\%$ en X se asocia con $\beta_1/100$ unidades de Y.
4. **Log–log:** $\log Y = \beta_0 + \beta_1 \log X + u$. β_1 es una elasticidad.

1.3 Dummies e interacciones

Una variable indicadora D toma valores 0 y 1 y siempre se interpreta respecto de una categoría base. Si

$$Y = \beta_0 + \beta_1 X + \delta D + \varepsilon,$$

entonces δ es un cambio de intercepto. En efecto,

$$E(Y \mid X, D=0) = \beta_0 + \beta_1 X, \qquad E(Y \mid X, D=1) = (\beta_0 + \delta) + \beta_1 X.$$

Para permitir también un cambio de pendiente se introduce una interacción:

$$Y = \beta_0 + \beta_1 X + \delta D + \gamma(XD) + \varepsilon.$$

La pendiente para $D = 1$ es $\beta_1 + \gamma$. El coeficiente de la interacción no debe interpretarse aislado de los términos que la componen.

Trampa de variables ficticias. Con m categorías y una constante se incluyen $m - 1$ dummies. Incluir las m categorías junto con la constante genera colinealidad perfecta. Éste es un caso exacto de la condición $\operatorname{rank}(X) < k + 1$, no simplemente un VIF "alto".

Un ejemplo financiero es

$$\text{spread} = \beta_0 + \beta_1 \,\text{duration} + \delta \,\text{InvestmentGrade} + \gamma(\text{duration} \times \text{InvestmentGrade}) + \varepsilon.$$

Aquí δ modifica el nivel del spread y γ modifica su sensibilidad a la duración respecto del grupo base.

1.4 R^2 y ajuste

Con constante,

$$R^2 = \frac{\text{SSE}}{\text{SST}} = 1 - \frac{\text{SSR}}{\text{SST}},$$

mientras que

$$\bar{R}^2 = 1 - \frac{\text{SSR}/(n-k-1)}{\text{SST}/(n-1)}.$$

Agregar una regresora nunca reduce R^2, pero puede disminuir $\bar{R}^2$ si la reducción de SSR no compensa la pérdida de grados de libertad.

La diferencia operativa es sencilla: R^2 nunca disminuye al agregar regresoras; $\bar{R}^2$ sí puede hacerlo porque penaliza la pérdida de grados de libertad. Ninguno de los dos prueba causalidad ni garantiza una especificación correcta.

Un R^2 elevado puede coexistir con endogeneidad, heteroscedasticidad, tendencia espuria o una forma funcional inadecuada. Es una medida de ajuste *in sample*, no un certificado de validez causal.

1.5 Precios hedónicos

Un modelo hedónico descompone el precio de un bien diferenciado en el valor asociado a sus características observables:

$$P_i = f(z_{1i}, \ldots, z_{ki}) + \varepsilon_i.$$

En una especificación lineal,

$$P_i = \beta_0 + \beta_1 \, m_i^2 + \beta_2 \,\text{edad}_i + \beta_3 \,\text{metro}_i + \varepsilon_i,$$

β_1 es el precio marginal estimado de un metro cuadrado adicional, condicional a los demás atributos. En una especificación log–lineal, $\log P_i = \beta_0 + \beta_1 z_i + \cdots$, β_1 se interpreta aproximadamente como cambio porcentual en precio por unidad de atributo.

Los problemas frecuentes son variables omitidas de calidad, endogeneidad espacial, no linealidad e interacciones. Por ello el precio implícito de un atributo no debe leerse fuera de la forma funcional y del conjunto de controles.

1.6 Modelos anidados

Dos modelos están anidados si uno puede obtenerse imponiendo restricciones paramétricas sobre el otro. Por ejemplo,

$$M_1 : Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + u, \qquad M_0 : Y = \beta_0 + \beta_1 X_1 + u$$

son anidados porque M_0 se obtiene imponiendo $\beta_2 = 0$. La prueba F clásica es natural en este caso.

En cambio,

$$M_A : Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + u, \qquad M_B : Y = \gamma_0 + \gamma_1 Z_1 + \gamma_2 Z_2 + v$$

son no anidados si ninguno puede obtenerse como caso restringido del otro. Entonces una prueba F clásica de restricciones no es, en general, la comparación apropiada. Pueden considerarse AIC, BIC, desempeño fuera de muestra, teoría económica y pruebas específicas como Davidson–MacKinnon, según el objetivo.

Cuantiles

MCO modela la media condicional $E(Y \mid X)$. La regresión cuantílica modela directamente

$$Q_\tau(Y \mid X) = X'\beta_\tau, \qquad 0 < \tau < 1,$$

y estima β_τ minimizando la pérdida asimétrica

$$\min_b \sum_{i=1}^{n} \rho_\tau(Y_i - X_i'b), \qquad \rho_\tau(u) = u\big(\tau - \mathbf{1}\{u < 0\}\big).$$

Así, $\beta_{j,0.90}$ describe la asociación de X_j con el percentil 90 condicional de Y, no con su media. Es especialmente útil con distribuciones asimétricas, colas relevantes y efectos heterogéneos a lo largo de la distribución, como spreads, pérdidas, volatilidad o gasto.

Código 1. *Python — Regresión cuantílica con datos reales de tarjetas de crédito*

```python
import pandas as pd
import statsmodels.api as sm
import statsmodels.formula.api as smf

# 72 observaciones del conjunto ccard de statsmodels
df = sm.datasets.ccard.load_pandas().data

rows = []
for q in [0.10, 0.25, 0.50, 0.75, 0.90]:
    fit = smf.quantreg(
        "AVGEXP ~ AGE + INCOME + OWNRENT", data=df
    ).fit(q=q)
    rows.append([q, fit.params["INCOME"], fit.bse["INCOME"]])

out = pd.DataFrame(rows, columns=["q", "beta_income", "se"])
print(out.round(3).to_string(index=False))
```

Salida seleccionada

```
    q  beta_income     se
 0.10       34.504  8.832
 0.25       62.883 14.765
 0.50       56.404 13.831
 0.75       82.392 15.013
 0.90      140.859 21.863
```

Cómo se lee. El coeficiente de ingreso no es constante a lo largo de la distribución del gasto. En el cuantil 0.10, una unidad adicional de ingreso se asocia con unos 34.5 de gasto; en el cuantil 0.90, con aproximadamente 140.9. **La pendiente media no resume por sí sola la heterogeneidad condicional.**

1.7 Lectura financiera

Tres especificaciones resumen buena parte del uso de regresión en finanzas:

$$R_{i,t} - R_{f,t} = \alpha_i + \beta_i(R_{m,t} - R_{f,t}) + \varepsilon_{i,t},$$

$$R_{i,t} - R_{f,t} = \alpha_i + \beta_M MKT_t + \beta_S SMB_t + \beta_H HML_t + \varepsilon_{i,t},$$

y

$$\Delta Spread_t = \beta_0 + \beta_1 \Delta i_t + \beta_2 \Delta VIX_t + \beta_3 \Delta Liquidez_t + \varepsilon_t.$$

La lectura siempre es condicional: cada beta mide sensibilidad al factor correspondiente manteniendo los demás constantes. En series financieras deben vigilarse especialmente heteroscedasticidad, autocorrelación, colas pesadas y dinámica.

DataFrames mínimos que deben aparecer en una práctica. Una entrega reproducible debería mostrar, como mínimo:

1. `df.head()` para reconocer estructura, variables y frecuencia;
2. `df.describe()` para escala, dispersión y extremos;
3. una tabla de coeficientes con estimación, error estándar, t, p-value e intervalo;
4. una tabla de diagnósticos con BP, BG y JB;
5. una tabla final con la interpretación económica de los coeficientes relevantes.

Código 2. *Python — De datos reales a una salida de inferencia*

```python
import statsmodels.api as sm
import statsmodels.formula.api as smf

# Gasto con tarjeta: 72 observaciones reales
df = sm.datasets.ccard.load_pandas().data
fit = smf.ols("AVGEXP ~ AGE + INCOME + OWNRENT", data=df).fit()

print(fit.params.round(3))
print(fit.bse.round(3))
print(fit.pvalues.round(4))
print("R2 =", round(fit.rsquared, 3))
print("F =", round(fit.fvalue, 3), "p(F) =", round(fit.f_pvalue, 4))
```

Salida seleccionada

```
Coeficientes:
Intercept      0.397
AGE           -0.777
INCOME        79.836
OWNRENT       32.088

Errores estandar:
Intercept    163.985
AGE            5.513
INCOME        23.672
OWNRENT       84.724

p-values:
Intercept    0.9981
AGE          0.8883
INCOME       0.0012
OWNRENT      0.7061

R2 = 0.198
F = 5.598   p(F) = 0.0017
```

Cómo se lee. El modelo es significativo en conjunto ($p(F) = 0.0017$), pero la evidencia individual se concentra en `INCOME`: su estimación es 79.84 y su p-value es 0.0012. Edad y tenencia de vivienda no muestran evidencia individual al 5 % en esta especificación. **Significancia global no significa que todas las pendientes sean significativas.**

1.8 Restricciones

- **No restringido (NR):** se estiman libremente los $k + 1$ parámetros. Su suma de cuadrados residual es SSR_{NR}.
- **Restringido (R):** se imponen las q restricciones de H_0 (por ejemplo $\beta_2 = \beta_3 = 0$, lo que equivale a quitar X_2 y X_3) y se vuelve a estimar. Su suma de cuadrados residual es SSR_R.

Como el modelo restringido tiene menos libertad para ajustar los datos, siempre $\mathrm{SSR}_R \geq \mathrm{SSR}_{NR}$. La pregunta de la prueba es si el aumento $\mathrm{SSR}_R - \mathrm{SSR}_{NR}$ es grande en comparación con el ruido residual del modelo no restringido.

Estadístico F.

$$F = \frac{(\mathrm{SSR}_R - \mathrm{SSR}_{NR})/q}{\mathrm{SSR}_{NR}/(n-k-1)} \overset{H_0}{\sim} F_{q,\, n-k-1},$$

donde q es el número de restricciones, n el tamaño de muestra y k el número de regresoras del modelo *no restringido* (sin contar la constante). Si ambos modelos tienen la misma variable dependiente, la forma equivalente con R^2 es

$$F = \frac{(R^2_{NR} - R^2_R)/q}{(1 - R^2_{NR})/(n-k-1)}.$$

Caso particular (prueba global): si $H_0 : \beta_1 = \cdots = \beta_k = 0$, el modelo restringido es $Y_i = \beta_0 + \varepsilon_i$, su residual es $\mathrm{SSR}_R = \mathrm{SST}$ y $R^2_R = 0$:

$$F = \frac{\mathrm{SSE}/k}{\mathrm{SSR}/(n-k-1)} = \frac{R^2/k}{(1-R^2)/(n-k-1)}.$$

1.9 ANOVA y prueba F

Con constante,

$$\mathrm{SST} = \mathrm{SSE} + \mathrm{SSR}, \qquad \mathrm{MSR} = \frac{\mathrm{SSE}}{k}, \qquad \mathrm{MSE} = \frac{\mathrm{SSR}}{n-k-1},$$

y

$$F = \frac{\mathrm{MSR}}{\mathrm{MSE}}.$$

La idea es más importante que la tabla: comparar variación explicada por grado de libertad con variación residual por grado de libertad. En el Ejercicio 1,

$$\mathrm{SSE} = 9.4882, \qquad \mathrm{SSR} = 1.2118,$$

de donde

$$\mathrm{MSR} = 4.7441, \qquad \mathrm{MSE} = 0.1731, \qquad \boldsymbol{F = 27.40}.$$

La conclusión es global; no implica que cada pendiente sea individualmente significativa.

Código 3. *ANOVA mínima en Python*

```python
from scipy.stats import f

k = int(model.df_model)
df_resid = int(model.df_resid)
MSR = model.ess / k
MSE = model.ssr / df_resid

F = MSR / MSE
p = f.sf(F, k, df_resid)
print(F, p)
```

1.10 Multicolinealidad

La multicolinealidad aparece cuando una columna de la matriz de diseño puede aproximarse muy bien mediante una combinación lineal de otras columnas. En el caso extremo de colinealidad perfecta, $X'X$ es singular y el estimador usual

$$\hat{\boldsymbol{\beta}} = (X'X)^{-1}X'\mathbf{y}$$

no está definido. En el caso más habitual, la dependencia es fuerte pero no exacta: el estimador existe, aunque algunos errores estándar pueden aumentar considerablemente.

No existe una única "tabla de multicolinealidad". Conviene leer varias piezas de información en conjunto.

(i) **Matriz de correlaciones.** Detecta relaciones lineales bivariadas fuertes entre regresoras. Es útil como primera inspección, pero puede no detectar dependencias que involucren tres o más variables.

(ii) **VIF y tolerancia.** Para la regresora X_j, se estima una regresión auxiliar de X_j sobre todas las demás regresoras y se obtiene R_j^2. Entonces

$$\mathrm{VIF}_j = \frac{1}{1-R_j^2}, \qquad \mathrm{Tol}_j = 1 - R_j^2 = \frac{1}{\mathrm{VIF}_j}.$$

(iii) **Autovalores e índices de condición.** Después de estandarizar las columnas de X, los autovalores pequeños indican direcciones de baja variación. Un índice de condición puede definirse por

$$\kappa_j = \sqrt{\frac{\lambda_{\max}}{\lambda_j}}.$$

(iv) **Número de condición.** Resume cuán cerca se encuentra la matriz de diseño de una dependencia lineal numéricamente problemática. Su valor depende de la escala; por ello debe calcularse sobre una matriz adecuadamente estandarizada si se quiere interpretar como diagnóstico de colinealidad.

Umbrales: orientación, no ley. Los valores VIF > 5 o VIF > 10 se utilizan con frecuencia como señales de atención, pero no son teoremas ni fronteras universales. Un VIF debe interpretarse junto con el tamaño de muestra, el objetivo del modelo, la estabilidad de los coeficientes, los errores estándar y la naturaleza de las variables. Del mismo modo, un índice de condición elevado es una advertencia geométrica, no una sentencia automática de que el modelo deba descartarse.

Ejemplo con las regresoras del Ejercicio 1

Para las variables mercado X_1 y tasa X_2 del Ejercicio 1 se obtiene

$$\mathrm{Corr}(X_1, X_2) \approx -0.8534.$$

Con sólo dos regresoras, la regresión auxiliar de una sobre la otra tiene

$$R_j^2 = r_{12}^2 \approx 0.7283,$$

y por tanto

$$\mathrm{VIF}_1 = \mathrm{VIF}_2 = \frac{1}{1-0.7283} \approx 3.681.$$

En este caso, ambas regresoras tienen la misma tolerancia, 0.2717, y el mismo

$$\textbf{VIF} \approx \textbf{3.681}.$$

La correlación es alta en valor absoluto, pero el VIF no debe traducirse mecánicamente en una orden de eliminar alguna variable. La pregunta relevante es si la imprecisión resultante impide responder la pregunta económica que motivó el modelo.

Para la matriz de correlaciones estandarizada de estas dos regresoras, los autovalores son aproximadamente

$$\lambda_1 = 1.8534, \qquad \lambda_2 = 0.1466,$$

de modo que el mayor índice de condición es

$$\sqrt{\frac{1.8534}{0.1466}} \approx 3.556.$$

El autovalor grande es 1.8534 y el pequeño 0.1466; por ello el mayor índice de condición es

$$\boldsymbol{\kappa_{\max}} \approx \textbf{3.556}.$$

1.11 Matriz de diseño

Antes de interpretar un conjunto de coeficientes conviene distinguir qué pregunta responde cada salida:

Para leer rápido una salida conviene mantener separadas las preguntas. La **ANOVA** responde por significancia global; la **tabla de coeficientes**, por efectos individuales y su precisión; las **correlaciones**, por relaciones bivariadas entre regresoras; el **VIF**, por inflación de varianza; los **autovalores e índices de condición**, por direcciones casi redundantes de X; y **MANOVA**, por efectos conjuntos sobre varias respuestas. Ninguna de estas salidas sustituye a las demás.

1.12 Cálculo reproducible

El siguiente bloque reproduce el diagnóstico del Ejercicio 1. La idea es que el alumno pueda pasar de la tabla manual a una salida computacional que conserve la misma notación conceptual.

Código 4. *Python — Diagnóstico completo de una regresión lineal en Python.*

```python
import numpy as np
import pandas as pd
import statsmodels.formula.api as smf

from statsmodels.stats.anova import anova_lm
from statsmodels.stats.outliers_influence import variance_inflation_factor
from sklearn.preprocessing import StandardScaler

# Datos del Ejercicio 1
df = pd.DataFrame({
    "mercado": [1.2, -0.8, 2.0, 0.5, -1.5, 1.0, 2.5, -0.3, 0.0, 1.4],
    "tasa":    [7.0, 7.5, 6.5, 7.0, 8.0, 7.5, 6.0, 7.5, 7.0, 6.0],
    "fondo":   [1.0, 0.2, 1.6, 1.1, -1.2, 0.2, 2.4, -0.7, 0.9, 1.5]
})

# 1. Modelo MCO
modelo = smf.ols("fondo ~ mercado + tasa", data=df).fit()
print(modelo.summary())

# 2. Tabla ANOVA
tabla_anova = anova_lm(modelo)
print(tabla_anova)

# 3. Matriz de correlaciones de las regresoras
X = df[["mercado", "tasa"]]
print(X.corr())

# 4. VIF y tolerancia
vif = pd.DataFrame({
    "variable": X.columns,
    "VIF": [
        variance_inflation_factor(X.values, j)
        for j in range(X.shape[1])
    ]
})

# Para interpretar VIF como diagnostico de colinealidad es preferible
# incluir la constante en las regresiones auxiliares:
import statsmodels.api as sm
X_const = sm.add_constant(X)

vif = pd.DataFrame({
    "variable": X.columns,
    "VIF": [
        variance_inflation_factor(X_const.values, j + 1)
        for j in range(X.shape[1])
    ]
})
vif["tolerancia"] = 1.0 / vif["VIF"]
print(vif)

```

```python
# 5. Autovalores e indices de condicion
Z = StandardScaler().fit_transform(X)
R = np.corrcoef(Z, rowvar=False)

eigenvalues = np.linalg.eigvalsh(R)[::-1]
condition_indices = np.sqrt(eigenvalues.max() / eigenvalues)

tabla_condicion = pd.DataFrame({
    "autovalor": eigenvalues,
    "indice_condicion": condition_indices
})
print(tabla_condicion)

# 6. Numero de condicion de la matriz estandarizada
#    (sin constante, para no mezclar escala con colinealidad)
numero_condicion = np.linalg.cond(Z)
print("Numero de condicion:", numero_condicion)
```

Salida seleccionada: Ejercicio 1

```
R2 = 0.8867
F global = 27.4045     p(F) = 0.00049

coeficiente   estimacion   EE       t       p
mercado          0.2950   0.2112   1.396   0.2053
tasa            -1.0368   0.3991  -2.598   0.0355

corr(mercado,tasa) = -0.8534
VIF mercado = 3.6810
VIF tasa    = 3.6810
indice de condicion maximo = 3.5560
```

Cómo se lee. El modelo tiene un ajuste alto y es globalmente significativo, pero la variable mercado no es individualmente significativa al 5 %. La tasa sí lo es. La correlación entre regresoras es alta en valor absoluto y el VIF muestra pérdida de precisión, aunque no una colinealidad perfecta. **Debe leerse conjuntamente ajuste, inferencia individual y geometría de X.**

Qué debe mirar el alumno en Python. El objetivo del código no es sustituir la interpretación por una impresión de pantalla. Debe verificarse, en este orden, la tabla ANOVA, la tabla de coeficientes, la matriz de correlaciones, el VIF y, si hay sospecha de dependencia más compleja, los autovalores o índices de condición. Si distintas salidas parecen contar historias distintas, ése es precisamente el momento en que debe revisarse la estructura de X y no aplicar un umbral de forma automática.

1.13 MANOVA

MANOVA (*Multivariate Analysis of Variance*) se utiliza cuando existe un vector de variables dependientes,

$$\mathbf{Y}_i = \begin{pmatrix} Y_{1i} \\ \vdots \\ Y_{mi} \end{pmatrix},$$

y se desea estudiar si ciertos factores o regresoras producen un efecto conjunto sobre ese vector de respuestas. En lugar de una única suma de cuadrados, aparecen matrices de suma de cuadrados y productos cruzados. Entre los estadísticos habituales se encuentran la lambda de Wilks, la traza de Pillai, la traza de Hotelling–Lawley y la raíz máxima de Roy.

Las cuatro estadísticas más usuales resumen la separación multivariada desde ángulos distintos: la **lambda de Wilks** disminuye cuando la evidencia contra H_0 aumenta; la **traza de Pillai** acumula variación explicada y suele ser una lectura estable; **Hotelling–Lawley** suma las raíces características; y la **raíz máxima de Roy** se concentra en la dirección de mayor separación.

La multicolinealidad, en cambio, pregunta por relaciones entre las columnas de X. Es posible tener un MANOVA perfectamente bien planteado y, al mismo tiempo, presentar multicolinealidad entre las regresoras. Son problemas distintos.

Código 5. *Python — MANOVA con Iris: scikit-learn para los datos y statsmodels para la inferencia*

```python
from sklearn.datasets import load_iris
from statsmodels.multivariate.manova import MANOVA

iris = load_iris(as_frame=True)
df = iris.frame.rename(columns={
    "sepal length (cm)": "sepal_length",
    "sepal width (cm)": "sepal_width",
    "petal length (cm)": "petal_length",
    "petal width (cm)": "petal_width",
    "target": "species",
})

fit = MANOVA.from_formula(
    "sepal_length + sepal_width + petal_length + petal_width ~ C(species)",
    data=df,
)
print(fit.mv_test())
```

Salida seleccionada: efecto de especie

Statistic	Value	Num DF	Den DF	F	p
Wilks' lambda	0.0234	8.0	288.0	199.15	<0.001
Pillai's trace	1.1919	8.0	290.0	53.47	<0.001
Hotelling-Lawley trace	32.4773	8.0	203.4	582.20	<0.001
Roy's greatest root	32.1919	4.0	145.0	1166.96	<0.001

Cómo se lee. Las cuatro estadísticas conducen a la misma conclusión: las especies difieren en el vector conjunto de medidas morfológicas. **MANOVA responde por varias respuestas simultáneas; no diagnostica multicolinealidad entre regresoras.**

Lectura de una salida MANOVA. No debe elegirse el estadístico que produzca el menor p-value. Se especifica el contraste multivariado y se reporta de manera coherente una estadística principal, junto con sus grados de libertad aproximados y su p-value. La traza de Pillai es una elección frecuente cuando se desea una lectura estable frente a ciertas desviaciones de los supuestos, pero la elección debe justificarse por el diseño y no por el resultado observado.

1.14 Residuos

El diagnóstico comienza después de estimar. Su propósito no es conseguir que todas las pruebas "salgan bien", sino detectar estructura sistemática que permanece en los residuos y que puede volver inadecuada la inferencia clásica o la propia especificación de la media condicional.

La inspección debe responder preguntas concretas. **Residuos contra ajustados** busca curvatura y cambios de varianza; un **Q–Q** o histograma hace visibles colas, asimetría y valores extremos; **residuos contra tiempo** muestra rachas o persistencia; la **ACF** busca correlación serial; y **leverage/Cook** identifica observaciones con influencia desproporcionada.

Conviene separar tres niveles: supuestos sobre la media condicional, supuestos sobre la matriz de varianzas y covarianzas y supuestos distributivos. Corregir el error estándar no corrige una media mal especificada; por ejemplo, errores robustos no resuelven una variable omitida endógena.

Heteroscedasticidad y prueba de Breusch–Pagan

Existe heteroscedasticidad cuando

$$\operatorname{Var}(\varepsilon_i \mid X_i) = \sigma_i^2$$

varía entre observaciones. Bajo exogeneidad, MCO puede seguir siendo insesgado y consistente, pero deja de ser eficiente dentro de la clase lineal insesgada y los errores estándar clásicos pueden estar mal calibrados.

La prueba de Breusch–Pagan procede así:

1. estimar el modelo original y obtener $\hat{e}_i$;
2. regresar $\hat{e}_i^2$ sobre las regresoras de la prueba;
3. calcular $LM = nR^2_{aux}$;
4. bajo H_0 de homoscedasticidad, usar la referencia asintótica χ^2_q.

Si, por ejemplo, $n = 200$ y la regresión auxiliar produce $R^2_{aux} = 0.08$, entonces

$$LM = 200(0.08) = 16.$$

Con $q = 3$, este valor aporta evidencia contra homoscedasticidad al compararlo con una χ^2_3.

Si la media condicional parece bien especificada, los **errores robustos HC** mantienen los coeficientes MCO y corrigen la matriz de varianza. **WLS** puede ganar eficiencia cuando la estructura de varianza está bien modelada. Las **transformaciones** pueden estabilizar la varianza, pero deben conservar una interpretación económica coherente. Ninguna de estas estrategias corrige endogeneidad.

Autocorrelación: Durbin–Watson y Breusch–Godfrey

Existe autocorrelación serial si

$$\operatorname{Cov}(\varepsilon_t, \varepsilon_{t-j} \mid X) \neq 0$$

para algún rezago j. Un caso elemental es

$$\varepsilon_t = \rho\varepsilon_{t-1} + u_t, \qquad |\rho| < 1.$$

El estadístico de Durbin–Watson es

$$DW = \frac{\sum_{t=2}^{T}(\hat{e}_t - \hat{e}_{t-1})^2}{\sum_{t=1}^{T}\hat{e}_t^2},$$

y, heurísticamente,

$$DW \approx 2(1 - \hat{\rho}).$$

Así, $DW \approx 2$ sugiere poca autocorrelación de primer orden; valores pequeños sugieren autocorrelación positiva y valores grandes, negativa. Esta regla no sustituye la decisión formal y tiene limitaciones importantes cuando hay una variable dependiente rezagada.

Breusch–Godfrey es más flexible. Para orden p se regresa $\hat{e}_t$ sobre las regresoras originales y $\hat{e}_{t-1}, \ldots, \hat{e}_{t-p}$ y se calcula

$$LM = TR^2_{aux} \overset{a}{\sim} \chi^2_p$$

bajo ausencia de autocorrelación hasta orden p.

Durbin–Watson es una lectura rápida centrada principalmente en autocorrelación de primer orden y tiene limitaciones con dependientes rezagadas. Breusch–Godfrey permite especificar un orden p y formula el problema como una regresión auxiliar; por ello es la herramienta más flexible cuando se necesita una prueba formal de correlación serial de orden superior.

Cuando se desea conservar los coeficientes MCO y ajustar la inferencia ante heteroscedasticidad y autocorrelación débil, pueden utilizarse errores estándar HAC/Newey–West. No sustituyen una especificación dinámica si la media condicional está mal modelada.

Modelos dinámicos y rezagos

Un modelo dinámico incorpora valores pasados de Y, de X o de ambos. En el modelo

$$Y_t = \alpha + \phi Y_{t-1} + \beta X_t + u_t,$$

ϕ mide persistencia. Si $|\phi| < 1$, un aumento permanente de una unidad en X_t tiene multiplicador de largo plazo

$$\frac{\beta}{1-\phi}.$$

Por ejemplo, con $\phi = 0.75$ y $\beta = 0.50$,

$$\frac{0.50}{1-0.75} = 2.$$

El impacto contemporáneo es 0.50, pero el efecto acumulado de largo plazo es 2.

Un modelo de rezagos distribuidos toma la forma

$$Y_t = \alpha + \beta_0 X_t + \beta_1 X_{t-1} + \beta_2 X_{t-2} + u_t.$$

Aquí β_0 es el impacto contemporáneo, β_1 el efecto después de un periodo y β_2 después de dos; la suma $\beta_0 + \beta_1 + \beta_2$ es el efecto acumulado dentro del horizonte modelado. El número de rezagos puede guiarse por teoría, frecuencia de los datos, AIC/BIC, diagnóstico de residuos, estabilidad, parsimonia y desempeño fuera de muestra.

Normalidad y prueba de Jarque–Bera

Jarque–Bera contrasta si asimetría y curtosis son compatibles con normalidad. Si S es la asimetría muestral y K la curtosis total,

$$JB = \frac{n}{6}\left(S^2 + \frac{(K-3)^2}{4}\right) \overset{a}{\sim} \chi^2_2.$$

Con $n = 120$, $S = 0.8$ y $K = 4.2$,

$$JB = \frac{120}{6}\left(0.8^2 + \frac{(4.2-3)^2}{4}\right) = 20.$$

Rechazar normalidad no implica que MCO deje de ser consistente. En rendimientos financieros, colas pesadas y episodios extremos son frecuentes; la consecuencia depende del objetivo, del tamaño de muestra y de las condiciones asintóticas.

Python: una tabla única de diagnósticos

Código 6. *Python — Diagnóstico directo con tasas e inflación de Alemania*

```python
import statsmodels.api as sm
import statsmodels.formula.api as smf
from statsmodels.stats.diagnostic import het_breuschpagan, acorr_breusch_godfrey
from statsmodels.stats.stattools import durbin_watson, jarque_bera

# 107 observaciones trimestrales: 1972Q2--1998Q4
df = sm.datasets.interest_inflation.load_pandas().data
fit = smf.ols("R ~ Dp", data=df).fit()

bp = het_breuschpagan(fit.resid, fit.model.exog)
bg = acorr_breusch_godfrey(fit, nlags=4)
dw = durbin_watson(fit.resid)
jb = jarque_bera(fit.resid)

print("beta_Dp =", fit.params["Dp"], "p =", fit.pvalues["Dp"])
print("BP: LM =", bp[0], "p =", bp[1])
print("DW =", dw)
print("BG(4): LM =", bg[0], "p =", bg[1])
print("JB =", jb[0], "p =", jb[1])
```

Salida seleccionada

```
beta_Dp = 0.1182    p = 0.1651
BP:    LM = 0.0163  p = 0.8983
DW = 0.1728
BG(4): LM = 94.7263 p = 1.30e-19
JB = 1.6894          p = 0.4297
```

Cómo se lee. La pendiente contemporánea de inflación no es significativa al 5 %. Breusch–Pagan no detecta heteroscedasticidad en esta especificación y Jarque–Bera no rechaza normalidad. En cambio, $DW \approx 0.17$ y BG(4) rechaza con enorme claridad la ausencia de autocorrelación. **El problema dominante es temporal: el modelo estático deja mucha memoria en los residuos.**

Protocolo empírico. La secuencia recomendada conserva un orden lógico: primero se especifica el modelo; después se estima y se interpretan las magnitudes; a continuación se formula la inferencia conjunta mediante la prueba F; finalmente se estudian los residuos y, si es necesario, se corrige la inferencia o se reespecifica el modelo. Una conclusión profesional debe distinguir signo, magnitud, precisión y diagnóstico. No basta con escribir "significativo" o "no significativo".

1.15 Distribuciones de referencia

Distribución t de Student

Si $Z \sim N(0,1)$ y $U \sim \chi^2_\nu$ son independientes, entonces

$$T = \frac{Z}{\sqrt{U/\nu}} \sim t_\nu.$$

La distribución t_ν tiene soporte en toda la recta real y es simétrica alrededor de cero. Su forma es parecida a la normal estándar, pero sus colas son más pesadas: con pocos grados de libertad asigna más probabilidad a valores extremos. Al aumentar ν, se aproxima a $N(0,1)$. Su media es cero si $\nu > 1$ y no existe si $\nu \leq 1$; su varianza es $\nu/(\nu-2)$ si $\nu > 2$ y no existe si $\nu \leq 2$.

¿Por qué se usa en regresión? Para probar una hipótesis individual como $H_0 : \beta_j = \beta_{j,0}$ cuando la varianza de los errores es desconocida. Se estima esa varianza con los residuos y se divide la diferencia entre el estimador y el valor hipotético por su error estándar:

$$t = \frac{\hat{\beta}_j - \beta_{j,0}}{\mathrm{se}(\hat{\beta}_j)}.$$

Bajo los supuestos clásicos de errores normales, independientes y homocedásticos, bajo H_0 esta estadística sigue una t con $n-k-1$ grados de libertad. Para una alternativa bilateral se compara $|t|$ con el valor crítico $t_{\alpha/2;\,n-k-1}$; valores grandes en cualquiera de las dos colas son evidencia contra H_0. La misma distribución se usa para construir intervalos de confianza individuales para los coeficientes.

En Python. Si $\alpha = 0.05$ y $\nu = 7$, `t.ppf(1-0.05/2, 7)` devuelve 2.3646. Para un estadístico observado t_{obs}, el p-value bilateral se obtiene con `2*t.sf(abs(t_obs), 7)`.

Distribución F

Si $U_1 \sim \chi^2_{\nu_1}$ y $U_2 \sim \chi^2_{\nu_2}$ son independientes, entonces

$$F = \frac{U_1/\nu_1}{U_2/\nu_2} \sim F_{\nu_1,\nu_2}.$$

La distribución F sólo toma valores no negativos, suele ser asimétrica hacia la derecha y queda determinada por sus dos grados de libertad: ν_1 (numerador) y ν_2 (denominador). Se usa en la prueba de este apunte porque compara el aumento promedio en la suma de cuadrados residual al imponer las restricciones con la varianza residual estimada en el modelo no restringido. Bajo H_0 y los mismos supuestos clásicos, esa razón sigue una $F_{q,n-k-1}$. Por ello, la región de rechazo está en la cola derecha: un valor F grande indica que las restricciones empeoran el ajuste más de lo que cabría atribuir al ruido residual.

En Python. Para $\alpha = 0.05$, $q = 2$ y 7 grados de libertad residuales, `f.ppf(1-0.05, 2, 7)` devuelve 4.7374. El p-value se obtiene con `f.sf(F_obs, 2, 7)`.

Cómo elegir entre t y F. La prueba t evalúa una restricción sobre un coeficiente; la prueba F evalúa una o varias restricciones lineales de manera conjunta. Si se prueba una sola restricción bilateral en el mismo modelo, ambas pruebas son equivalentes:

$$F_{1,\nu} = t^2_{\nu}, \qquad F_{\text{observado}} = t^2_{\text{observado}}.$$

El cuadrado elimina el signo de t, por eso la equivalencia corresponde a la prueba t bilateral, no a una prueba unilateral. Con varias restricciones no basta con mirar las pruebas t por separado: la prueba F también toma en cuenta cómo se estiman conjuntamente los coeficientes.

1.16 Lectura de una prueba F

1. **Hipótesis.** Escribir H_0 (las q restricciones) y H_1 (al menos una no se cumple).
2. **Modelo no restringido.** Estimar por MCO y calcular SSR_{NR}.
3. **Modelo restringido.** Imponer H_0, estimar y calcular SSR_R.
4. **Estadístico.** Sustituir en la fórmula de F.
5. **Distribución de referencia y regla de decisión.** Bajo H_0 y los supuestos clásicos (incluida normalidad de los errores), $F \sim F_{q,n-k-1}$. Se rechaza H_0 al nivel α si $F > F_{\alpha;\,q,\,n-k-1}$. La prueba es de una sola cola (derecha): sólo valores grandes de F contradicen H_0.
6. **Conclusión en contexto**, en el lenguaje del problema.

Obtener valores críticos sin tabla. En Python, los valores críticos exactos se obtienen con SciPy. Por ejemplo:

Código 7. *Python — Valores críticos de t y F usados en los ejercicios*

```python
from scipy.stats import t, f

# t bilateral al 5%, 7 gl
t_crit = t.ppf(1 - 0.05/2, df=7)       # 2.3646

# F al 5%, q=2 restricciones y 7 gl residuales
```

```
F_crit = f.ppf(1 - 0.05, dfn=2, dfd=7) # 4.7374

print(t_crit, F_crit)
```

La lectura es inmediata: en una prueba t bilateral se compara $|t_{\text{obs}}|$ con $t_{\alpha/2;\nu}$; en una prueba F se compara F_{obs} con $F_{\alpha;q,\nu}$. En los ejercicios se mostrará también el código que produce el p-value correspondiente.

2 Datos reales

La teoría anterior se vuelve más transparente cuando se observa en datos que no fueron construidos para que la conclusión resulte limpia. Los siguientes casos no sustituyen los ejercicios algebraicos: los complementan. Cada conjunto se carga directamente desde Python y permite reproducir estimaciones, diagnósticos y figuras. En los ejemplos computacionales se conserva una secuencia deliberada: código, salida seleccionada y lectura econométrica. La salida completa de un paquete es útil para verificar; en las notas se muestra sólo aquello que debe interpretarse.

2.1 Longley

El conjunto Longley contiene 16 observaciones anuales de Estados Unidos entre 1947 y 1962. La variable dependiente es empleo total; entre las regresoras aparecen el deflactor del PNB, PNB, desempleo, tamaño de las fuerzas armadas, población y año. El conjunto es clásico precisamente porque sus regresoras son altamente colineales y se utilizó históricamente para evaluar la estabilidad numérica de rutinas de mínimos cuadrados.

El modelo completo produce

$$\boldsymbol{R^2 \approx 0.9955}, \qquad \bar{R}^2 \approx 0.9925, \qquad \boldsymbol{F \approx 330.29}, \qquad \boldsymbol{p}\text{-value}_{\boldsymbol{F}} \approx \boldsymbol{4.98 \times 10^{-10}}.$$

La regresión es globalmente muy significativa y ajusta extraordinariamente bien en muestra. Sin embargo, varios coeficientes individuales tienen errores estándar grandes y p-value elevados. No hay contradicción: el conjunto de regresoras explica mucho, pero la muestra contiene poca información independiente para separar ciertos efectos parciales.

Precisión

La multicolinealidad perfecta impide estimar MCO porque $X'X$ no es invertible. La multicolinealidad alta, en cambio, no destruye el estimador, pero puede volverlo muy impreciso. Para una regresora X_j se define

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2},$$

donde R_j^2 proviene de regresar X_j sobre todas las demás regresoras. En Longley, el VIF del PNB es aproximadamente

$$\mathrm{VIF}_{GNP} \approx 1788.5,$$

el de población es aproximadamente 399.2 y el de año aproximadamente 759.0. Estos números no deben leerse como un ritual de umbrales: documentan que algunas columnas de X están casi contenidas en el espacio generado por las otras.

El número de condición reportado por el modelo sin estandarizar es del orden de 4.86×10^9. Su magnitud refleja tanto escalas muy distintas como casi dependencias lineales. Por eso, para diagnóstico fino conviene estandarizar regresoras antes de interpretar autovalores e índices de condición.

Código y lectura

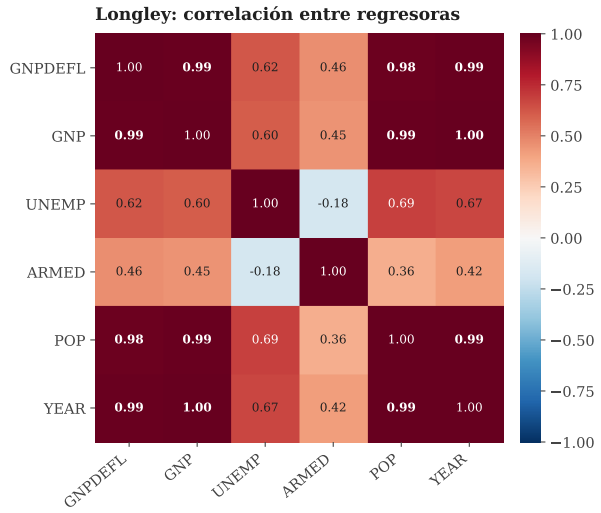


Figura 1. *Correlaciones entre las regresoras de Longley. Las correlaciones cercanas a uno entre PNB, población, deflactor y año anticipan problemas de precisión individual.*

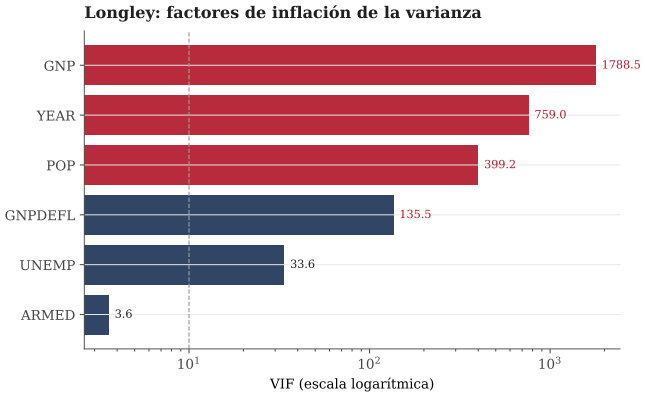


Figura 2. *Factores de inflación de la varianza en Longley. La escala es tan extrema que la lectura cualitativa es inmediata: el problema no es una correlación "moderada", sino redundancia lineal severa.*

Código 8. *Python — Longley: MCO, VIF y número de condición*

```python
import statsmodels.api as sm
from statsmodels.stats.outliers_influence import variance_inflation_factor

longley = sm.datasets.longley.load_pandas().data

y = longley["TOTEMP"]
X = sm.add_constant(longley.drop(columns="TOTEMP"))
model = sm.OLS(y, X).fit()

print(model.summary())
print("R2:", model.rsquared)
print("R2 ajustada:", model.rsquared_adj)
print("F global:", model.fvalue)
print("p(F):", model.f_pvalue)

for j, name in enumerate(X.columns[1:], start=1):
    vif = variance_inflation_factor(X.values, j)
    print(name, vif)
```

Salida esencial: Longley

R2	0.995479
R2 ajustada	0.992465
F global	330.2853
p(F)	4.984e-10

coeficiente	estimacion	error est.	p-value
GNPDEFL	15.0619	84.9149	0.8631
GNP	-0.0358	0.0335	0.3127
UNEMP	-2.0202	0.4884	0.0025
ARMED	-1.0332	0.2143	0.0009
POP	-0.0511	0.2261	0.8262
YEAR	1829.1515	455.4785	0.0030

Cómo se lee. La primera línea no debe eclipsar a las siguientes. El modelo explica casi toda la variación muestral y la prueba global rechaza con amplitud que todas las pendientes sean cero. Sin embargo, GNP, POP y GNPDEFL aparecen individualmente imprecisos. En Longley, ésa es precisamente la señal: la información conjunta es fuerte, pero varias columnas de X se mueven casi en la misma dirección y dificultan separar los efectos parciales.

Resultado central: ajuste global extraordinario no implica identificación individual precisa.

La lección es importante: un R^2 enorme no garantiza que cada $\hat{\beta}_j$ esté bien identificado. La significancia global pertenece al subespacio generado por las regresoras; la significancia individual depende de cuánto movimiento independiente queda para aislar cada pendiente.

2.2 Engel

Los datos de Engel contienen ingreso y gasto en alimentos de 235 hogares trabajadores de Bélgica en 1857. En MCO,

$$\widehat{foodexp} = 147.48 + 0.4852\, income,$$

con

$$R^2 \approx 0.8304, \qquad F \approx 1140.53, \qquad p\text{-value}_F < 10^{-90}.$$

La asociación media es muy precisa: en esta escala, una unidad adicional de ingreso se asocia con aproximadamente 0.485 unidades adicionales de gasto anual en alimentos.

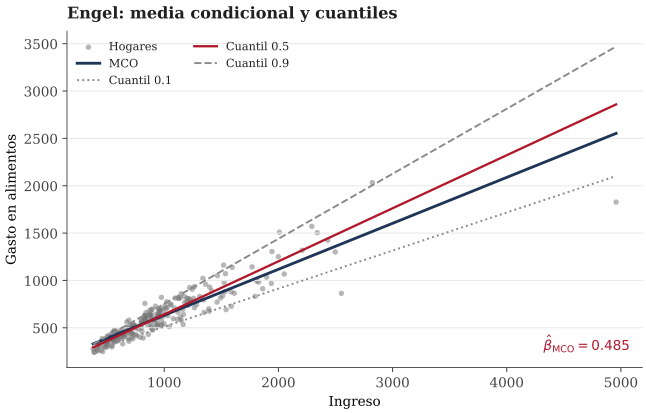


Figura 3. *Datos de Engel con recta MCO y regresiones cuantílicas. La sensibilidad del gasto en alimentos al ingreso aumenta hacia cuantiles altos de la distribución condicional.*

Heteroscedasticidad

El gráfico de residuos muestra que la dispersión aumenta con el nivel ajustado. Esto sugiere

$$\mathrm{Var}(\varepsilon_i \mid X_i) = \sigma_i^2$$

en lugar de una varianza constante σ^2.

La prueba de Breusch–Pagan arroja

$$\boldsymbol{LM \approx 109.26}, \qquad \boldsymbol{p}\text{-value} \approx \mathbf{1.42 \times 10^{-25}}.$$

La homoscedasticidad se rechaza de manera contundente. Bajo exogeneidad, este hallazgo no vuelve sesgados a los coeficientes MCO; sí invalida, en general, la fórmula clásica de varianza y puede distorsionar pruebas t y F basadas en errores estándar homoscedásticos.

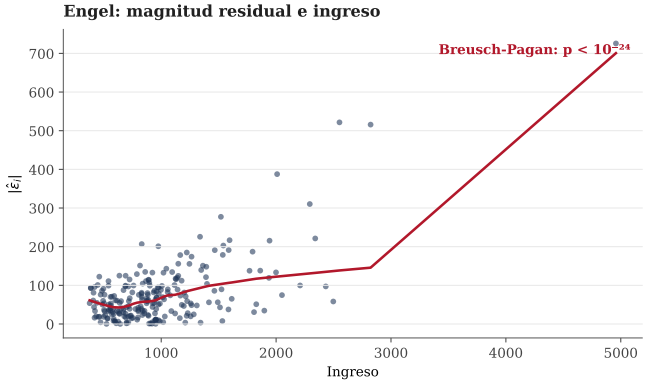


Figura 4. *Magnitud absoluta de los residuos frente al ingreso. La variación residual crece con la escala del hogar.*

Una respuesta práctica es conservar los coeficientes MCO y usar una matriz de covarianza robusta HC. Esto corrige la inferencia frente a heteroscedasticidad bajo supuestos adecuados; no corrige endogeneidad, variables omitidas ni una forma funcional equivocada.

Código 9. *Python — Engel: MCO, Breusch–Pagan y errores estándar robustos HC3*

```python
import statsmodels.api as sm
from statsmodels.stats.diagnostic import het_breuschpagan

engel = sm.datasets.engel.load_pandas().data
y = engel["foodexp"]
X = sm.add_constant(engel["income"])

ols = sm.OLS(y, X).fit()
robust = ols.get_robustcov_results(cov_type="HC3")

lm, lm_pvalue, fvalue, f_pvalue = het_breuschpagan(
    ols.resid, ols.model.exog
)

print(ols.params)
print("BP LM:", lm, "p:", lm_pvalue)
print(robust.summary())
```

Salida esencial: Engel

```
MCO
const       147.4754   (EE 15.9571)   p < 0.001
income        0.4852   (EE  0.0144)   p < 0.001
R2            0.8304

Breusch-Pagan
LM          109.2627
p-value       1.421e-25
```

Cómo se lee. **Resultado central: la pendiente es precisa, pero la homoscedasticidad se rechaza de manera contundente.**

La pendiente de ingreso está estimada con gran precisión, pero eso no autoriza a usar sin examen el error estándar homoscedástico. Breusch–Pagan rechaza con claridad la varianza constante. La estimación puntual MCO no cambia por pedir una covarianza HC3; lo que cambia es la cuantificación de su incertidumbre. Esta distinción —coeficiente frente a inferencia— debe aparecer explícitamente en la conclusión.

Cuantiles

La regresión cuantílica modela

$$Q_\tau(Y \mid X) = X'\beta_\tau, \qquad 0 < \tau < 1,$$

en lugar de $\mathbb{E}(Y \mid X)$. En Engel, las pendientes estimadas del ingreso son aproximadamente

$$\hat{\beta}_{0.10} = \mathbf{0.402}, \qquad \hat{\beta}_{0.50} = 0.560, \qquad \hat{\beta}_{0.90} = \mathbf{0.686}.$$

La relación ingreso–gasto no es la misma en toda la distribución condicional. Esto es precisamente lo que una sola recta MCO oculta.

Código 10. *Python — Engel: regresión cuantílica en varios cuantiles*

```python
import statsmodels.api as sm
from statsmodels.regression.quantile_regression import QuantReg

engel = sm.datasets.engel.load_pandas().data
X = sm.add_constant(engel["income"])
y = engel["foodexp"]

for q in [0.10, 0.25, 0.50, 0.75, 0.90]:
    fit = QuantReg(y, X).fit(q=q)
    print(q, fit.params["income"])
```

Salida esencial: pendientes cuantílicas en Engel

cuantil	beta_income
0.10	0.4018
0.25	0.4741
0.50	0.5602
0.75	0.6440
0.90	0.6863

Cómo se lee. La pendiente aumenta conforme avanzamos hacia la parte alta de la distribución condicional del gasto. MCO resume una media; estas cinco pendientes muestran que la respuesta al ingreso no es homogénea entre hogares. El interés de la regresión cuantílica no es producir cinco números donde antes había uno, sino revelar una estructura que una sola media no puede describir.

2.3 Dummies e interacciones

Las variables indicadoras no son una excepción a la regresión lineal; son una forma de codificar cambios de nivel o de pendiente. Si $D \in \{0, 1\}$,

$$Y = \beta_0 + \beta_1 X + \delta D + \gamma(XD) + \varepsilon,$$

entonces para $D = 0$ la pendiente es β_1, mientras que para $D = 1$ es $\beta_1 + \gamma$. La interacción no se interpreta sola: modifica una pendiente base.

El conjunto `committee` de `statsmodels` contiene información sobre 20 comités de la Cámara de Representantes de Estados Unidos, incluyendo asignaciones de proyectos, tamaño, número de subcomités, personal y una dummy de prestigio. Es un caso real donde dummy e interacción tienen sentido institucional.

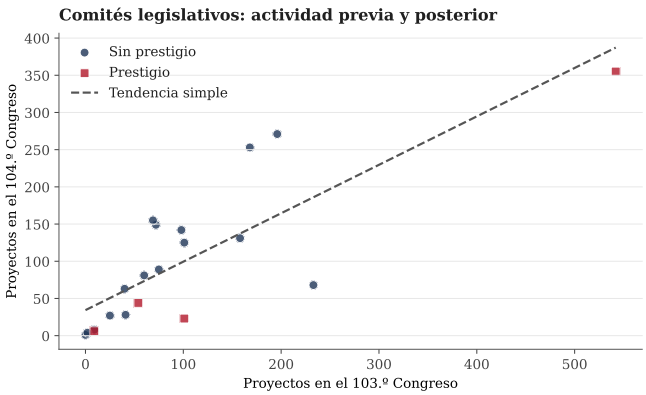


Figura 5. *Actividad legislativa y número de subcomités, distinguiendo comités de alta reputación. La separación visual no sustituye la regresión condicional, pero orienta la especificación.*

Una especificación útil es

$$BILLS104_i = \beta_0 + \beta_1 BILLS103_i + \beta_2 SIZE_i + \beta_3 SUBS_i + \beta_4 \log(STAFF_i) + \delta PRESTIGE_i + \gamma\, SUBS_i \log(STAFF_i) + u_i.$$

Con esta muestra el modelo alcanza $R^2 \approx 0.812$ y una prueba F global con p-value $\approx 4.23 \times 10^{-4}$. El coeficiente de una dummy o de una interacción no debe aislarse de su grupo base: su significado depende de qué otras variables se mantienen fijas y de cómo se construyó la interacción.

Código 11. *Python — Committee: dummies e interacción con datos reales*

```python
import numpy as np
import statsmodels.api as sm

committee = sm.datasets.committee.load_pandas().data.copy()
committee["logSTAFF"] = np.log(committee["STAFF"])
committee["SUBS_logSTAFF"] = committee["SUBS"] * committee["logSTAFF"]

cols = ["BILLS103", "SIZE", "SUBS", "logSTAFF",
        "PRESTIGE", "SUBS_logSTAFF"]
X = sm.add_constant(committee[cols])
y = committee["BILLS104"]

model = sm.OLS(y, X).fit()
print(model.summary())
```

Salida esencial: comités legislativos

```
R2          0.8123
F global    9.3782
p(F)        0.000423

variable          coef.       p-value
BILLS103          0.7041       <0.001
SIZE             -0.3531        0.827
SUBS             21.7385        0.545
logSTAFF         55.0512        0.229
PRESTIGE        -52.3352        0.137
SUBS_logSTAFF    -4.2839        0.592
```

Cómo se lee. **Resultado central: el bloque es significativo; la evidencia individual se concentra en la actividad legislativa previa.**

La regresión es significativa como conjunto, pero la evidencia individual se concentra en la actividad legislativa previa. El signo de `PRESTIGE` no debe interpretarse aisladamente como un "efecto del prestigio": la muestra es pequeña, la especificación contiene una interacción y cada coeficiente es condicional al resto. La salida sirve para practicar una lectura conjunta, no para convertir cada renglón en una afirmación causal.

La llamada "trampa de las dummies" es simplemente colinealidad perfecta. Con constante y m categorías exhaustivas, incluir m dummies produce una relación lineal exacta entre columnas de X. Se omite una categoría y ésta se convierte en base.

2.4 Autocorrelación

El conjunto `interest_inflation` contiene 107 observaciones trimestrales de 1972Q2 a 1998Q4 para Alemania Occidental y, posteriormente, Alemania. Incluye una tasa nominal de largo plazo R_t y el cambio logarítmico del deflactor del PIB, Dp_t.

Un modelo estático sencillo,

$$R_t = \beta_0 + \beta_1 Dp_t + u_t,$$

produce

$$\hat{\beta}_1 \approx 0.118, \qquad R^2 \approx 0.0183, \qquad p\text{-value}(\beta_1) \approx 0.165.$$

El signo es positivo, pero la evidencia individual es débil. Más importante aún: los residuos muestran una dependencia temporal severa.

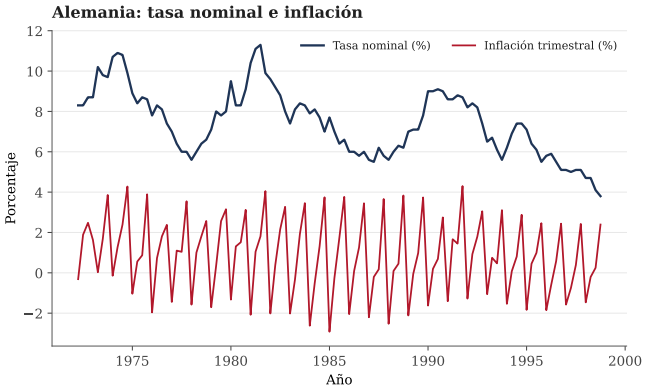


Figura 6. *Tasa nominal de largo plazo e inflación en Alemania. La persistencia temporal visible advierte contra una lectura puramente transversal.*

El estadístico Durbin–Watson es aproximadamente

$$\boldsymbol{DW \approx 0.173},$$

muy lejos del valor heurístico 2 asociado con poca autocorrelación de primer orden. Una prueba Breusch–Godfrey con cuatro rezagos produce

$$\boldsymbol{LM \approx 94.73}, \qquad \boldsymbol{p}\text{-value} \approx \mathbf{1.30 \times 10^{-19}}.$$

Por tanto, la especificación estática deja una gran cantidad de estructura temporal sin modelar.

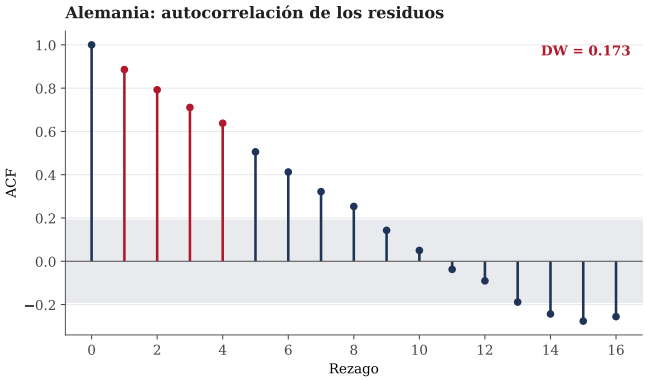


Figura 7. *Función de autocorrelación de los residuos del modelo estático. La persistencia es incompatible con la idea de errores serialmente no correlacionados.*

Código 12. *Python — Interest–Inflation: Durbin–Watson y Breusch–Godfrey*

```python
import statsmodels.api as sm
from statsmodels.stats.stattools import durbin_watson
from statsmodels.stats.diagnostic import acorr_breusch_godfrey

D = sm.datasets.interest_inflation.load_pandas().data
X = sm.add_constant(D["Dp"])
model = sm.OLS(D["R"], X).fit()

print("DW:", durbin_watson(model.resid))
print("BG(4):", acorr_breusch_godfrey(model, nlags=4))

# Inferencia HAC/Newey-West sin cambiar los coeficientes MCO
hac = model.get_robustcov_results(cov_type="HAC", maxlags=4)
print(hac.summary())
```

Salida esencial: tasa nominal e inflación

coeficiente de Dp	0.1182
p-value	0.1651
R2	0.0183
Durbin-Watson	0.1728
BG(4): LM	94.7263
BG(4): p-value	1.303e-19

Cómo se lee. **Resultado central: el problema dominante no es el coeficiente contemporáneo, sino la autocorrelación residual.**

La pendiente contemporánea no es significativa al 5 %, pero el problema más serio está en otra parte: DW es extremadamente bajo y Breusch–Godfrey rechaza con amplitud la ausencia de correlación serial. La conclusión correcta no es simplemente "inflación no significativa"; es que una regresión estática deja sin modelar una estructura temporal dominante.

HAC corrige la matriz de covarianza ante heteroscedasticidad y autocorrelación débil, pero no convierte una mala especificación de la media en una buena. Si la dinámica pertenece a $\mathbb{E}(R_t \mid \mathcal{F}_{t-1})$, entonces conviene modelarla explícitamente.

2.5 Dinámica

El conjunto `macrodata` contiene 203 observaciones trimestrales de Estados Unidos entre 1959Q1 y 2009Q3. Entre otras variables incluye inflación y tasa de interés real. La persistencia de estas series motiva una especificación dinámica.

Considere el modelo

$$r_t = \alpha + \phi r_{t-1} + \beta\, infl_t + u_t.$$

Con estos datos se obtiene aproximadamente

$$\hat{\alpha} = 2.316, \qquad \hat{\phi} = 0.428, \qquad \hat{\beta} = -0.391, \qquad R^2 \approx 0.493.$$

La condición $|\hat{\phi}| < 1$ es compatible con una dinámica estable. Si el cambio en inflación fuera permanente y la especificación se interpretara estructuralmente, el multiplicador de largo plazo asociado con β sería

$$\frac{\hat{\beta}}{1-\hat{\phi}} \approx \mathbf{-0.683}.$$

Esta fórmula no debe aplicarse mecánicamente: sólo tiene sentido si el modelo dinámico es estable y la interpretación del cambio permanente es coherente con la pregunta económica.

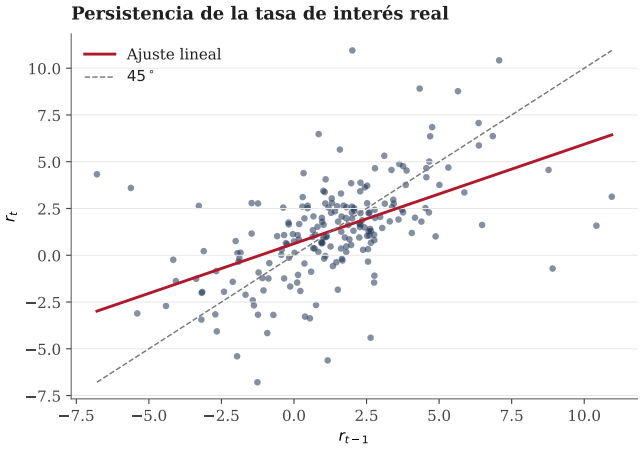


Figura 8. *Persistencia de la tasa real: r_t frente a r_{t-1}. La relación temporal justifica introducir rezagos en lugar de esconderlos dentro del error.*

Código 13. *Python — Macrodata: modelo dinámico y multiplicador de largo plazo*

```python
import statsmodels.api as sm

D = sm.datasets.macrodata.load_pandas().data.copy()
D["realint_l1"] = D["realint"].shift(1)
D = D.dropna()

X = sm.add_constant(D[["realint_l1", "infl"]])
y = D["realint"]
model = sm.OLS(y, X).fit()

phi = model.params["realint_l1"]
beta = model.params["infl"]
long_run = beta / (1 - phi)

print(model.summary())
print("Multiplicador de largo plazo:", long_run)
```

Salida esencial: modelo dinámico en Macrodata

```
variable        coef.       EE        p-value
const           2.3162     0.2387     <0.001
realint_l1      0.4282     0.0521     <0.001
infl           -0.3907     0.0425     <0.001

R2                        0.4931
multiplicador LP          -0.6833
```

Cómo se lee. **Resultado central: la dinámica estimada es estable y el multiplicador de largo plazo es aproximadamente -0.683.**

La persistencia es fuerte pero menor que uno en valor absoluto, por lo que la dinámica estimada es compatible con estabilidad. La pendiente contemporánea de inflación es negativa en esta especificación y el cociente $\hat{\beta}/(1-\hat{\phi})$ resume el efecto acumulado que implicaría un cambio permanente, siempre que la interpretación estructural del modelo sea defendible.

2.6 MANOVA

MANOVA aparece cuando existen varias variables dependientes que se desean contrastar conjuntamente. Esto es distinto de la multicolinealidad, que describe relaciones lineales entre regresoras. El conjunto Iris contiene 150 flores de tres especies y cuatro medidas morfológicas.

Podemos preguntar si el vector de medias de longitud y anchura de sépalos y pétalos difiere por especie.

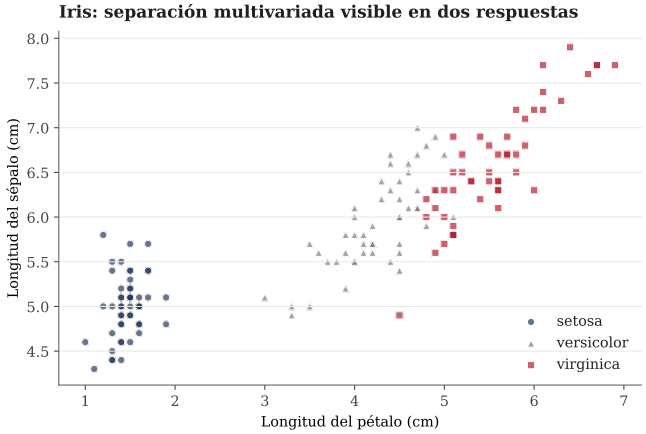


Figura 9. *Iris: dos de las cuatro respuestas morfológicas por especie. MANOVA aprovecha la estructura conjunta de varias respuestas; no diagnostica redundancia entre columnas explicativas de una regresión.*

Las estadísticas más habituales —lambda de Wilks, traza de Pillai, traza de Hotelling–Lawley y raíz máxima de Roy— resumen de manera distinta la separación multivariada entre grupos. No es necesario memorizarlas como una lista: conviene entender que comparan variación entre grupos con variación dentro de grupos en un espacio de respuestas de dimensión mayor que uno.

Código 14. *Python — Iris: MANOVA con varias respuestas*

```python
from sklearn.datasets import load_iris
from statsmodels.multivariate.manova import MANOVA

iris = load_iris(as_frame=True)
df = iris.frame.copy()
df["species"] = df["target"].map(dict(enumerate(iris.target_names)))

df = df.rename(columns={
    "sepal length (cm)": "sepal_length",
    "sepal width (cm)": "sepal_width",
    "petal length (cm)": "petal_length",
    "petal width (cm)": "petal_width",
})

maov = MANOVA.from_formula(
    "sepal_length + sepal_width + petal_length + petal_width ~ species",
    data=df,
)
print(maov.mv_test())
```

Salida esencial: efecto de especie en MANOVA

species	Value	Num DF	Den DF	F	Pr > F
Wilks' lambda	0.0234	8	288.0	199.15	<0.001
Pillai's trace	1.1919	8	290.0	53.47	<0.001
Hotelling-Lawley	32.4773	8	203.4	582.20	<0.001
Roy's greatest root	32.1919	4	145.0	1166.96	<0.001

Cómo se lee. **Resultado central: las cuatro pruebas multivariadas rechazan igualdad entre especies con $p < 0.001$.**

Las cuatro estadísticas llevan a la misma conclusión sustantiva: el vector de medidas morfológicas difiere por especie. La lambda de Wilks pequeña y los p-values prácticamente nulos documentan

una separación multivariada marcada. Nada de esto diagnostica multicolinealidad; la pregunta y el objeto estadístico son distintos.

2.7 Inferencia y predicción

`statsmodels` y `scikit-learn` pueden estimar la misma recta por mínimos cuadrados, pero están diseñados para preguntas distintas. Si se usa la misma matriz X, `LinearRegression` reproduce los coeficientes MCO; su interfaz, sin embargo, está orientada a predicción, validación y construcción de flujos de modelado. `statsmodels` expone de forma natural errores estándar, pruebas e intervalos. Conviene usar cada herramienta para la pregunta que resuelve mejor.

Con Engel, una partición fija de 80 % para entrenamiento y 20 % para prueba permite ilustrarlo sin cambiar de conjunto de datos.

Código 15. *Python — Engel con scikit-learn: entrenamiento, predicción y métricas*

```python
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score, mean_squared_error
import statsmodels.api as sm

engel = sm.datasets.engel.load_pandas().data
X = engel[["income"]]
y = engel["foodexp"]

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=42
)

reg = LinearRegression().fit(X_train, y_train)
y_pred = reg.predict(X_test)

print("intercepto:", reg.intercept_)
print("pendiente:", reg.coef_[0])
print("R2 test:", r2_score(y_test, y_pred))
print("RMSE test:", mean_squared_error(y_test, y_pred) ** 0.5)
```

Salida esencial: Engel fuera de muestra

```
intercepto    163.0757
pendiente       0.4617
R2 test         0.8447
RMSE test     119.8959
```

Cómo se lee. Aquí R^2 y RMSE describen desempeño predictivo sobre observaciones no utilizadas para ajustar la recta. No son sustitutos de un p-value ni de un intervalo de confianza. La pendiente de entrenamiento es cercana a la MCO de la muestra completa, pero la pregunta ha cambiado: ahora interesa cuánto error comete el modelo al predecir nuevos hogares.

En problemas con fuerte colinealidad, `Ridge` puede estabilizar predicciones mediante una penalización. Esa regularización cambia deliberadamente los coeficientes y, por tanto, no debe presentarse como si fuera MCO con mejores p-values.

Código 16. *Python — Longley con RidgeCV: regularización para predicción, no para inferencia clásica*

```python
import numpy as np
import statsmodels.api as sm
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import RidgeCV
from sklearn.model_selection import LeaveOneOut, cross_val_predict
from sklearn.metrics import mean_squared_error

```

```python
D = sm.datasets.longley.load_pandas().data
X = D.drop(columns="TOTEMP")
y = D["TOTEMP"]

ridge = make_pipeline(
    StandardScaler(),
    RidgeCV(
        alphas=np.logspace(-3, 4, 200),
        cv=LeaveOneOut(),
        scoring="neg_mean_squared_error"
    )
)
ridge.fit(X, y)

alpha = ridge.named_steps["ridgecv"].alpha_
pred = cross_val_predict(ridge, X, y, cv=LeaveOneOut())
rmse = mean_squared_error(y, pred) ** 0.5

print("alpha elegido:", alpha)
print("RMSE LOO:", rmse)
```

Salida esencial: RidgeCV en Longley

```
alpha elegido    0.002866
RMSE LOO       401.2883
```

Cómo se lee. La regularización introduce sesgo a cambio de estabilidad. En una muestra tan pequeña como Longley, la validación deja además poca información para evaluar predicción. El ejemplo es útil precisamente para separar dos objetivos: diagnosticar e interpretar parámetros con MCO, o construir un predictor regularizado. No son sinónimos.

2.8 Diagnóstico

El diagnóstico debe responder a preguntas distintas. Un gráfico de residuos frente a ajustados busca forma funcional y cambios de varianza. Una ACF busca dependencia temporal. Un VIF estudia cuánto de una regresora puede reconstruirse con las demás. Jarque–Bera resume asimetría y curtosis. Ninguno de estos instrumentos sustituye a los otros porque cada uno examina una propiedad diferente.

Heteroscedasticidad

Bajo exogeneidad, la heteroscedasticidad no implica por sí sola sesgo de MCO. El problema es

$$\operatorname{Var}(\varepsilon_i \mid X_i) = \sigma_i^2,$$

por lo que la matriz clásica $\hat{\sigma}^2(X'X)^{-1}$ deja de describir correctamente la incertidumbre. Las alternativas más frecuentes son errores robustos HC, transformaciones justificadas por la teoría o WLS cuando existe un modelo plausible para la varianza.

2.9 Autocorrelación

En series de tiempo,

$$\operatorname{Cov}(\varepsilon_t, \varepsilon_{t-j} \mid X) \neq 0$$

indica que el error conserva memoria. Durbin–Watson sirve como diagnóstico elemental de primer orden; Breusch–Godfrey permite un orden p configurable y es más flexible, en particular cuando aparecen rezagos de la variable dependiente.

2.10 Normalidad y Jarque–Bera

Jarque–Bera utiliza asimetría S y curtosis K:

$$JB = \frac{n}{6}\left(S^2 + \frac{(K-3)^2}{4}\right).$$

Bajo normalidad y condiciones asintóticas,

$$JB \overset{a}{\sim} \chi^2_2.$$

Rechazar normalidad no implica que MCO deje de existir ni que, bajo exogeneidad, pierda automáticamente consistencia. En muestras grandes, la inferencia puede apoyarse en resultados asintóticos y matrices robustas; en colas financieras extremas puede ser necesario un modelo probabilístico más apropiado.

2.11 Flujo reproducible

El siguiente patrón es deliberadamente corto. La idea es que el estudiante pueda aplicarlo a casi cualquier problema lineal antes de escribir una interpretación.

Código 17. *Python — Flujo reproducible: MCO, VIF y diagnósticos esenciales*

```python
import statsmodels.api as sm
from statsmodels.stats.diagnostic import het_breuschpagan, acorr_breusch_godfrey
from statsmodels.stats.stattools import durbin_watson, jarque_bera
from statsmodels.stats.outliers_influence import variance_inflation_factor

# 1. Preparar y estimar
y = df["y"]
X = sm.add_constant(df[["x1", "x2", "x3"]])
model = sm.OLS(y, X).fit()

# 2. Inferencia basica
print(model.params)
print(model.bse)
print(model.tvalues)
print(model.pvalues)
print(model.conf_int())
print(model.fvalue, model.f_pvalue)

# 3. Multicolinealidad
for j, name in enumerate(X.columns[1:], start=1):
    print(name, variance_inflation_factor(X.values, j))

# 4. Heteroscedasticidad
print("BP:", het_breuschpagan(model.resid, model.model.exog))

# 5. Dependencia temporal
print("DW:", durbin_watson(model.resid))
print("BG(4):", acorr_breusch_godfrey(model, nlags=4))

# 6. Forma marginal de los residuos
print("JB:", jarque_bera(model.resid))

# 7. Inferencia robusta si el diagnostico la justifica
print(model.get_robustcov_results(cov_type="HC3").summary())
```

La salida no debe copiarse entera en un reporte. Debe transformarse en una conclusión: qué parámetro se estimó, en qué unidades, con qué precisión, bajo qué supuestos y qué diagnóstico limita la interpretación.

3 Ejercicios resueltos

3.1 1. Fondo

Contexto. Como en el ejemplo 1.2 de las notas, un analista explica el rendimiento mensual de un fondo de inversión, Y_i (%), con el rendimiento del mercado, X_{1i} (%), y la tasa de interés, X_{2i} (%):

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i, \qquad n = 10, \quad k = 2.$$

Mes i	1	2	3	4	5	6	7	8	9	10
X_1: mercado (%)	1.2	−0.8	2.0	0.5	−1.5	1.0	2.5	−0.3	0.0	1.4
X_2: tasa (%)	7.0	7.5	6.5	7.0	8.0	7.5	6.0	7.5	7.0	6.0
Y: fondo (%)	1.0	0.2	1.6	1.1	−1.2	0.2	2.4	−0.7	0.9	1.5

Se pide. (a) Estimar el modelo por MCO. (b) Probar al 5 % la significancia global $H_0 : \beta_1 = \beta_2 = 0$. (c) Probar al 5 % $H_0 : \beta_1 = 0$ con una prueba F y comparar con la prueba t.

Resolución

Hipótesis.

$$H_0 : \ \beta_1 = \beta_2 = 0 \qquad \text{vs.} \qquad H_1 : \ \beta_1 \neq 0 \text{ o } \beta_2 \neq 0.$$

Hay $q = 2$ restricciones. Bajo H_0 ni el mercado ni la tasa ayudan a explicar el rendimiento del fondo.

Estimación. Las medias son

$$\bar{X}_1 = 0.6, \qquad \bar{X}_2 = 7.0, \qquad \bar{Y} = 0.7,$$

y las sumas centradas necesarias son

$$S_{11} = 14.28, \quad S_{22} = 4.00, \quad S_{12} = -6.45, \quad S_{1y} = 10.90, \quad S_{2y} = -6.05, \quad \text{SST} = 10.70.$$

Con ellas se resuelven directamente las ecuaciones normales:

Las ecuaciones normales en desviaciones,

$$\begin{pmatrix} S_{11} & S_{12} \\ S_{12} & S_{22} \end{pmatrix} \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} S_{1y} \\ S_{2y} \end{pmatrix},$$

se resuelven con la regla de Cramer. El determinante es

$$D = S_{11}S_{22} - S_{12}^2 = (14.28)(4.00) - (-6.45)^2 = 57.12 - 41.6025 = 15.5175.$$

Entonces

$$\hat{\beta}_1 = \frac{S_{22}S_{1y} - S_{12}S_{2y}}{D} = \frac{(4.00)(10.90) - (-6.45)(-6.05)}{15.5175} = \frac{4.5775}{15.5175} = 0.2950,$$

$$\hat{\beta}_2 = \frac{S_{11}S_{2y} - S_{12}S_{1y}}{D} = \frac{(14.28)(-6.05) - (-6.45)(10.90)}{15.5175} = \frac{-16.089}{15.5175} = -1.0368,$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1\bar{X}_1 - \hat{\beta}_2\bar{X}_2 = 0.7 - (0.2950)(0.6) - (-1.0368)(7.0) = 7.7808.$$

$$\boldsymbol{\hat{Y}_i = 7.7808 + 0.2950\, X_{1i} - 1.0368\, X_{2i}}$$

Lectura: manteniendo fija la tasa, un punto porcentual más de rendimiento de mercado se asocia con 0.295 puntos más de rendimiento del fondo; manteniendo fijo el mercado, un punto más de tasa se asocia con 1.037 puntos menos.

Ajuste. Usando las sumas anteriores,

$$\text{SSE} = \hat{\beta}_1 S_{1y} + \hat{\beta}_2 S_{2y} = 9.4882, \qquad \text{SSR}_{NR} = \text{SST} - \text{SSE} = 1.2118,$$

y

$$\boldsymbol{R^2 = 0.8867}.$$

La comprobación computacional aparece al final de los ejercicios.

Restricción global. Bajo $H_0 : \beta_1 = \beta_2 = 0$ el modelo es $Y_i = \beta_0 + \varepsilon_i$, cuyo estimador de MCO es $\hat{\beta}_0 = \bar{Y} = 0.7$. Sus residuos son $Y_i - \bar{Y}$, así que

$$\text{SSR}_R = \sum_{i=1}^{10} (Y_i - \bar{Y})^2 = \text{SST} = 10.70.$$

Contraste. Con $q = 2$, $n = 10$, $k = 2$ y $n - k - 1 = 7$:

$$F = \frac{(\text{SSR}_R - \text{SSR}_{NR})/q}{\text{SSR}_{NR}/(n-k-1)} = \frac{(10.70 - 1.2118)/2}{1.2118/7} = \frac{4.7441}{0.17311} = 27.40.$$

Con R^2: $F = \dfrac{0.8867/2}{(1-0.8867)/7} = \dfrac{0.44337}{0.016179} = 27.40$. Coinciden.

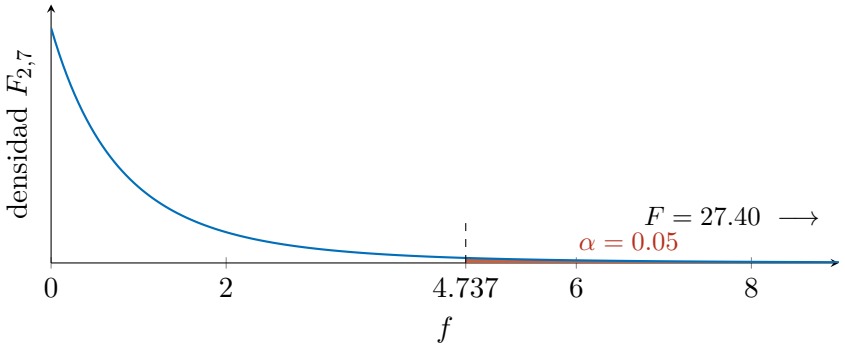
Conclusión. Bajo H_0, $F \sim F_{2,7}$ y el valor crítico al 5 % es $F_{0.05;\,2,7} = 4.737$.

$$F = 27.40 > 4.737 \implies \text{se rechaza } H_0.$$

También $27.40 > 9.547 = F_{0.01;\,2,7}$: se rechaza incluso al 1 % (valor $p \approx 0.0005$).

Conclusión: el rendimiento del mercado y la tasa de interés, considerados conjuntamente, explican una parte significativa de la variación del rendimiento del fondo.

Región de rechazo al 5 %: el estadístico observado $F = 27.40$ queda muy a la derecha



Restricción individual. Hipótesis: $H_0 : \beta_1 = 0$ vs. $H_1 : \beta_1 \neq 0$; ahora $q = 1$.

Modelo restringido: quitar X_1 y estimar $Y_i = \gamma_0 + \gamma_2 X_{2i} + \varepsilon_i$ (regresión simple):

$$\hat{\gamma}_2 = \frac{S_{2y}}{S_{22}} = \frac{-6.05}{4.00} = -1.5125, \qquad \hat{\gamma}_0 = \bar{Y} - \hat{\gamma}_2 \bar{X}_2 = 0.7 + 1.5125(7.0) = 11.2875,$$

$$\text{SSR}_R = S_{yy} - \hat{\gamma}_2 S_{2y} = 10.70 - (-1.5125)(-6.05) = 10.70 - 9.1506 = 1.5494.$$

Estadístico:

$$F = \frac{(1.5494 - 1.2118)/1}{1.2118/7} = \frac{0.3376}{0.17311} = 1.950.$$

Decisión: $F_{0.05;\,1,7} = 5.591$ y $1.950 < 5.591$: **no se rechaza** H_0 (valor $p \approx 0.21$).

Relación con la prueba t. Con $\hat{\sigma}^2 = \mathrm{SSR}_{NR}/(n-k-1) = 0.17311$,

$$\mathrm{se}(\hat{\beta}_1) = \sqrt{\frac{\hat{\sigma}^2\, S_{22}}{D}} = \sqrt{\frac{(0.17311)(4.00)}{15.5175}} = 0.2112, \qquad t = \frac{0.2950}{0.2112} = 1.396,$$

y $t^2 = (1.396)^2 = 1.950 = F$. Lo mismo ocurre con los valores críticos: $t^2_{0.025;7} \approx 5.591 = F_{0.05;1,7}$ (el valor crítico t redondeado es 2.365). Con una sola restricción, la prueba F y la prueba t bilateral son la misma prueba.

Lección del ejercicio 1. El mercado no es significativo *individualmente* ($F = 1.95$), pero las dos regresoras sí lo son *conjuntamente* ($F = 27.40$). No hay contradicción: el mercado y la tasa están fuertemente correlacionados en la muestra (correlación -0.85; observe que $S_{12} = -6.45$), de modo que los datos apenas permiten separar el efecto de cada una, aunque dejan claro que el bloque explica al fondo. Por eso una prueba conjunta no se reemplaza por varias pruebas t por separado.

3.2 2. Cartera

Contexto. Un analista estudia el rendimiento mensual de una cartera de acciones mexicanas, Y_i (%), en función del rendimiento de un índice de mercado, X_{1i} (%), y de la variación mensual del tipo de cambio, X_{2i} (%). Se considera el modelo

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i, \qquad n = 12, \quad k = 2.$$

Mes i	1	2	3	4	5	6	7	8	9	10	11	12
X_1: mercado (%)	1.5	−1.0	2.2	0.8	−1.6	1.1	2.8	−0.5	0.3	1.7	−0.9	2.0
X_2: tipo de cambio (%)	0.2	0.8	−0.3	0.1	1.0	0.4	−0.5	0.7	0.0	−0.2	0.9	−0.4
Y: cartera (%)	1.665	−1.090	2.565	0.745	−1.050	0.755	2.975	−0.710	0.775	2.035	−0.970	2.020

Se pide.

(a) Estimar el modelo por MCO e interpretar los coeficientes.

(b) Probar al 5 % la significancia global

$$H_0 : \beta_1 = \beta_2 = 0.$$

(c) Probar al 5 % la hipótesis individual

$$H_0 : \beta_2 = 0$$

mediante una prueba F y comprobar la equivalencia con la prueba t bilateral.

(d) Explicar por qué puede rechazarse la significancia global aun cuando una de las dos variables no sea individualmente significativa al 5 %.

Resolución

Hipótesis. La prueba conjunta es

$$H_0 : \beta_1 = \beta_2 = 0 \qquad \text{vs.} \qquad H_1 : \text{al menos uno de los dos coeficientes es distinto de cero.}$$

Hay $q = 2$ restricciones. El modelo no restringido contiene las dos regresoras; bajo H_0, el modelo restringido contiene únicamente la constante.

Cálculo. Las medias son

$$\bar{X}_1 = 0.7000, \qquad \bar{X}_2 = 0.2250, \qquad \bar{Y} = 0.8096.$$

Definiendo

$$x_{1i} = X_{1i} - \bar{X}_1, \qquad x_{2i} = X_{2i} - \bar{X}_2, \qquad y_i = Y_i - \bar{Y},$$

se obtienen las sumas de productos centradas

$$S_{11} = \sum x_{1i}^2 = 22.5000, \qquad S_{22} = \sum x_{2i}^2 = 3.0825,$$

$$S_{12} = \sum x_{1i}x_{2i} = -7.8300,$$

$$S_{1y} = \sum x_{1i}y_i = 22.8265, \qquad S_{2y} = \sum x_{2i}y_i = -8.2404,$$

y

$$\mathrm{SST} = S_{yy} = \sum y_i^2 = 24.0199.$$

El determinante del sistema de ecuaciones normales es

$$D = S_{11}S_{22} - S_{12}^2 = (22.5)(3.0825) - (-7.83)^2 = 8.04735.$$

Estimación. Con dos regresoras,

$$\hat{\beta}_1 = \frac{S_{22}S_{1y} - S_{12}S_{2y}}{D} = 0.7258,$$

$$\hat{\beta}_2 = \frac{S_{11}S_{2y} - S_{12}S_{1y}}{D} = -0.8297.$$

La constante es

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1\bar{X}_1 - \hat{\beta}_2\bar{X}_2 = 0.4882.$$

Por tanto,

$$\boxed{\hat{Y}_i = 0.4882 + 0.7258X_{1i} - 0.8297X_{2i}}.$$

Interpretación económica. Manteniendo fija la variación del tipo de cambio, un aumento de un punto porcentual en el rendimiento del mercado se asocia, en promedio, con un aumento de aproximadamente 0.726 puntos porcentuales en el rendimiento de la cartera.

Manteniendo fijo el rendimiento del mercado, un aumento de un punto porcentual en X_2 se asocia con una disminución estimada de aproximadamente 0.830 puntos porcentuales en el rendimiento de la cartera. Esta segunda interpretación describe la magnitud estimada; todavía falta determinar si la evidencia estadística es suficiente para afirmar que el efecto es distinto de cero.

Ajuste. Para el modelo no restringido,

$$\mathrm{SSR}_{NR} = 0.6159.$$

Como

$$\mathrm{SST} = \mathrm{SSE} + \mathrm{SSR},$$

se tiene

$$\mathrm{SSE} = 24.0199 - 0.6159 = 23.4040,$$

y

$$R^2 = 1 - \frac{\mathrm{SSR}_{NR}}{\mathrm{SST}} = 1 - \frac{0.6159}{24.0199} = 0.9744.$$

Interpretación. En esta muestra, aproximadamente el 97.44 % de la variación observada de Y alrededor de su media es explicada por el conjunto formado por X_1 y X_2. Esto no significa, por sí solo, que cada coeficiente sea individualmente significativo, ni prueba causalidad.

Restricción. Bajo

$$H_0 : \beta_1 = \beta_2 = 0,$$

el modelo restringido es

$$Y_i = \beta_0 + \varepsilon_i.$$

Con constante, el valor ajustado es simplemente $\bar{Y}$, de modo que

$$\mathrm{SSR}_R = \sum_{i=1}^{12} (Y_i - \bar{Y})^2 = \mathrm{SST} = 24.0199.$$

Prueba global. Aquí

$$q = 2, \qquad n = 12, \qquad k = 2,$$

por lo que los grados de libertad del denominador son

$$n - k - 1 = 12 - 2 - 1 = 9.$$

Entonces

$$F_{\text{obs}} = \frac{(\mathrm{SSR}_R - \mathrm{SSR}_{NR})/q}{\mathrm{SSR}_{NR}/(n-k-1)} = \frac{(24.0199 - 0.6159)/2}{0.6159/9} = 170.99.$$

Equivalentemente,

$$F_{\text{obs}} = \frac{R^2/k}{(1-R^2)/(n-k-1)} = \frac{0.9744/2}{(1-0.9744)/9} = 170.99.$$

Conclusión. Bajo H_0,

$$F \sim F_{2,9}.$$

Al 5 %,

$$F_{0.05;\,2,9} = 4.256.$$

Como

$$170.99 > 4.256,$$

se rechaza H_0.

Conclusión estadística. Existe evidencia muy fuerte de que las dos regresoras son conjuntamente relevantes para explicar el rendimiento de la cartera.

Conclusión correcta en palabras. El rechazo de H_0 no afirma que *ambos* coeficientes sean distintos de cero; afirma que los datos son incompatibles con que *los dos sean simultáneamente cero*. Por lo menos una de las restricciones planteadas en H_0 no es compatible con la muestra.

Prueba individual. Ahora se desea contrastar

$$H_0 : \beta_2 = 0 \qquad \text{vs.} \qquad H_1 : \beta_2 \neq 0.$$

Hay una sola restricción, $q = 1$.

Al imponer $\beta_2 = 0$, el modelo restringido es

$$Y_i = \gamma_0 + \gamma_1 X_{1i} + \varepsilon_i.$$

La estimación restringida produce

$$\mathrm{SSR}_R = 0.8621,$$

mientras que el modelo no restringido mantiene

$$\mathrm{SSR}_{NR} = 0.6159.$$

Por tanto,

$$F_{\text{obs}} = \frac{(0.8621 - 0.6159)/1}{0.6159/9} = 3.597.$$

El valor crítico al 5 % es

$$F_{0.05;\,1,9} = 5.117.$$

Así,

$$3.597 < 5.117,$$

y **no se rechaza** H_0 al 5 %.

Comprobación. Para el coeficiente del tipo de cambio,

$$\hat{\beta}_2 = -0.8297, \qquad \mathrm{se}(\hat{\beta}_2) = 0.4374.$$

Entonces

$$t_{\text{obs}} = \frac{-0.8297}{0.4374} = -1.8968.$$

Con $\nu = 9$ grados de libertad,

$$t_{0.025;9} = 2.262.$$

Como

$$|-1.8968| < 2.262,$$

no se rechaza H_0 al 5 %.

Además,

$$t_{\text{obs}}^2 = (-1.8968)^2 = 3.598 \approx F_{\text{obs}}.$$

La pequeña diferencia se debe únicamente al redondeo. Una prueba F con una sola restricción y una prueba t bilateral para la misma restricción conducen a la misma decisión.

Interpretación del ejercicio 2. Este ejercicio muestra una distinción fundamental. El modelo es claramente significativo en conjunto: la prueba global rechaza con amplitud $H_0 : \beta_1 = \beta_2 = 0$. Sin embargo, al aislar el coeficiente del tipo de cambio, la evidencia al 5 % no es suficiente para rechazar $\beta_2 = 0$.

No existe contradicción. La prueba global pregunta si *el bloque completo* carece de poder explicativo; la prueba individual pregunta si, una vez controlado por el mercado, queda evidencia suficiente para atribuir a X_2 un efecto distinto de cero. Son preguntas estadísticas distintas.

También conviene separar tres ideas:

1. un coeficiente estimado puede tener una magnitud económicamente interesante;
2. esa magnitud puede estimarse con incertidumbre considerable;
3. no rechazar una hipótesis nula no equivale a demostrar que el efecto verdadero sea exactamente cero.

3.3 3. Factores

Contexto. Como en el ejemplo 3.2 de las notas, se explica el rendimiento anual en exceso de una acción, R_i (%), con tres características: tamaño S_i (*Size*, escala 1–5), valor V_i (*Value*, escala 0–2) y momento M_i (*Momentum*, escala −2 a 3):

$$R_i = \beta_0 + \beta_1 S_i + \beta_2 V_i + \beta_3 M_i + \varepsilon_i, \qquad n = 12, \quad k = 3.$$

Acción i	1	2	3	4	5	6	7	8	9	10	11	12
S	2	4	1	3	5	2	4	3	1	5	3	4
V	1	0	2	1	0	2	1	0	2	1	1	0
M	3	1	2	-1	0	1	2	-2	0	1	-1	2
R (%)	3.0	1.5	4.0	1.0	-0.5	2.5	1.0	0.5	2.5	0.0	2.5	1.0

Se pide. Probar al 5 % si Value y Momentum, como bloque, aportan información sobre el rendimiento una vez que se controla por tamaño: $H_0 : \beta_2 = \beta_3 = 0$.

Resolución

Hipótesis.

$$H_0:\ \beta_2 = \beta_3 = 0 \qquad \text{vs.} \qquad H_1:\ \beta_2 \neq 0 \text{ o } \beta_3 \neq 0, \qquad q = 2.$$

Modelo no restringido en forma matricial. La matriz de diseño X tiene una columna de unos y las columnas S, V, M. Sus productos cruzados son sumas que se obtienen directamente de la tabla de datos:

$$X'X = \begin{pmatrix} n & \sum S & \sum V & \sum M \\ \sum S & \sum S^2 & \sum SV & \sum SM \\ \sum V & \sum SV & \sum V^2 & \sum VM \\ \sum M & \sum SM & \sum VM & \sum M^2 \end{pmatrix} = \begin{pmatrix} 12 & 37 & 11 & 8 \\ 37 & 135 & 25 & 23 \\ 11 & 25 & 17 & 10 \\ 8 & 23 & 10 & 30 \end{pmatrix},$$

$$X'\mathbf{y} = \begin{pmatrix} \sum R \\ \sum SR \\ \sum VR \\ \sum MR \end{pmatrix} = \begin{pmatrix} 19.0 \\ 41.0 \\ 25.5 \\ 20.5 \end{pmatrix}.$$

Por ejemplo, $\sum SV = 2(1)+4(0)+1(2)+\cdots+4(0) = 25$ y $\sum MR = 3(3.0)+1(1.5)+\cdots+2(1.0) = 20.5$. El determinante es $\det(X'X) = 18\,225 \neq 0$ (no hay colinealidad perfecta) y la inversa es

$$(X'X)^{-1} = \begin{pmatrix} 2.14579 & -0.45663 & -0.72927 & 0.02096 \\ -0.45663 & 0.10765 & 0.14189 & -0.00807 \\ -0.72927 & 0.14189 & 0.33789 & -0.02694 \\ 0.02096 & -0.00807 & -0.02694 & 0.04291 \end{pmatrix}.$$

(Verifique, por ejemplo, que la primera fila de $X'X$ por la primera columna de la inversa da 1.) Entonces $\hat{\boldsymbol{\beta}} = (X'X)^{-1}X'\mathbf{y}$; la primera pendiente es

$$\hat{\beta}_1 = (-0.45663)(19.0) + (0.10765)(41.0) + (0.14189)(25.5) + (-0.00807)(20.5) = -0.8091,$$

y del mismo modo se obtienen las demás:

$$\boldsymbol{\hat{R}_i = 3.8816 - 0.8091\, S_i + 0.0253\, V_i + 0.2602\, M_i}$$

Suma de cuadrados residual SSR_{NR}**.** Atajo matricial: $\mathrm{SSR} = \mathbf{y}'\mathbf{y} - \hat{\boldsymbol{\beta}}'X'\mathbf{y}$, con $\mathbf{y}'\mathbf{y} = \sum R_i^2 = 49.50$ y

$$\hat{\boldsymbol{\beta}}'X'\mathbf{y} = (3.88156)(19.0) + (-0.80914)(41.0) + (0.02527)(25.5) + (0.26016)(20.5) = 46.5528,$$

$$\mathrm{SSR}_{NR} = 49.50 - 46.5528 = 2.9472.$$

Comprobación con los residuos:

i	1	2	3	4	5	6	7	8	9	10	11	12	Σ
$\hat{R}_i$	3.069	0.905	3.643	1.219	−0.164	2.574	1.191	0.934	3.123	0.121	1.219	1.165	19.000
$\hat{e}_i$	−0.069	0.595	0.357	−0.219	−0.336	−0.074	−0.191	−0.434	−0.623	−0.121	1.281	−0.165	0.000
$\hat{e}_i^2$	0.005	0.354	0.127	0.048	0.113	0.005	0.036	0.188	0.388	0.015	1.640	0.027	2.947

Modelo restringido: regresión simple sobre S. Imponer $\beta_2 = \beta_3 = 0$ equivale a estimar $R_i = \gamma_0 + \gamma_1 S_i + \varepsilon_i$. Con las fórmulas de cálculo (que usan las mismas sumas de $X'X$ y $X'\mathbf{y}$):

$$S_{SS} = \sum S^2 - \frac{(\sum S)^2}{n} = 135 - \frac{37^2}{12} = 135 - 114.0833 = 20.9167,$$

$$S_{SR} = \sum SR - \frac{(\sum S)(\sum R)}{n} = 41.0 - \frac{(37)(19.0)}{12} = 41.0 - 58.5833 = -17.5833,$$

$$S_{RR} = \sum R^2 - \frac{(\sum R)^2}{n} = 49.50 - \frac{19.0^2}{12} = 49.50 - 30.0833 = 19.4167 = \mathrm{SST}.$$

Coeficientes:

$$\hat{\gamma}_1 = \frac{S_{SR}}{S_{SS}} = \frac{-17.5833}{20.9167} = -0.8406,$$

$$\hat{\gamma}_0 = \bar{R} - \hat{\gamma}_1 \bar{S} = \frac{19}{12} + 0.8406\Big(\frac{37}{12}\Big) = 1.5833 + 2.5920 = 4.1753.$$

Suma de cuadrados residual:

$$\mathrm{SSR}_R = S_{RR} - \hat{\gamma}_1 S_{SR} = 19.4167 - (-0.8406)(-17.5833) = 19.4167 - 14.7812 = 4.6355.$$

Contraste. Con $q = 2$, $n = 12$, $k = 3$ y $n - k - 1 = 8$:

$$F = \frac{(\mathrm{SSR}_R - \mathrm{SSR}_{NR})/q}{\mathrm{SSR}_{NR}/(n-k-1)} = \frac{(4.6355 - 2.9472)/2}{2.9472/8} = \frac{0.84415}{0.36840} = 2.291.$$

Con R^2: $R^2_{NR} = 1 - 2.9472/19.4167 = 0.8482$ y $R^2_R = 1 - 4.6355/19.4167 = 0.7613$, de modo que

$$F = \frac{(0.8482 - 0.7613)/2}{(1 - 0.8482)/8} = \frac{0.043476}{0.018974} = 2.291.$$

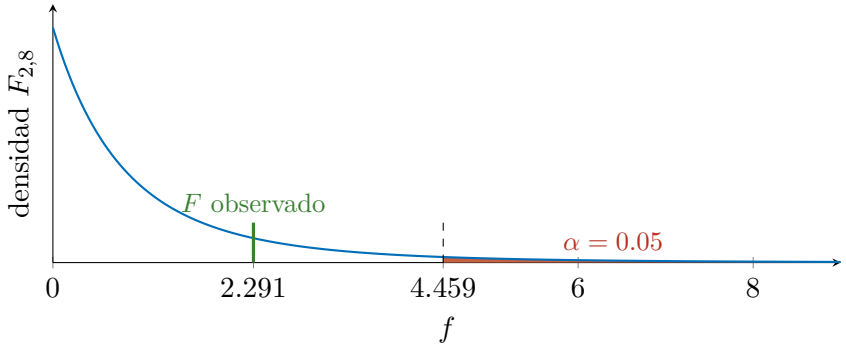
Conclusión. Bajo H_0, $F \sim F_{2,8}$ y $F_{0.05;\,2,8} = 4.459$.

$$F = 2.291 < 4.459 \implies \text{no se rechaza } H_0 \quad (\text{valor } p \approx 0.16).$$

Ni siquiera al 10 % se rechaza, pues $2.291 < 3.113 = F_{0.10;\,2,8}$.

Conclusión: una vez que se controla por tamaño, Value y Momentum, como bloque, no aportan información estadísticamente significativa sobre el rendimiento en esta muestra. Quitarlas eleva la suma de cuadrados residual de 2.947 a 4.636, pero ese aumento es compatible con el ruido residual.

El estadístico observado $F = 2.291$ cae en la región de no rechazo



Lección del ejercicio 3. Que el bloque $\{V, M\}$ no sea significativo no significa que el modelo completo sea inútil. La prueba global del mismo modelo, $H_0 : \beta_1 = \beta_2 = \beta_3 = 0$, da

$$F = \frac{\text{SSE}/k}{\text{SSR}/(n-k-1)} = \frac{(19.4167 - 2.9472)/3}{2.9472/8} = 14.90 > 4.066 = F_{0.05;\,3,8},$$

así que el modelo sí explica el rendimiento; lo que explica proviene esencialmente del tamaño. Cada prueba F responde a la pregunta que fija su H_0: hay que leer siempre *qué* restricciones se están probando.

3.4 4. Prueba t

Contexto. Retomamos la regresión del ejercicio 1, que explica el rendimiento del fondo con el rendimiento del mercado y la tasa de interés. La pendiente estimada de la tasa y su error estándar fueron $\hat{\beta}_2 = -1.0368$ y $\text{se}(\hat{\beta}_2) = 0.3991$, respectivamente. Con $n = 10$ observaciones y $k = 2$ regresoras, los grados de libertad residuales son $\nu = n - k - 1 = 7$.

Se pide. (a) Probar al 5 % $H_0 : \beta_2 = 0$ contra $H_1 : \beta_2 \neq 0$ con una prueba t. (b) Construir el intervalo de confianza del 95 % para β_2. (c) Representar la regla de decisión en la distribución t_7.

Resolución

Hipótesis y estadístico. La prueba es bilateral porque la alternativa permite que la pendiente sea positiva o negativa:

$$H_0 : \beta_2 = 0, \qquad H_1 : \beta_2 \neq 0, \qquad \alpha = 0.05.$$

El estadístico compara la estimación con el valor indicado por H_0, medido en errores estándar:

$$t = \frac{\hat{\beta}_2 - 0}{\text{se}(\hat{\beta}_2)} = \frac{-1.0368}{0.3991} = -2.598, \qquad \nu = 7.$$

Bajo H_0 y los supuestos clásicos, $T \sim t_7$.

Valor crítico y decisión. Al ser bilateral, se asigna $\alpha/2 = 0.025$ a cada cola. El valor crítico es $t_{0.025;\,7} = 2.365$:

$$|t| = 2.598 > 2.365 \implies \text{se rechaza } H_0.$$

El p-value bilateral es aproximadamente 0.0355: si H_0 fuera cierta, la probabilidad de observar un estadístico con magnitud al menos tan extrema como 2.598 sería de alrededor de 3.55 de cero. Su signo negativo indica una asociación inversa con el rendimiento del fondo, manteniendo fijo el rendimiento del mercado.

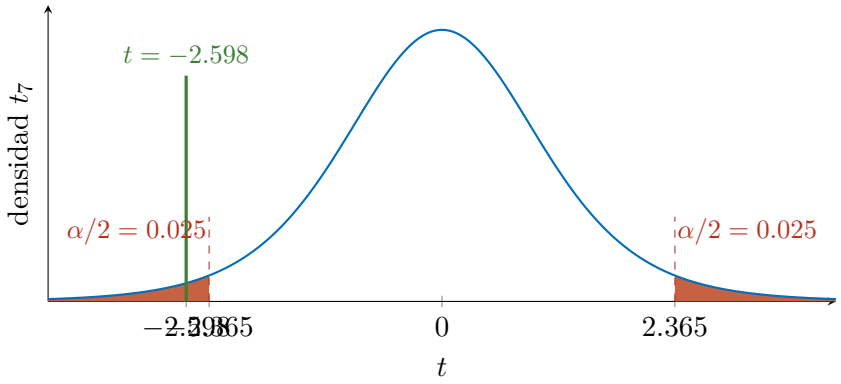
Intervalo de confianza del 95 %. El intervalo es la estimación más y menos el valor crítico multiplicado por su error estándar:

$$\hat{\beta}_2 \pm t_{0.025;\,7}\,\mathrm{se}(\hat{\beta}_2) = -1.0368 \pm (2.365)(0.3991) = -1.0368 \pm 0.9439,$$

$$\boldsymbol{\beta_2 \in [-1.9807,\ -0.0929]} \quad \text{(IC del 95 \%)}.$$

El intervalo no contiene cero, en concordancia con la decisión de rechazar H_0.

Prueba bilateral al 5 %: el estadístico observado cae en la región de rechazo



Comprobación con la prueba F. Para una sola restricción bilateral, la prueba F equivalente da $F_{1,7} = t^2 \approx 6.748$. Como $6.748 > F_{0.05;\,1,7} = 5.591$, también **se rechaza** H_0. Esto ilustra que $F = t^2$ conserva la decisión de la prueba t bilateral, aunque no conserva el signo del efecto.

3.5 5. Magnitud y significancia

Contexto. Considere un modelo semilogarítmico para salario:

$$\ln(\text{salario}_i) = \beta_0 + \beta_1\,\text{educación}_i + \beta_2\,\text{experiencia}_i + \beta_3\,\text{experiencia}_i^2 + \beta_4\,\text{mujer}_i + \varepsilon_i.$$

Con $n = 80$ observaciones y $k = 4$ regresoras, se obtiene

$$\hat{\beta}_1 = 0.082, \qquad \mathrm{se}(\hat{\beta}_1) = 0.021.$$

Se desea probar $H_0 : \beta_1 = 0$ contra $H_1 : \beta_1 \neq 0$ al 5 %.

Resolución

Los grados de libertad son $\nu = n - k - 1 = 75$ y

$$t_{\text{obs}} = \frac{0.082}{0.021} = 3.905.$$

El valor crítico bilateral es $t_{0.025;75} \approx 1.992$. Como

$$|t_{\text{obs}}| = 3.905 > 1.992,$$

se rechaza H_0. El p-value es aproximadamente 0.00020.

El intervalo de confianza del 95 % es

$$0.082 \pm (1.992)(0.021) = [0.040,\ 0.124].$$

Interpretación que sí debe escribirse. El resultado estadístico indica que, manteniendo constantes las demás variables del modelo, existe evidencia de que la educación está asociada con el

salario. Como la variable dependiente está en logaritmos, un año adicional de educación se asocia aproximadamente con un aumento de 8.2 % en el salario; de forma exacta, el cambio porcentual asociado es $100(e^{0.082} - 1) \approx 8.55$ %. El intervalo de confianza sugiere un efecto aproximado entre 4 % y 12 % por año adicional. La significancia estadística no sustituye la discusión de la magnitud económica del efecto.

3.6 6. Una cola

Contexto. En un modelo de demanda, el coeficiente de gasto publicitario se estima como

$$\hat{\beta}_A = 0.34, \qquad \text{se}(\hat{\beta}_A) = 0.15,$$

con $n = 50$ y $k = 3$. La pregunta económica no es si el efecto es simplemente distinto de cero, sino si es *positivo*:

$$H_0 : \beta_A \leq 0, \qquad H_1 : \beta_A > 0.$$

Resolución

Aquí $\nu = 46$ y

$$t_{\text{obs}} = \frac{0.34}{0.15} = 2.267.$$

Como la alternativa es de cola derecha, el valor crítico al 5 % es

$$t_{0.05;46} \approx 1.679.$$

Por tanto, $2.267 > 1.679$ y **se rechaza** H_0. El p-value unilateral es aproximadamente 0.0141.

Bilateral y unilateral no son intercambiables. La dirección de la prueba debe fijarse *antes* de observar el signo de $\hat{\beta}_A$. No es correcto calcular primero una prueba bilateral y después cambiarla a unilateral porque el coeficiente salió positivo. La hipótesis alternativa proviene de la pregunta económica, no del resultado muestral.

3.7 7. Un bloque

Contexto. Un modelo de rendimiento contiene cinco regresoras ($k = 5$) y se estima con $n = 60$ observaciones. Se quiere saber si dos variables macroeconómicas pueden eliminarse conjuntamente:

$$H_0 : \beta_4 = \beta_5 = 0.$$

Al estimar ambos modelos se obtiene

$$\text{SSR}_{NR} = 120, \qquad \text{SSR}_R = 138, \qquad q = 2.$$

Resolución

Los grados de libertad residuales del modelo no restringido son

$$n - k - 1 = 60 - 5 - 1 = 54.$$

Entonces

$$F_{\text{obs}} = \frac{(138 - 120)/2}{120/54} = 4.05.$$

Bajo H_0, $F \sim F_{2,54}$. Al 5 %,

$$F_{0.05;2,54} \approx 3.168.$$

Como $4.05 > 3.168$, **se rechaza** H_0; el p-value es aproximadamente 0.0230.

Qué significa el rechazo en una prueba conjunta. La conclusión correcta es que las dos restricciones *no son conjuntamente compatibles* con los datos al 5 %. No se puede concluir, a partir de esta prueba, que ambos coeficientes sean individualmente distintos de cero. Puede ocurrir que uno sea el que genere el rechazo o que la información relevante esté en su comportamiento conjunto.

3.8 8. No rechazo

Contexto. En un modelo con $n = 90$ y $k = 4$ se prueban tres restricciones simultáneas. Se obtiene

$$\text{SSR}_{NR} = 210, \qquad \text{SSR}_R = 219, \qquad q = 3.$$

Resolución

Los grados de libertad residuales son 85 y

$$F_{\text{obs}} = \frac{(219 - 210)/3}{210/85} = 1.214.$$

El valor crítico al 5 % es $F_{0.05;3,85} \approx 2.712$ y el p-value ≈ 0.310. Por tanto, no se rechaza H_0.

"No rechazar" no significa "demostrar". La evidencia muestral no es suficientemente fuerte para concluir que las tres restricciones fallen. Esto no prueba que H_0 sea verdadera ni que los coeficientes sean exactamente cero. La ausencia de rechazo puede deberse a que los efectos son pequeños, a que la muestra contiene poca información o a que los errores estándar son grandes. En econometría debe evitarse la frase "se acepta H_0" salvo que se esté usando un procedimiento diseñado explícitamente como prueba de equivalencia.

3.9 9. Restricción lineal

Contexto. Suponga que la pregunta económica es si dos efectos marginales son iguales:

$$H_0 : \beta_2 = \beta_3 \qquad \Longleftrightarrow \qquad H_0 : \beta_2 - \beta_3 = 0.$$

En una regresión con 70 grados de libertad residuales se obtiene

$$\hat{\beta}_2 - \hat{\beta}_3 = 0.18, \qquad \text{se}(\hat{\beta}_2 - \hat{\beta}_3) = 0.07.$$

Resolución

La prueba t es

$$t_{\text{obs}} = \frac{0.18}{0.07} = 2.571.$$

Al 5 % bilateral, $t_{0.025;70} \approx 1.994$, de modo que **se rechaza** H_0. El p-value es aproximadamente 0.0123.

Como hay una sola restricción, la prueba F equivalente satisface

$$F_{\text{obs}} = t_{\text{obs}}^2 = 6.612, \qquad F_{0.05;1,70} \approx 3.978.$$

La decisión es la misma.

Una idea importante sobre q. Una restricción lineal no tiene por qué ser "un coeficiente igual a cero". En este ejercicio $\beta_2 - \beta_3 = 0$ cuenta como *una* restricción, por lo que $q = 1$. En general pueden probarse restricciones como $\beta_1 + 2\beta_2 = 1$ o un sistema de varias igualdades lineales mediante una prueba F.

3.10 Cómo concluir

Una conclusión econométrica completa tiene tres niveles. Conviene escribirlos en este orden:

1. **Decisión estadística:** "se rechaza" o "no se rechaza" H_0 al nivel α.
2. **Traducción al parámetro:** indicar qué restricción concreta deja de ser compatible con la muestra.
3. **Interpretación económica:** explicar qué significa el signo, la magnitud y las unidades del efecto, si la especificación permite hacerlo.

Ejemplo de redacción correcta. "Como p-value $= 0.023 < 0.05$, se rechaza $H_0 : \beta_4 = \beta_5 = 0$ al 5 %. Existe evidencia de que las variables macroeconómicas consideradas aportan información explicativa de manera conjunta, condicional en las otras regresoras del modelo. La prueba no permite afirmar que ambas sean individualmente significativas."

Ejemplo de redacción que debe evitarse. "La F salió grande, entonces las variables sirven."

Esta frase no identifica la hipótesis, el nivel de significancia, la naturaleza conjunta de la prueba ni el alcance de la conclusión.

4 Ejercicios propuestos

En todos los ejercicios, escriba explícitamente H_0 y H_1, identifique la distribución de referencia, calcule el estadístico, determine el valor crítico o el p-value, tome una decisión y cierre con una interpretación en el contexto del problema.

1. En una regresión con $n = 40$ y $k = 3$ se obtiene $\hat{\beta}_2 = 1.25$ y $\text{se}(\hat{\beta}_2) = 0.48$. Pruebe $H_0 : \beta_2 = 0$ contra $H_1 : \beta_2 \neq 0$ al 5 % y construya el intervalo de confianza del 95 %.
2. En un modelo de ventas, $\hat{\beta}_P = -0.72$ y $\text{se}(\hat{\beta}_P) = 0.29$, con 55 grados de libertad residuales. Pruebe $H_0 : \beta_P \geq 0$ contra $H_1 : \beta_P < 0$ al 1 %. Explique por qué la prueba es unilateral.
3. Un modelo no restringido tiene $n = 75$, $k = 6$, $\text{SSR}_{NR} = 164$ y el modelo restringido tiene $\text{SSR}_R = 181$. Si $q = 2$, realice la prueba F al 5 %.
4. Con $n = 120$, $k = 5$, $R^2_{NR} = 0.63$ y $R^2_R = 0.59$, pruebe cuatro restricciones conjuntas al 5 % usando la forma de la prueba F basada en R^2.
5. En un modelo con $n = 100$ y $k = 4$, la prueba global usa $R^2 = 0.21$. Pruebe $H_0 : \beta_1 = \cdots = \beta_4 = 0$ al 5 %. Interprete cuidadosamente qué significa rechazar o no rechazar.
6. Para $H_0 : \beta_1 + \beta_2 = 1$ se tiene $\hat{\beta}_1 + \hat{\beta}_2 = 1.18$ y $\text{se}(\hat{\beta}_1 + \hat{\beta}_2) = 0.09$, con 60 grados de libertad. Realice la prueba bilateral al 5 % y exprese la prueba F equivalente.
7. Un investigador obtiene un p-value $= 0.078$ en una prueba F. Escriba la decisión al 10 %, 5 % y 1 %. Discuta por qué "significativo" no es una propiedad absoluta de un resultado.
8. Un coeficiente es estadísticamente significativo con $\hat{\beta} = 0.0021$ y un error estándar muy pequeño. Explique qué información adicional necesitaría para decidir si el efecto es económicamente importante.
9. En una prueba de tres restricciones se obtiene $F_{\text{obs}} = 2.45$ con grados de libertad $(3, 40)$. Use la tabla F del apéndice para acotar el p-value entre niveles de significancia disponibles.
10. Con $t_{\text{obs}} = -2.10$ y $\nu = 20$, use la tabla t para decidir una prueba bilateral al 10 %, 5 % y 1 %. Después compruebe sus decisiones en R o Python.
11. Explique por qué, al comparar dos modelos anidados, necesariamente $\text{SSR}_R \geq \text{SSR}_{NR}$. ¿Qué indicaría obtener lo contrario en un cálculo manual?
12. Construya un ejemplo verbal en el que una prueba F conjunta rechace H_0 aunque ninguna de dos pruebas t individuales parezca especialmente contundente. Explique por qué las pruebas individuales no sustituyen la prueba conjunta.

Preguntas de interpretación para acompañar cualquier ejercicio. Después de terminar el cálculo, pregúntese siempre: ¿qué parámetro o conjunto de parámetros está bajo prueba?, ¿la conclusión es individual o conjunta?, ¿la alternativa es bilateral o unilateral?, ¿qué unidades tiene

el coeficiente?, ¿la magnitud es económicamente relevante?, ¿la conclusión depende de supuestos que deberían mencionarse? Estas preguntas evitan que la inferencia se reduzca a comparar dos números.

4.1 Respuestas

1. Prueba t bilateral. Con $n = 40$, $k = 3$ y $\nu = 36$,

$$t = \frac{1.25}{0.48} = 2.604, \qquad p = 2P(T_{36} > 2.604) \approx 0.0133.$$

Como $p < 0.05$, **se rechaza** $H_0 : \beta_2 = 0$. El intervalo del 95 % es

$$\mathbf{1.25 \pm 2.028(0.48) = [0.277,\ 2.223]}.$$

En Python:

Código.

```
from scipy.stats import t
df = 36
t_obs = 1.25/0.48
p = 2*t.sf(abs(t_obs), df)
crit = t.ppf(.975, df)
print(t_obs, p, 1.25-crit*.48, 1.25+crit*.48)
```

2. Prueba unilateral.

$$t = \frac{-0.72}{0.29} = -2.483, \qquad p = P(T_{55} \leq -2.483) \approx 0.0081.$$

Por tanto, **se rechaza H_0 al 1 %**: hay evidencia de un efecto negativo.

3. Dos restricciones.

$$F = \frac{(181 - 164)/2}{164/68} = 3.524, \qquad p \approx 0.0350.$$

Así, **se rechazan conjuntamente las dos restricciones al 5 %**. En Python:

Código.

```
from scipy.stats import f
F = ((181-164)/2)/(164/68)
p = f.sf(F, 2, 68)
print(F, p)
```

4. Prueba F a partir de R^2.

$$F = \frac{(0.63 - 0.59)/4}{(1 - 0.63)/114} = 3.081, \qquad p \approx 0.0189.$$

Luego, **se rechazan las cuatro restricciones al 5 %**.

5. Significancia global.

$$F = \frac{0.21/4}{0.79/95} = 6.313, \qquad p \approx 1.51 \times 10^{-4}.$$

La conclusión correcta es: **el bloque de cuatro regresoras es conjuntamente significativo**. Esto no implica que las cuatro pendientes lo sean individualmente.

5 Práctica con datos reales

Los ejercicios siguientes retoman los mismos principios de inferencia y diagnóstico, pero ahora sobre conjuntos de datos reproducibles. Conviene ejecutarlos en Python y contrastar la salida computacional con las fórmulas desarrolladas en las secciones anteriores.

Problemas

Los siguientes ejercicios están diseñados para que el código sea parte del razonamiento y no una caja negra.

Ejercicio 1. Longley: significancia global frente a significancia individual

Cargue `sm.datasets.longley.load_pandas().data`. Estime empleo total sobre todas las regresoras disponibles. Después:

1. reporte R^2, $\bar{R}^2$, F global y su p-value;
2. identifique qué coeficientes no son individualmente significativos al 5 %;
3. calcule VIF para cada regresora;
4. explique por qué un modelo puede ser globalmente muy significativo y, al mismo tiempo, producir varios p-value individuales grandes;
5. vuelva a estimar después de estandarizar sólo las regresoras continuas y compare el número de condición.

Resultado esperado. El punto central no es "eliminar toda variable con VIF alto". La respuesta correcta discute redundancia de información, tamaño de muestra, tendencia común y precisión de efectos parciales.

Ejercicio 2. Engel: MCO clásico frente a HC3

Con los datos de Engel, estime gasto en alimentos sobre ingreso. Compare los errores estándar clásicos con HC3 y aplique Breusch–Pagan.

Resultado esperado. La pendiente MCO es aproximadamente 0.485 y la heteroscedasticidad se rechaza con enorme claridad. La comparación debe centrarse en la inferencia, no en un cambio de los coeficientes puntuales.

Ejercicio 3. Engel: media y cuantiles

Estime cuantiles $\tau = 0.10, 0.50, 0.90$ y compare sus pendientes con MCO. Interprete por qué la pendiente aumenta de aproximadamente 0.402 a 0.686 entre los cuantiles 0.10 y 0.90.

Ejercicio 4. Alemania: de un modelo estático a uno dinámico

Estime R_t sobre Dp_t. Calcule DW y BG(4). Después incluya al menos un rezago de R_t y compare el diagnóstico residual.

Resultado esperado. El modelo estático presenta autocorrelación severa. El objetivo no es forzar un p-value por encima de 0.05, sino capturar una dinámica económicamente plausible.

Ejercicio 5. Macrodata: multiplicador de largo plazo

Estime

$$realint_t = \alpha + \phi realint_{t-1} + \beta infl_t + u_t.$$

Calcule $\beta/(1-\phi)$ y discuta qué supuestos hacen posible hablar de largo plazo.

Ejercicio 6. Iris: MANOVA

Use las cuatro medidas morfológicas como respuestas y especie como factor. Compare lambda de Wilks y traza de Pillai. Explique por qué esta prueba no sustituye un VIF.

Resultados

1. Longley

El modelo completo entrega $R^2 \approx 0.9955$ y $\bar{R}^2 \approx 0.9925$. La prueba conjunta produce $F \approx 330.29$ con p-value $\approx 4.98 \times 10^{-10}$, por lo que se rechaza que todas las pendientes sean simultáneamente cero. Sin embargo, algunos p-value individuales son grandes. Por ejemplo, el deflactor del PNB y población no son individualmente precisos en esta especificación. Los VIF extremos —en particular $\text{VIF}_{GNP} \approx 1788.5$— explican por qué las varianzas de varios estimadores están fuertemente infladas. La conclusión correcta no es que "el modelo sea malo": predicción conjunta e identificación de pendientes individuales son cuestiones distintas.

2. Engel

MCO produce

$$\widehat{foodexp} = 147.48 + 0.4852\, income.$$

La prueba de Breusch–Pagan da $LM \approx 109.26$ y p-value $\approx 1.42 \times 10^{-25}$, por lo que la hipótesis de homoscedasticidad se rechaza. Los coeficientes MCO no cambian al solicitar HC3; cambia la estimación de su matriz de covarianza. Ésta es exactamente la distinción entre estimación e inferencia robusta.

3. Engel cuantílico

Las pendientes aproximadas son 0.402, 0.560 y 0.686 para $\tau = 0.10, 0.50, 0.90$. El ingreso está asociado con incrementos mayores del gasto en alimentos en cuantiles altos de la distribución condicional. MCO resume esa heterogeneidad en una única pendiente media cercana a 0.485.

4. Alemania

El modelo estático presenta $DW \approx 0.173$ y BG(4) con $LM \approx 94.73$, p-value $\approx 1.30 \times 10^{-19}$. La evidencia de autocorrelación es demasiado fuerte para tratarla como un detalle de presentación. Una especificación dinámica o una estrategia temporal más rica debe formar parte del modelo, mientras que HAC puede utilizarse cuando el interés está en robustecer la inferencia de una media condicional ya razonable.

5. Macrodata

La estimación produce aproximadamente $\hat{\phi} = 0.428$ y $\hat{\beta} = -0.391$. Como $|\hat{\phi}| < 1$, el modelo estimado es estable en el sentido elemental del ARDL(1,0). El multiplicador es

$$\frac{-0.391}{1 - 0.428} \approx -0.683.$$

Su interpretación económica exige cautela: estabilidad estadística no demuestra exogeneidad de la inflación ni identificación causal.

6. Iris

La MANOVA encuentra separación multivariada marcada entre especies cuando se consideran conjuntamente las medidas morfológicas. Wilks y Pillai son formas alternativas de resumir esa separación. Un VIF, en cambio, se calcula a partir de regresiones auxiliares entre columnas explicativas. Por ello no responden a la misma pregunta y no son intercambiables.

6 Verificación en Python

Una clase pequeña permite comprobar los resultados sin repetir código. El objeto estima MCO y devuelve coeficientes, pruebas t, prueba global, intervalos y restricciones F.

Código 18. *Verificador orientado a objetos*

```python
from dataclasses import dataclass
import pandas as pd
import statsmodels.api as sm
from scipy.stats import t, f

@dataclass
class OLSVerifier:
    data: pd.DataFrame
    y: str
    x: list[str]

    def fit(self):
        X = sm.add_constant(self.data[self.x])
        self.model = sm.OLS(self.data[self.y], X).fit()
        return self

    def coefficients(self):
        return pd.DataFrame({
            "beta": self.model.params,
            "se": self.model.bse,
            "t": self.model.tvalues,
            "p": self.model.pvalues
        })

    def t_test(self, name, value=0.0, alpha=0.05):
        b, se = self.model.params[name], self.model.bse[name]
        stat = (b - value) / se
        df = int(self.model.df_resid)
        crit = t.ppf(1 - alpha/2, df)
        return {
            "t": stat,
            "p": 2*t.sf(abs(stat), df),
            "critical": crit,
            "CI": (b-crit*se, b+crit*se)
        }

    def global_f(self, alpha=0.05):
        F = float(self.model.fvalue)
        dfn, dfd = int(self.model.df_model), int(self.model.df_resid)
        return {
            "F": F,
            "p": f.sf(F, dfn, dfd),
            "critical": f.ppf(1-alpha, dfn, dfd)
        }

    def restriction_f(self, restriction):
        test = self.model.f_test(restriction)
        return {"F": float(test.fvalue), "p": float(test.pvalue)}
```

Código 19. *Comprobación del Ejercicio 1*

```python
df = pd.DataFrame({
    "mercado": [1.2,-0.8,2.0,0.5,-1.5,1.0,2.5,-0.3,0.0,1.4],
    "tasa":    [7.0,7.5,6.5,7.0,8.0,7.5,6.0,7.5,7.0,6.0],
    "fondo":   [1.0,0.2,1.6,1.1,-1.2,0.2,2.4,-0.7,0.9,1.5]
})

v = OLSVerifier(df, "fondo", ["mercado", "tasa"]).fit()
print(v.coefficients().round(4))
print("R2 =", round(v.model.rsquared, 4))
print("F global =", v.global_f())
```

```
11 print("tasa =", v.t_test("tasa"))
```

Código 20. *Salida esencial*

```
              beta      se       t       p
const       7.7808  2.8562  2.7244  0.0296
mercado     0.2950  0.2113  1.3960  0.2053
tasa       -1.0368  0.3991 -2.5976  0.0355

R2 = 0.8867
F global = {'F': 27.4045, 'p': 0.00049, 'critical': 4.7374}
```

La clase reproduce

$$\hat{Y} = 7.7808 + 0.2950X_1 - 1.0368X_2, \qquad R^2 = 0.8867, \qquad F = 27.40.$$

El cálculo queda automatizado; la interpretación sigue siendo responsabilidad del alumno.

7 Resumen

Prueba t para un coeficiente.

$$t = \frac{\hat{\beta}_j - \beta_{j,0}}{\mathrm{se}(\hat{\beta}_j)}, \qquad \nu = n - k - 1.$$

Bilateral: rechazar si $|t| > t_{\alpha/2;\nu}$.
Cola derecha: rechazar si $t > t_{\alpha;\nu}$.
Cola izquierda: rechazar si $t < -t_{\alpha;\nu}$.

Prueba F de q restricciones lineales.

$$F = \frac{(\mathrm{SSR}_R - \mathrm{SSR}_{NR})/q}{\mathrm{SSR}_{NR}/(n-k-1)} \sim F_{q,n-k-1} \quad \text{bajo } H_0.$$

Se rechaza si $F > F_{\alpha;q,n-k-1}$.

Intervalo de confianza bilateral para β_j.

$$\hat{\beta}_j \pm t_{\alpha/2;n-k-1}\,\mathrm{se}(\hat{\beta}_j).$$

8 Cierre

Una conclusión profesional evita tanto la verbosidad como la simplificación excesiva. Debe contener cinco elementos: el objeto contrastado, la dirección y magnitud de la estimación, la precisión estadística, el diagnóstico relevante y la limitación interpretativa principal.

Por ejemplo, en Engel puede escribirse: “El gasto anual en alimentos aumenta en promedio con el ingreso; la pendiente MCO estimada es 0.485 y es estadísticamente muy precisa. Sin embargo, los residuos muestran heteroscedasticidad severa, por lo que la inferencia homoscedástica clásica no es adecuada. La regresión cuantílica muestra además que la sensibilidad al ingreso es mayor en cuantiles altos del gasto, de modo que una única pendiente media oculta heterogeneidad importante.”

En Alemania, una conclusión correcta sería: “La pendiente contemporánea de inflación es positiva pero no significativa al 5 % en el modelo estático. No obstante, el diagnóstico residual revela autocorrelación muy fuerte, por lo que la principal limitación del modelo no es sólo la imprecisión de $\hat{\beta}_1$, sino una especificación temporal incompleta.”